

■ APPRENTISSAGE SUPERVISÉ ET NON SUPERVISÉ

L'APPRENTISSAGE SUPERVISÉ

C. LES ARBRES DE DÉCISIONS

Les modèles étudiés jusqu'ici, principalement les KNN et la régression logistique, réalisent l'étiquetage d'une observation $x \in \mathcal{X}$ en une seule étape. En particulier, ils utilisent le même ensemble de variables pour toutes les classes, et leur accordent la même importance pour toutes les observations.


Ce n'est donc pas adapté aux situations où les classes ont une distribution multimodale, suivant les régions de l'espace considérées, elles sont déterminées par différentes variables.


ex : symptômes d'une maladie qui ne sont pas les mêmes suivant l'âge de l'individu.

Les arbres de décision, au contraire, sont des modèles hiérarchiques qui se comportent comme une série successive de tests conditionnels, dans laquelle chaque test dépend des tests précédents et de leur résultat.

Définition

On appelle **arbre de décision** un modèle de prédiction qui peut être représenté sous la forme d'un arbre. Chaque noeud de l'arbre teste une condition sur une seule variable et chacun de ses enfants correspond à une réponse possible à cette condition. Les feuilles de l'arbre correspondent à une étiquette.





Les arbres de décision

- permettent de traiter des variables qualitatifs (ex : taille et couleur du fruit), sans nécessiter une représentation numérique de ces variables. On parle *d'apprentissage non métrique*. Ils sont donc adaptés aux données hétérogènes (variables quantitatives et qualitatives)
- permettent de traiter un problème de classification multiclasse sans passer par des classifications binaires *Et pour les KNN ? pour la régression logistique ?*
- permettent de traiter des classes multi-modales (comme ici pour l'étiquette « pomme », qui est affectée à un fruit grand et rouge ou à un fruit jaune et rond.) *Et pour les KNN ? pour la régression logistique ?*

■ L'algorithme CART




Pour construire des arbres de décisions, on peut utiliser l'algorithme CART (Classification and Regression Tree). C'est un algorithme de partitionnement de l'espace par une approche gloutonne, récursive et divisive qui permet d'apprendre un *arbre binaire* à partir de données d'apprentissage $(x_1, y_1), \dots, (x_n, y_n) \in \mathcal{X} \times \mathcal{Y}$.

- 1** Chaque noeud sépare linéairement le jeu de données (chaque noeud a exactement deux enfants ; pas de perte de généralité car un arbre peut être ré-exprimé sous la forme d'un arbre binaire)
- 2** Pour partitionner les données on n'utilise qu'une seule variable par noeud. Pour des variables numériques, la frontière de décision produite est alors orthogonale à l'axe de cette variable.
- 3** Lorsqu'on arrive au feuille, on utilise une règle d'agrégation (vote pour un problème de classification, moyenne pour un problème de régression) pour estimer l'étiquette y d'un point $x \in \mathcal{X}$.

■ Séparation linéaire

Un arbre peut être ré-exprimé sous la forme d'un arbre binaire



Tirée de l'ouvrage *Introduction au Machine Learning* de Chloé-Agathe Azencott

Remarque La construction de l'arbre est itérative, noeud par noeud, en partant de la racine

■ Une seule variable par noeud

À chaque noeud d'un arbre de décision construit par CART correspond une variable séparatrice x^j selon laquelle vont être partitionnées les données. Cette variable séparatrice définit deux régions R_l et R_m , correspondant aux enfants du noeud considéré.

variable binaire (quali ou quanti) Si x^j est binaire alors les deux régions sont

$$R_l(x^j) = \{x \in \mathcal{X} : x^j = 1\} \quad R_m(x^j) = \{x \in \mathcal{X} : x^j = 0\}$$

variable qualitative nominale Si x^j peut prendre plus de deux modalités, alors pour un sous-ensemble S de modalités sélectionnées (souvent $\dim(S) = 1$) :

$$R_l(x^j, S) = \{x \in \mathcal{X} : x^j \in S\} \quad R_m(x^j, S) = \{x \in \mathcal{X} : x^j \notin S\}$$

variable quantitative continue Si x^j est une variable quantitative continue, alors pour un point de séparation sélectionné s qui est la valeur de l'attribut par rapport à laquelle va se faire la décision :

$$R_l(x^j, s) = \{x \in \mathcal{X} : x^j < s\} \quad R_m(x^j, s) = \{x \in \mathcal{X} : x^j \geq s\}$$

■ Une seule variable par noeud




variable qualitative ordinale Si x^j est quantitative ordinale, on peut la traiter comme une variable quantitative continue (séparation "par seuil" en respectant l'ordre des modalités) ou comme une variable qualitative nominale (regroupement de modalités)

variable quantitative discrète Si x^j est une variable quantitative discrète, alors on la traite souvent comme une variable quantitative continue (séparation "par seuil"). Si x^j prend peu de valeurs différentes, on peut aussi la traiter comme une variable qualitative nominale (regroupement de modalités) même si, dans ce cas-là, on perd la notion d'ordre

Autre exemple


L'étudiant va réussir à valider son cours de *machine learning*



■ Une seule variable par noeud




Notes en maths et en informatique



■ Une seule variable par noeud

Chaque noeud produit une frontière de décision orthogonale aux axes




Remarques

- L'algorithme construit non pas un mais plusieurs séparateurs linéaires pour construire des frontières de décision non linéaires.
- Utiliser des séparateurs linéaires parallèles aux axes favorise l'interprétabilité
- Chaque point du jeu de données (et plus généralement, chaque point $x \in \mathcal{X}$) n'appartient qu'à une unique région à un instant donné

■ Une seule variable par noeud


L'arbre correspondant



■ Une seule variable par noeud



Quel arbre pour la partition suivante ?



Remarque Un arbre de décision partitionne l'espace $\mathcal{X}$ des observations en autant de régions qu'il a de feuilles dans l'arbre final construit

■ Règle d'agrégation

Supposons que l'algorithme a partitionné le jeu de données en r régions $R_1, R_2, \dots, R_r$.

Toutes les observations qui tombent dans une même feuille, i.e. qui appartiennent à une même région, reçoivent alors la même étiquette.




Problème de classification L'étiquette prédite d'un nouveau point x qui est dans une région est l'étiquette majoritaire dans la région des observations d'apprentissage qui sont dans cette région

$$f(x) = \sum_{j=1}^r \mathbb{1}\{x \in R_j\} \arg \max_{k \in \{1, \dots, C\}} \sum_{\substack{i \in \{1, \dots, n\} \\ x_i \in R_j}} \mathbb{1}\{y_i = k\}$$

Problème de régression L'étiquette prédite d'un nouveau point x qui est dans une région est l'étiquette moyenne des observations d'apprentissage qui sont dans cette région

$$f(x) = \sum_{j=1}^r \mathbb{1}\{x \in R_j\} \frac{1}{|R_j|} \sum_{\substack{i \in \{1, \dots, n\} \\ x_i \in R_j}} y_i$$

■ Variables séparatrices



Pour un noeud, comment choisir la bonne séparation, i.e. la bonne **variable séparatrice** et la frontière de séparation ?

En classification, pour un noeud (une région R), on choisit le découpage qui maximise le gain d'information, i.e., on choisit la variable séparatrice x^j et le seuil de séparation *seuil* (s pour une variable continue ou S pour une variable discrète) qui maximise

$$\mathcal{IG}(R_l, R_m) = \mathcal{I}(R) - \frac{n_l}{n} \mathcal{I}(R_l(x^j, \text{seuil})) - \frac{n_m}{n} \mathcal{I}(R_m(x^j, \text{seuil}))$$

avec

- $\mathcal{I}$: un critère d'impureté qui quantifie à quel point la région considérée est « polluée » par des éléments des classes qui n'y sont pas majoritaires.
- n : le nombre de points x_i du jeu d'entraînement qui sont dans R .
- n_l, n_m : le nombre de points x_i du jeu d'entraînement qui sont respectivement dans R_l et R_m

Quels critères d'impureté utiliser ?

■ Critères d'impureté

Soit p_k est la proportion d'éléments de la classe k dans la région R .

■ Impureté de Gini

Permet de quantifier la probabilité qu'un exemple du jeu d'entraînement soit mal étiqueté s'il était étiqueté aléatoirement en fonction de la distribution des étiquettes dans R

$$\mathcal{I}_G(R) = \sum_{k=1}^C p_k(1 - p_k) = \sum_{k=1}^C \sum_{k' \neq k \in \{1, \dots, C\}} p_k p_{k'}$$

■ Entropie

Permet de définir l'impureté d'une région R de sorte à choisir la séparation qui maximise le gain d'information : le but de la construction est alors de minimiser la quantité d'information supplémentaire nécessaire pour étiqueter correctement les exemples d'entraînement de R .

$$\mathcal{I}_E(R) = - \sum_k p_k \log_2(p_k)$$

■ Erreur de classification

Permet de définir l'impureté d'une région R comme la proportion d'exemples de cette région qui n'appartiennent pas à la classe majoritaire.

$$\mathcal{I}_{EC}(R) = 1 - \max_k(p_k)$$

- Soit le *Mean-Squared Error* MSE (relativement à la moyenne) :

$$\text{MSE}(R) = \frac{1}{n} \sum_i (y_i - \bar{y})^2$$

- On cherche à minimiser le critère suivant :

$$\frac{n_l}{n} \text{MSE}(R_l) + \frac{n_r}{n} \text{MSE}(R_m)$$

- On calcule le MSE relativement à la moyenne car celle-ci est justement notre prédiction pour un nœud fixé.

Quand est-ce qu'on arrête la construction d'un arbre ?

- Si l'arbre est peu profond, on risque de mal modéliser le problème (sous-apprentissage)
- Si l'arbre est trop profond, on risque de "trop coller aux données" et donc de sur-apprendre

Stratégie n°1

On détermine un des hyper-paramètres suivant par validation croisée

- Profondeur maximale
- nombre de feuilles maximal
- nombre d'exemples minimal dans une feuille/nœud

Question : comment se comporte la variance et le biais en fonction de la profondeur de l'arbre ?

Stratégie n°2 - Élagage

On utilise un ensemble de validation pour re-visiter un arbre appris sans limite sur un ensemble d'apprentissage. On ne garde que les branches qui apportent une amélioration en validation.

C'est une méthode de régularisation permettant de contrôler la complexité de l'arbre, mesurée par le nombre de régions qu'il définit. En particulier, on cherche à minimiser le coût en complexité suivant d'un arbre T :

$$C_{\lambda}(T) = \sum_{l=1}^{|T|} n_l \mathcal{I}(R_l) + \lambda |T|$$

où

- $|T|$ est le nombre de régions définies par l'arbre T
- $\lambda > 0$, un hyperparamètre permettant de contrôler l'importance relative de la mesure d'erreur et de la complexité



Les arbres de décision ont tendance à donner des modèles trop simples et à avoir des performances de prédiction à peine supérieures à des modèles aléatoires et peu robustes aux variations dans les données. On les qualifie d'apprenants faibles (weak learners en anglais). Heureusement, il est possible d'y remédier grâce aux méthodes ensemblistes (bagging, forêts aléatoires, boosting, voir cours *Régularisation et optimisation*)



C.A. Azencot Introduction au Machine Learning, *Dunod*,
ISBN : 978-2-10-084143-1



S. Shalev-Shwartz and S. Ben-David, Understanding Machine Learning: From Theory to Algorithms, *Cambridge University Press*, DOI :
10.1017/CBO9781107298019, 2014



T. Hastie, R. Tibshirani, and J. Friedman. The Elements of Statistical Learning, *Springer New York*, DOI : 10.1007/978-0-387-84858-7, 2009