

■ CLASSIFICATION SUPERVISÉE ET NON SUPERVISÉE

Clustering

MARINE DEMANGEOT


Ce cours s'inspire très largement de l'ouvrage
Introduction au Machine Learning
de Chloé-Agathe Azencott

■ Clustering – Objectif

Contexte On observe des **données** $x_1, \dots, x_n \in \mathcal{X}$ pour n individus mais **sans étiquettes** associées (on dit qu'elles sont non étiquetées)

Objectif Séparer les données en sous-groupes homogènes, appelés **clusters**

Permet d'extraire de l'information sur les données, de mieux comprendre leurs caractéristiques générales : c'est une **analyse exploratoire des données**



Identification de gènes similaires

Permet de faire des hypothèses sur le rôle des gènes




Image tirée d'une présentation donnée par Chloé-Agathe Azencott en 2019 aux Mines de Paris (Fontainebleau)

Segmentation de marché

Permet d'identifier des groupes d'utilisateurs ou de clients dont le comportement est similaire afin de mieux comprendre leur profil




Image tirée d'une présentation donnée par Chloé-Agathe Azencott en 2019 aux Mines de Paris (Fontainebleau)

Compression d'image



Image originale



Image compressée (16 couleurs)




Image compressée (4 couleurs)

Image tirée du site [Towards Data Science](#)

Annotation d'un corpus de texte

En regroupant automatiquement l'ensemble des textes par sujet à l'aide d'un algorithme de clustering, il est possible de déterminer le ou les sujets abordés par des textes d'un même cluster en lisant seulement quelques textes de ce cluster



Objectif Séparer les données en sous-groupes, appelés **clusters** tels que chaque cluster est le plus **homogène** possible et les clusters entre eux sont les plus **distincts/séparés** possible

On souhaite donc que les individus similaires soient dans le même cluster et que les individus dissimilaires soient dans des clusters différents. Comment mesurer la distance entre deux individus ?



On mesure la distance entre deux individus à l'aide d'**une fonction d appelée distance**

Définition

Soit un ensemble $\mathcal{X}$. Une fonction $d : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+$ est appelée *distance* si elle vérifie les propriétés suivantes :

- $\forall x, y \in \mathcal{X} \quad d(x, y) = d(y, x) \quad (\text{Symétrie})$
- $\forall x, y \in \mathcal{X} \quad d(x, y) = 0 \Leftrightarrow x = y \quad (\text{Séparation})$
- $\forall x, y, z \in \mathcal{X} \quad d(x, y) \leq d(x, z) + d(z, y) \quad (\text{Inégalité triangulaire})$

■ Distances – variables quantitatives



■ $x = (x_1, \dots, x_d), y = (y_1, \dots, y_d) \in \mathbb{R}^d$ variables **quantitatives** $d \in \mathbb{N}^*$

Exemple de distance :

- **Euclidienne** – $d(x, y) = \|x - y\|_2 = \sqrt{\sum_{i=1}^d (x_i - y_i)^2}$
- **Manhattan** – $d(x, y) = \|x - y\|_1 = \sum_{i=1}^d |x_i - y_i|$
- **Minkowski** – $d(x, y) = \left(\sum_{i=1}^d (x_i - y_i)^p \right)^{1/p}$ $p \in \mathbb{R}^*$
- **Chebyshev** – $d(x, y) = \max_{i \in \{1, \dots, n\}} |x_i - y_i|$
- **Mahalanobis** – $d(x, y) = \sqrt{(x - y)^\top \Sigma^{-1} (x - y)}$
 Σ : matrice de variance-covariance empirique

Remarque On considère souvent la distance euclidienne que l'on notera plus simplement $\|\cdot\|$ par la suite.

■ Distances – variables qualitatives ou mixtes ■

- $x = (x_1, \dots, x_d), y = (y_1, \dots, y_d)$ variables **qualitatives**

Exemple de distance : Distance du χ_2 , distance de Jaccard, distance de Gower. Ces distances ne sont pas des distances au sens mathématique. La distance du χ_2 ne respecte par exemple pas la propriété de symétrie

- $x = (x_1, \dots, x_d), y = (y_1, \dots, y_d)$ variables **quantitatives et qualitatives**


Exemples de stratégies possibles :

- Rendre les variables quantitatives qualitatives (découpage en classes)
- Rendre les variables qualitatives quantitatives (ex : encodage one-hot)
- Rendre toutes les variables qualitatives puis faire une analyse des correspondances multiples (ACM) et considérer les coordonnées (quantitatives) des individus dans les nouveaux axes.


■ Choix d'une partition

Question Une fois la distance choisie, quelle partition (clustering) choisir ?

Stratégie de ne pas séparer les points proches l'un de l'autre
(e.g. algorithme de clustering hiérarchique avec lien simple)



Stratégie de ne pas avoir des points trop éloignés dans le même cluster
(e.g. algorithme des 2-moyennes)



Tirée de l'ouvrage *Understanding Machine Learning: From Theory to Algorithms*



On voudrait choisir la partition qui minimise un certain critère (à choisir) qui dépend de l'homogénéité et de la séparabilité des clusters

■ Homogénéité

Le fait que des observations proches appartiennent au même cluster peut se traduire par la notion d'homogénéité

Définition

On appelle *centroïde* du cluster C le point défini par

$$\mu_C = \frac{1}{|C|} \sum_{x \in C} x \quad |C| : \text{nombre d'observations dans } C$$

Définition


On appelle *homogénéité* du cluster C_k (*tightness* en anglais) la moyenne des distances des observations de ce cluster à son centroïde μ_k :

$$T_k = \frac{1}{|C_k|} \sum_{x \in C_k} d(x, \mu_k)$$

L'*homogénéité globale* d'un clustering de $\mathcal{D}$ de taille K est donné par

$$T = \frac{1}{K} \sum_{k=1}^K T_k$$

Remarque On souhaite avoir T le plus petit possible



Tirée de l'ouvrage *Introduction au Machine Learning* de Chloé-Agathe Azencott

Pour quantifier à quel point les clusters sont distants les uns des autres, nous pouvons utiliser le critère de séparabilité

Définition


On appelle *séparabilité* des clusters C_k et C_ℓ la distance entre leurs centroïdes :

$$S_{k\ell} = d(\mu_k, \mu_\ell)$$

La *séparabilité globale* d'un clustering de D de taille K se calcule comme la moyenne des séparabilités des clusters deux à deux :

$$S = \frac{2}{K(K-1)} \sum_{k=1}^K \sum_{\ell=k+1}^K S_{k\ell}$$

Remarque On souhaite avoir S le plus élevé possible



Tirée de l'ouvrage *Introduction au Machine Learning* de Chloé-Agathe Azencott

Définition

On appelle *indice de Davies-Bouldin* du cluster C_k la valeur

$$D_k = \max_{\ell \neq k} \frac{T_k + T_\ell}{S_{k\ell}}$$

L'*indice de Davies-Bouldin global* d'un clustering de $\mathcal{D}$ de taille K se calcule comme la moyenne des indices de Davies-Bouldin des clusters :

$$D = \frac{1}{K} \sum_{k=1}^K D_k$$

Objectif On souhaite trouver le clustering $\mathcal{D}$ qui minimise D

■ Coefficient de silhouette

Définition

On appelle *coefficient de silhouette* de l'observation $x \in \{x_1, \dots, x_n\}$ la valeur

$$s_x = \frac{b(x) - a(x)}{\max((a(x), b(x)))} \in [-1, 1]$$

avec

$$a(x) = \frac{1}{|C_{k(x)}| - 1} \sum_{y \in C_{k(x)}, y \neq x} d(x, y) \quad b(x) = \min_{\ell \neq k(x)} \frac{1}{|C_\ell|} \sum_{y \in C_\ell} d(x, y)$$

i.e. $a(x)$ est la distance moyenne de x à tous les autres éléments du cluster $C_{k(x)}$ auquel il appartient et $b(x)$ est la plus petite valeur que pourrait prendre $a(x)$ si x appartenait à un autre cluster

Le *coefficient de silhouette global* se calcule comme la moyenne des coefficients de silhouette :

$$s = \frac{1}{n} \sum_{i=1}^n s(x_i)$$

Remarque

Le coefficient de silhouette de x est d'autant plus proche de 1 que son assignation au cluster $C_{k(x)}$ est satisfaisante

■ Coefficient de silhouette

Définition

On appelle *coefficient de silhouette* de l'observation $x \in \{x_1, \dots, x_n\}$ la valeur

$$s_x = \frac{b(x) - a(x)}{\max((a(x), b(x)))} \in [-1, 1]$$

avec

$$a(x) = \frac{1}{|C_{k(x)}| - 1} \sum_{y \in C_{k(x)}, y \neq x} d(x, y) \quad b(x) = \min_{\ell \neq k(x)} \frac{1}{|C_\ell|} \sum_{y \in C_\ell} d(x, y)$$

i.e. $a(x)$ est la distance moyenne de x à tous les autres éléments du cluster $C_{k(x)}$ auquel il appartient et $b(x)$ est la plus petite valeur que pourrait prendre $a(x)$ si x appartenait à un autre cluster

Le *coefficient de silhouette global* se calcule comme la moyenne des coefficients de silhouette :

$$s = \frac{1}{n} \sum_{i=1}^n s(x_i)$$

Objectif On souhaite trouver le clustering $\mathcal{D}$ qui maximise s

■ Inertie intra et inter classes

Contexte On observe des **données** $x_1, \dots, x_n \in \mathbb{R}^d$. On note $\mu = \frac{1}{n} \sum_{i=1}^n x_i$ et on considère la distance euclidienne

On peut également quantifier la notion d'homogénéité et de séparabilité d'un clustering $\mathcal{D}$ de taille K de $\{x_1, \dots, x_n\}$ à travers la notion d'inertie donnée par

$$I = \sum_{i=1}^n \|x_i - \mu\|^2 = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2 + \sum_{k=1}^K |C_k| \|\mu_k - \mu\|^2$$

Aussi, I se décompose en deux parties :

- $I_W = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2$: **inertie intra-classes** qui mesure l'homogénéité au sein des classes
- $I_B = \sum_{k=1}^K |C_k| \|\mu_k - \mu\|^2$: **inertie inter-classes** qui mesure l'hétérogénéité entre les classes, c'est-à-dire à quel point les classes sont bien séparées

Objectif On souhaite trouver le clustering $\mathcal{D}$ qui maximise I_B ou de manière équivalente qui minimise I_W

■ Choix d'une partition

Contexte On souhaite partitionner des **données** $x_1, \dots, x_n \in \mathcal{X}$



On voudrait choisir la partition C^* qui minimise un certain critère R (à choisir) qui dépend de l'homogénéité et de la séparabilité des clusters

$$C^* = \arg \min_{K \in \{1, \dots, n\}} \min_{C_1, \dots, C_K} R(C_1, \dots, C_K)$$

avec $R(C_1, \dots, C_K)$ l'indice de Davies-Bouldin global, le coefficient de silhouette global ou la variance intra-classes du clustering $\mathcal{D} = \{C_1, \dots, C_K\}$



Le nombre de partitions possibles B_n , appelé nombre de Bell, est trop grand ; on ne peut pas explorer toutes les possibilités :

$$B_n = \frac{1}{e} \sum_{K \geq 1} \frac{K^n}{K!} \qquad B_{50} \geq 10^{48}$$



On va utiliser des algorithmes itératifs qui visent à explorer un sous ensemble de partitions dans lequel on espère que se trouve la partition optimale

Différents algorithmes itératifs existent dont les plus courants :

- les algorithmes agglomératifs ou divisifs : la classification hiérarchique
- les algorithmes par partitionnement : *e.g.* les K -moyennes
- les algorithmes probabilistes : les modèles de mélange

Différents algorithmes itératifs existent dont les plus courants :

- les algorithmes agglomératifs ou divisifs : **la classification hiérarchique**
- les algorithmes par partitionnement : *e.g.* **les K -moyennes**
- les algorithmes probabilistes : les modèles de mélange



CLUSTERING HIÉRARCHIQUE

■ Principe



Le clustering hiérarchique est un algorithme itératif qui propose une partition des données $\{x_1, \dots, x_n\}$ pour toute taille $k \in \{1, \dots, n\}$ possible de partition. Cet algorithme fonctionne par récurrence : chaque nouvelle partition est obtenue à partir de l'ancienne partition.

Deux stratégies

- **Clustering agglomératif** : initialement, chaque observation forme un cluster de taille 1. À chaque itération de l'algorithme, on trouve les deux clusters les plus proches, et on les agglomère en un seul cluster, et ce jusqu'à ne plus avoir qu'un unique cluster contenant les n observations.
- **Clustering divisif** : initialement, toutes les observations sont dans un même cluster de taille n . À chaque itération, on sépare un cluster en deux jusqu'à ce que chaque cluster ne contienne plus qu'une seule observation.

Par la suite, on s'intéresse au **clustering agglomératif** aussi appelé **classification ascendante hiérarchique** (CAH)

Question Comment mesurer la distance entre deux clusters ?

■ Distance entre deux clusters

Soit C_k, C_ℓ deux clusters

Exemples de distance/dissimilarité entre C_k et C_ℓ

- **lien simple** : $d(C_k, C_\ell) = \min_{(x,y) \in C_k \times C_\ell} d(x, y)$

C_k et C_ℓ sont agglomérés si deux de leurs éléments sont proches

- **lien complet** : $d(C_k, C_\ell) = \max_{(x,y) \in C_k \times C_\ell} d(x, y)$

C_k et C_ℓ sont agglomérés si tous leurs éléments sont proches.

- **lien moyen** : $d(C_k, C_\ell) = \frac{1}{|C_k|} \frac{1}{|C_\ell|} \sum_{x \in C_k} \sum_{y \in C_\ell} d(x, y)$

C_k et C_ℓ sont agglomérés si la distance moyenne entre un élément de C_k et un élément de C_ℓ est faible.

- **lien centroïdal** : $d(C_k, C_\ell) = d(\mu_k, \mu_\ell)$

C_k et C_ℓ sont agglomérés si la distance entre leurs centroïdes est faible

Remarque Ces distances s'attachent à garantir la séparabilité des clusters. Ce ne sont pas forcément des distances au sens mathématique. Par exemple, pour le lien complet $d(C_k, C_k) \neq 0$ si $|C| > 1$.

■ Distance entre deux clusters

Soit C_k, C_ℓ deux clusters

Exemples de distance/dissimilarité entre C_k et C_ℓ

➤ **distance de Ward** :
$$d(C_k, C_\ell) = \frac{|C_k| |C_\ell|}{|C_k| + |C_\ell|} \|\mu_k - \mu_\ell\|^2$$

Proposition

$K \in \{1, \dots, n\}$

La distance de Ward $d(C_k, C_\ell)$ correspond à la perte d'inertie inter-classes (de manière équivalente, au gain de variance intra-classe) lorsque l'on fusionne les classes C_k et C_ℓ pour passer de K à $K - 1$ classes


Ainsi, C_k et C_ℓ sont agglomérés si la fusion de ces deux clusters minimise la variance intra-classe de la nouvelle partition

Remarque La distance de Ward maximise aussi l'homogénéité des clusters

Remarque La distance de Ward prend en compte les effectifs des groupes : création de groupe équilibrés

■ Dendrogramme

Le résultat d'un clustering hiérarchique (agglomératif ou divisif) peut se visualiser sous la forme d'un **dendrogramme**



Tirée de l'ouvrage *Introduction au Machine Learning* de Chloé-Agathe Azencott

Remarque La longueur d'une branche de l'arbre est proportionnelle à la distance entre les deux clusters qu'elle connecte

■ Choix du nombre de clusters



Le clustering hiérarchique a l'avantage de ne pas requérir de définir à l'avance le nombre de clusters : cela permet d'explorer toutes les possibilités le long du dendrogramme. Cependant, il faut généralement prendre cette décision à un moment.

Il y a différentes manières de choisir le nombre de clusters :

- On arrête de fusionner des clusters dès que la distance minimale entre les clusters dépasse un certain seuil $r \in \mathbb{R}^*$. Ce seuil peut-être choisi arbitrairement ou égal à $\max_{(x,y) \in \{x_1, \dots, x_n\}} \alpha d(x, y)$ avec $\alpha < 1$.
On peut aussi faire cela visuellement en coupant le dendrogramme avant qu'une branche ne soit trop grande
- On peut évaluer les différentes partitions trouvées, c'est-à-dire les différents nœuds du dendrogramme, à l'aide d'une mesure de performance, e.g. le coefficient de silhouette, et choisir la partition avec la meilleure performance

La complexité algorithmique du clustering hiérarchique est élevée : à chaque itération, pour décider quels clusters regrouper, il faut calculer les distances deux à deux entre toutes les paires possibles de $\{x_1, \dots, x_n\}$: $O(dn^2)$ opérations





LES *K*-MOYENNES



Plutôt que d'explorer toutes les tailles de partition possibles il peut être préférable de se fixer un nombre K de clusters au préalable, ce qui permet de réduire les temps de calculs.

Objectif

Pour K fixé, trouver la partition de taille K des données $\{x_1, \dots, x_n\}$ qui minimise l'inertie intra-classes :

$$C^* = \arg \min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2$$



Problème d'optimisation trop long à résoudre



Utiliser une heuristique : *l'algorithme de Lloyd*

- 1 Choisir K observations $\mu_1, \dots, \mu_K$ aléatoirement dans l'espace pour servir de centroïdes initiaux. (On peut aussi les choisir de manière à les disperser au maximum parmi les données).

- 2 Affecter chaque observation x_i au centroïde dont elle est le plus proche :

$$k(x_i) = \arg \min_{k=1, \dots, K} \|x_i - \mu_k\|^2$$

Cela revient à regarder dans quelle cellule du diagramme de Voronoï induit par $\mu_1, \dots, \mu_K$ le point x_i se trouve

- 3 Recalculer les centroïdes de chaque cluster : $\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$
- 4 Répéter les opérations 2–3 jusqu'à convergence, c'est-à-dire jusqu'à ce que les affectations ne changent plus

Voir [cette animation](#)


■ Algorithme de Lloyd - variante



■ Algorithme de Lloyd - variante




Données



■ Algorithme de Lloyd - variante




Choix des centroïdes μ_1, μ_2, μ_3 (nombre de clusters $K = 3$)
problème dans cette illustration : les centroïdes de départ ne correspondent pas à des données



■ Algorithme de Lloyd - variante




Affectation des données au centroïde le plus proche



■ Algorithme de Lloyd - variante




Recalcul des centroïdes



■ Algorithme de Lloyd - variante




Affectation des données au centroïde le plus proche



■ Algorithme de Lloyd - variante




Recalcul des centroïdes



■ Algorithme de Lloyd - variante



Affectation des données au centroïde le plus proche : pas de changement



Proposition

L'inertie intra-classes

$$\sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2$$

diminue à chaque itération de l'algorithme

voir preuve du lemme 22.1 de l'ouvrage [*Understanding Machine Learning: From Theory to Algorithms*](#)



Il est donc possible de tomber dans un minimum local



Afin d'améliorer les performances de l'algorithme des K -moyennes, il est souvent recommandé de répéter la procédure plusieurs fois avec différentes initialisations aléatoires des centroïdes

■ Choix de K


Le nombre de cluster K est un hyperparamètre de l'algorithme des K -moyennes à choisir. Ce choix peut-être fait en minimisant un critère, comme l'inertie intra-classe



l'inertie intra-classe va forcément diminuer plus K augmente, pour autant, on ne veut pas choisir la partition avec n clusters



Pour K petit, on observe une décroissante forte de l'inertie intra-classes puis cette décroissante s'atténue au niveau d'un coude, là où l'on observe un changement de pente. On peut donc choisir K au niveau du coude ; c'est le *critère du coude*



Le coude se situe autour de $K = 4$

À chaque itération, on calcule Kn distances en d dimensions. Pour t itérations, la complexité algorithmique de l'algorithme de Lloyd est donc en $O(ndKt)$.

Puisque K et t sont négligeables devant n , cet algorithme est donc linéaire en le nombre d'observations, par opposition au clustering hiérarchique dont le coût est quadratique en n (si l'on stocke les distances entre les observations). C'est expliqué par le fait que le calcul des distances d'une observation x_i aux $n - 1$ autres points du jeu de données a été remplacé par un calcul de sa distance à K centroïdes

Il est possible de combiner K -moyennes et clustering hiérarchique : on fait un K -moyennes avec $K = \lambda n$, une fraction importante des données, et ensuite on fait un clustering hiérarchique ascendant sur le résultat de l'algorithme des K -moyennes

L'algorithme des K -moyennes est sensible aux données aberrantes. Si une observation x_i est très éloignée des autres observations, elle se retrouvera seule dans un cluster, tandis que le reste des données sera partitionné en $K - 1$ clusters.



Cependant, cela permet d'utiliser l'algorithme des K -moyenne pour détecter les observations aberrantes : ce sont celles qui sont seules dans un cluster.

Le partitionnement en K -médoides est une méthode de partitionnement plus robuste vis-à-vis des données aberrantes. Le médoïde d'une classe est défini comme le point de la classe dont la dissimilarité moyenne avec tous les autres points de la classe est minimale, c'est-à-dire qu'il s'agit de l'observation la plus centrale de la classe.

Forme des clusters

Les centroïdes des clusters trouvés par l'algorithme des K -moyennes forment un diagramme de Voronoï. Les clusters sont donc convexes.

Partitionnement en 3 clusters
par K -moyennes



Tirée de l'ouvrage *Introduction au Machine Learning* de Chloé-Agathe Azencott



On peut utiliser l'astuce du noyau à l'algorithme de Lloyd pour obtenir des clusters non convexes (voir section 12.4.3 d' *Introduction au Machine Learning* de Chloé-Agathe Azencott)

Three vertical gray bars are positioned in the background, one on the left, one in the center, and one on the right. They are slightly wider at the top and bottom, giving them a stylized appearance.

ÉVALUATION D'UN CLUSTERING

Le clustering n'étant pas supervisé, il nous faut mettre au point des critères d'évaluation qui ne dépendent pas d'une vérité terrain (c'est-à-dire d'étiquettes connues). La tâche est plus délicate que dans le cadre de l'apprentissage supervisé, dans lequel le but à atteindre est beaucoup plus clair. Voici quelques manières de vérifier la qualité d'un clustering

Stabilités des clusters

On veut que le clustering soit robuste : collecter plus de données, perturber ou supprimer quelques observations ou initialiser différemment l'algorithme de partitionnement ne devrait pas changer complètement les conclusions.

Évaluation externe

- **A posteriori**, un expert peut évaluer la qualité du clustering : les groupes sont-ils cohérents, ont-il du sens ?
- **A priori**, si on dispose d'un jeu de données (partiellement) étiquetées, on peut vérifier si on retrouve les classes avec le clustering ([indice de Rand](#))

Évaluation interne

- On peut mesurer certaines statistiques comme l'indice de Davies-Bouldin global ou le coefficient de silhouette global enfin de se rendre compte de la qualité du partitionnement en terme d'homogénéité des clusters et de séparabilité entre les clusters



C.A. Azencot Introduction au Machine Learning, *Dunod*,
ISBN : 978-2-10-084143-1



S. Shalev-Shwartz and S. Ben-David, Understanding Machine Learning: From Theory to Algorithms, *Cambridge University Press*, DOI :
10.1017/CBO9781107298019, 2014



T. Hastie, R. Tibshirani, and J. Friedman. The Elements of Statistical Learning, *Springer New York*, DOI : 10.1007/978-0-387-84858-7, 2009