

Théorie de l'Apprentissage Statistique

MIASHS M1 - Semestre 2

Table des matières

1. Introduction	1
2. Prédicteurs optimaux de Bayes	3
3. Consistance et convergence	9
4. Inégalités de concentration et Généralisation	11
5. Fonctions de perte calibrées	32
6. Bibliographie	45

1. Introduction

On se place dans le cadre de l'apprentissage supervisé binaire (même si on mentionnera rapidement la régression). On dispose d'un espace d'entrée $\mathcal{X}$ (typiquement $\mathbb{R}^d$) et d'un espace de sortie $\mathcal{Y} = \{0, 1\}$. Les données sont des couples $(X, Y) \in \mathcal{X} \times \mathcal{Y}$ tirés i.i.d. selon une distribution inconnue $P_{X,Y}$.

On cherche à apprendre un **classifieur** $h : \mathcal{X} \rightarrow \mathcal{Y}$ qui prédit correctement l'étiquette Y à partir de l'observation X . La qualité d'un classifieur est mesurée par son **risque théorique** :

$$L(h) = E[\ell(h(X), Y)]$$

où $\ell : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_+$ est une fonction de perte. Pour la perte 0-1, $\ell(y, \hat{y}) = \mathbb{1}_{\{y \neq \hat{y}\}}$, le risque vaut simplement $P(h(X) \neq Y)$.

La distribution $P_{X,Y}$ étant inconnue, on ne peut pas calculer $L(h)$ directement. On dispose seulement d'un échantillon fini $\mathcal{S}_n = \{(X_i, Y_i)\}_{i=1}^n$ i.i.d., à partir duquel on substitue au risque théorique le **risque empirique** :

$$R_n(h) = \frac{1}{n} \sum_{i=1}^n \ell(h(X_i), Y_i)$$

Minimiser $R_n(h)$ sans contrainte sur h conduit au surapprentissage : un classifieur qui mémorise $\mathcal{S}_n$ obtient $R_n(h) = 0$ mais ne généralise pas. On restreint donc la recherche à une **classe de fonctions** $\mathcal{H} \subset \mathcal{Y}^{\mathcal{X}}$ et on résout le **principe de minimisation du risque empirique** (ERM) :

$$\hat{h}_n = \arg \min_{h \in \mathcal{H}} R_n(h)$$

Ce cours étudie les fondements théoriques de cette démarche selon trois axes : le **prédicteur de Bayes** (classifieur optimal sous connaissance parfaite de $P_{X,Y}$), la **consistance et les bornes de généralisation** (dans quelle mesure $\hat{h}_n$ approche-t-il ce classifieur optimal quand $n \rightarrow +\infty$), et la **calibration des fonctions de perte** (comment substituer à la perte 0-1, non optimisable, une perte proxy convexe sans perdre les garanties théoriques).

2. Prédicteurs optimaux de Bayes

2.1. Le cadre de la décision Bayésienne

En apprentissage supervisé, nous cherchons à minimiser le risque théorique $L(h) = E[\ell(h(X), Y)]$. Le prédicteur qui atteint la valeur minimale de ce risque est appelé **prédicteur de Bayes**, noté h^* .

Théorème 1.1 (Classifieur de Bayes)

Pour la perte 0-1 ($\ell(y, \hat{y}) = \mathbb{1}_{\{y \neq \hat{y}\}}$), le classifieur optimal en x est donné par :

$$h^*(x) = \begin{cases} 1 & \text{si } \eta(x) \geq \frac{1}{2} \\ 0 & \text{sinon} \end{cases}$$

où $\eta(x) = P(Y = 1 \mid X = x)$ est la probabilité a posteriori.

Démonstration :

Soit $h : \mathcal{X} \rightarrow \{0, 1\}$ un classifieur mesurable quelconque. On cherche à minimiser le risque :

$$R(h) = E[\mathbb{1}_{\{h(X) \neq Y\}}] = P(h(X) \neq Y)$$

Étape 1 — Décomposition par conditionnement.

Par la loi des espérances totales :

$$R(h) = E_X \left[E[\mathbb{1}_{\{h(X) \neq Y\}} \mid X] \right] = E_X[r(h(X), X)]$$

où l'on a posé le risque conditionnel $r(\hat{y}, x) = P(\hat{y} \neq Y \mid X = x)$ pour une décision $h(x) \in \{0, 1\}$.

Puisque $R(h) = E_X[r(h(X), X)]$ et que $r(\cdot, x) \geq 0$ pour tout x , minimiser $R(h)$ revient à minimiser $r(h(x), x)$ **pour presque tout** x (au sens de la loi de X). On peut donc raisonner point par point.

Étape 2 — Calcul explicite du risque conditionnel.

Pour x fixé, la variable $Y \mid X = x$ est de Bernoulli de paramètre $\eta(x)$. On calcule $r(a, x)$ pour chaque décision possible :

- Si $a = 1$:

$$r(1, x) = P(Y \neq 1 \mid X = x) = P(Y = 0 \mid X = x) = 1 - \eta(x)$$

- Si $a = 0$:

$$r(0, x) = P(Y \neq 0 \mid X = x) = P(Y = 1 \mid X = x) = \eta(x)$$

Étape 3 — Minimisation ponctuelle.

La décision optimale en x est :

$$h^*(x) = \arg \min_{a \in \{0,1\}} r(a, x)$$

On choisit $a = 1$ si et seulement si $r(1, x) \leq r(0, x)$, c'est-à-dire :

$$1 - \eta(x) \leq \eta(x) \Leftrightarrow 1 \leq 2\eta(x) \Leftrightarrow \eta(x) \geq \frac{1}{2}$$

D'où :

$$h^*(x) = \begin{cases} 1 & \text{si } \eta(x) \geq \frac{1}{2} \\ 0 & \text{sinon} \end{cases}$$

Étape 4 — Optimalité globale.

Montrons que h^* minimise bien $R(h)$ parmi **tous** les classifieurs. Soit h un classifieur quelconque. On a :

$$R(h) - R(h^*) = E_X[r(h(X), X) - r(h^*(X), X)]$$

Par construction de h^* , on a $r(h^*(x), x) \leq r(a, x)$ pour tout $a \in \{0, 1\}$ et pour tout x . Donc :

$$r(h(x), x) - r(h^*(x), x) \geq 0 \quad \forall x$$

Par positivité de l'espérance :

$$R(h) - R(h^*) = E_X \left[\underbrace{r(h(X), X) - r(h^*(X), X)}_{\geq 0} \right] \geq 0$$

Ainsi $R(h^*) \leq R(h)$ pour tout classifieur h mesurable. ■

Remarque : Le risque de Bayes (risque minimal atteignable) vaut :

$$R^* = R(h^*) = E_X[\min(\eta(X), 1 - \eta(X))]$$

On vérifie que $R^* = 0$ si et seulement si $\eta(x) \in \{0, 1\}$ p.s., c'est-à-dire quand le problème est séparable (la règle de décision est déterministe et sans erreur).

2.2. Cas de la régression

Théorème 1.2 (Prédicteurs optimaux en régression)

1. **Erreur quadratique (L_2) :** $\ell(y, \hat{y}) = (y - \hat{y})^2$. Le prédicteur optimal est la **moyenne conditionnelle** :

$$h^*(x) = E[Y \mid X = x]$$

2. **Erreur absolue (L_1)** : $\ell(y, \hat{y}) = |y - \hat{y}|$. Le prédicteur optimal est la **médiane conditionnelle** de Y sachant $X = x$.

2.2.1. Preuve pour la perte L_2

Soit $h : \mathcal{X} \rightarrow \mathbb{R}$ un prédicteur mesurable. On cherche à minimiser :

$$R(h) = E[(Y - h(X))^2]$$

Étape 1 — Conditionnement.

Par la loi des espérances totales :

$$R(h) = E_X[E[(Y - h(X))^2 \mid X]]$$

Comme pour la classification, minimiser $R(h)$ revient à minimiser $E[(Y - h(x))^2 \mid X = x]$ pour presque tout x . On pose $m(x) = E[Y \mid X = x]$ et on fixe x .

Étape 2 — Décomposition biais-variance conditionnelle.

Pour toute constante $c \in \mathbb{R}$, on écrit $Y - c = (Y - m(x)) + (m(x) - c)$, d'où :

$$\begin{aligned} E[(Y - c)^2 \mid X = x] &= E[(Y - m(x) + m(x) - c)^2 \mid X = x] \\ &= E[(Y - m(x))^2 \mid X = x] + 2(m(x) - c) \underbrace{E[Y - m(x) \mid X = x]}_{=0} \\ &\quad + (m(x) - c)^2 \end{aligned}$$

Le terme croisé est nul car $E[Y - m(x) \mid X = x] = E[Y \mid X = x] - m(x) = 0$. On obtient donc :

$$E[(Y - c)^2 \mid X = x] = \underbrace{E[(Y - m(x))^2 \mid X = x]}_{\text{ne dépend pas de } c} + \underbrace{(m(x) - c)^2}_{\geq 0}$$

Étape 3 — Minimisation.

Le second terme $(m(x) - c)^2 \geq 0$ est minimisé (et annulé) uniquement pour $c = m(x)$. Donc :

$$h^*(x) = \arg \min_{c \in \mathbb{R}} E[(Y - c)^2 \mid X = x] = m(x) = E[Y \mid X = x]$$

Étape 4 — Optimalité globale.

Pour tout prédicteur h , on repart de la décomposition de l'étape 2 appliquée avec $c = h(x)$:

$$E[(Y - h(x))^2 \mid X = x] = E[(Y - m(x))^2 \mid X = x] + (m(x) - h(x))^2$$

En prenant l'espérance par rapport à X :

$$\begin{aligned} R(h) &= E_X[E[(Y - h(X))^2 \mid X]] \\ &= E_X[E[(Y - m(X))^2 \mid X]] + E_X[(m(X) - h(X))^2] \\ &= R(h^*) + E_X[(m(X) - h(X))^2] \end{aligned}$$

Donc :

$$R(h) - R(h^*) = E_X[(m(X) - h(X))^2] \geq 0$$

avec égalité si et seulement si $h(x) = m(x)$ pour presque tout x (au sens de la loi de X). ■

2.2.2. Preuve pour la perte L_1

Soit $h : \mathcal{X} \rightarrow \mathbb{R}$ un prédicteur mesurable. On cherche à minimiser :

$$R(h) = E[|Y - h(X)|]$$

Par le même argument de conditionnement, on minimise pour presque tout x :

$$g(c) = E[|Y - c| \mid X = x]$$

Étape 1 — Dérivation de g .

On suppose que $Y \mid X = x$ admet une densité conditionnelle $f_{Y|x}$. Alors :

$$\begin{aligned} g(c) &= \int_{-\infty}^{+\infty} |y - c| f_{Y|x}(y) \, dy \\ &= \int_{-\infty}^c (c - y) f_{Y|x}(y) \, dy + \int_c^{+\infty} (y - c) f_{Y|x}(y) \, dy \end{aligned}$$

On dérive sous le signe intégrale (théorème de Leibniz) :

$$\begin{aligned} g'(c) &= \int_{-\infty}^c f_{Y|x}(y) \, dy - \int_c^{+\infty} f_{Y|x}(y) \, dy \\ &= F_{Y|x}(c) - (1 - F_{Y|x}(c)) = 2F_{Y|x}(c) - 1 \end{aligned}$$

Étape 2 — Condition d'optimalité.

$g'(c) = 0$ donne $F_{Y|x}(c) = \frac{1}{2}$, soit $c = \text{Med}(Y \mid X = x)$, la médiane conditionnelle.

On vérifie qu'il s'agit bien d'un minimum : $g''(c) = 2f_{Y|x}(c) \geq 0$, donc g est convexe et la médiane est bien un minimiseur global.

3. Consistance et convergence

3.1. Consistance

3.1.1. Définition

Définition 1.2 (Consistance)

Soit $(h_n)_{n \geq 1}$ une suite de classifieurs appris sur un échantillon $\mathcal{S}_n = \{(X_i, Y_i)\}_{i=1}^n$ i.i.d. de loi $P_{X,Y}$. On dit que (h_n) est :

- **consistant en probabilité** si :

$$\forall \varepsilon > 0, \quad P(R(h_n) - R^* > \varepsilon) \xrightarrow{n \rightarrow +\infty} 0$$

- **consistant en moyenne quadratique** si :

$$E[(R(h_n) - R^*)^2] \xrightarrow{n \rightarrow +\infty} 0$$

- **fortement consistant** si :

$$P\left(\lim_{n \rightarrow +\infty} R(h_n) = R^*\right) = 1$$

où $R^* = R(h^*) = E_X[\min(\eta(X), 1 - \eta(X))]$ est le risque de Bayes.

Les trois notions sont de force croissante : consistance p.s. $\Rightarrow$ consistance en probabilité, et consistance en moyenne quadratique $\Rightarrow$ consistance en probabilité.

3.1.2. Pourquoi cette notion est-elle centrale ?

Le risque $R(h_n)$ se décompose naturellement en deux termes :

$$R(h_n) - R^* = \underbrace{R(h_n) - \inf_{h \in \mathcal{H}} R(h)}_{\text{terme d'estimation}} + \underbrace{\inf_{h \in \mathcal{H}} R(h) - R^*}_{\text{terme d'approximation}}$$

- Le **terme d'approximation** (ou biais) mesure la capacité de la classe $\mathcal{H}$ à approcher le classifieur de Bayes. Il est nul si $h^* \in \mathcal{H}$, et ne dépend pas des données.
- Le **terme d'estimation** mesure l'écart entre le meilleur classifieur théorique dans $\mathcal{H}$ et celui effectivement appris sur $\mathcal{S}_n$. Il tend vers 0 quand $n \rightarrow +\infty$ sous des conditions de régularité sur $\mathcal{H}$.

La consistance requiert que la somme de ces deux termes tende vers 0.

3.1.3. Consistance universelle

Définition 1.3 (Consistance universelle)

Un algorithme est dit **universellement consistant** si (h_n) est consistant pour **toute** distribution $P_{X,Y}$ sur $\mathcal{X} \times \{0,1\}$, sans hypothèse sur $\eta(x)$.

C'est une propriété bien plus forte : elle garantit que l'algorithme converge vers le risque de Bayes quelle que soit la structure du problème. Le résultat fondamental de Stone (1977) établit que les k -plus proches voisins avec $k = k(n) \rightarrow +\infty$ et $\frac{k(n)}{n} \rightarrow 0$ sont universellement consistants.

3.2. Consistance du classifieur k-NN

Théorème 2.1 (Consistance universelle de Stone, 1977)

Soit $(X_i, Y_i)_{i=1}^n$ un échantillon i.i.d. de loi $P_{X,Y}$ sur $\mathbb{R}^d \times \{0, 1\}$.
Si le paramètre $k = k(n)$ vérifie :

$$k(n) \xrightarrow{n \rightarrow +\infty} +\infty \quad \text{et} \quad \frac{k(n)}{n} \xrightarrow{n \rightarrow +\infty} 0$$

alors le classifieur k -NN est universellement consistant :

$$\forall P_{X,Y}, \quad E[R(h_n^{k\text{-NN}})] \xrightarrow{n \rightarrow +\infty} R^*$$

Intuition de la preuve : $k \rightarrow \infty$ permet de réduire la variance de l'estimation locale de $\eta(x)$ par la loi des grands nombres. $\frac{k}{n} \rightarrow 0$ garantit que les voisins sont de plus en plus proches de x (réduction du biais), capturant ainsi la valeur locale de la fonction de régression.

Exercice 2.1 Pourquoi ne peut-on pas prendre k fixe (ex: $k = 1$) pour assurer la consistance ? **Indice :** Calculez l'erreur de 1-NN quand $n \rightarrow \infty$ en fonction de l'erreur de Bayes L^* .

4. Inégalités de concentration et Généralisation

4.1. Inégalités fondamentales

L'apprentissage repose sur notre capacité à borner l'écart entre risque empirique $R_n(h)$ et risque théorique $R(h)$. Les inégalités de concentration quantifient la probabilité qu'une variable aléatoire s'écarte de son espérance.

4.1.1. Inégalité de Markov

Théorème (Inégalité de Markov)

Soit Z une variable aléatoire réelle positive ($Z \geq 0$ p.s.) et $t > 0$. Alors :

$$P(Z \geq t) \leq \frac{E[Z]}{t}$$

Démonstration :

On minore Z par la variable aléatoire $t\mathbb{1}_{Z \geq t}$:

$$Z \geq t\mathbb{1}_{Z \geq t} \quad \text{p.s.}$$

Cette inégalité se vérifie en distinguant deux événements :

- Sur l'événement $\{Z \geq t\}$: l'indicatrice vaut 1, donc $t\mathbb{1}_{Z \geq t} = t \leq Z$, l'inégalité tient.
- Sur l'événement $\{Z < t\}$: l'indicatrice vaut 0, donc $t\mathbb{1}_{Z \geq t} = 0 \leq Z$, l'inégalité tient par positivité de Z .

En prenant l'espérance, qui préserve l'inégalité :

$$E[Z] \geq E[t\mathbb{1}_{Z \geq t}] = tE[\mathbb{1}_{Z \geq t}] = tP(Z \geq t)$$

On divise par $t > 0$:

$$P(Z \geq t) \leq \frac{E[Z]}{t}$$

■

Remarque : La positivité de Z est essentielle. Pour une variable signée, on peut appliquer Markov à $|Z|$ ou $(Z - E[Z])^2$.

4.1.2. Inégalité de Bienaymé-Tchebychev

Théorème (Inégalité de Bienaymé-Tchebychev)

Soit Z une variable aléatoire réelle de variance finie. Pour tout $\varepsilon > 0$:

$$P(|Z - E[Z]| \geq \varepsilon) \leq \frac{\text{Var}(Z)}{\varepsilon^2}$$

Démonstration :

On applique l'inégalité de Markov à la variable aléatoire positive $(Z - E[Z])^2$ avec le seuil $t = \varepsilon^2$:

$$P((Z - E[Z])^2 \geq \varepsilon^2) \leq \frac{E[(Z - E[Z])^2]}{\varepsilon^2} = \frac{\text{Var}(Z)}{\varepsilon^2}$$

Or les événements $(Z - E[Z])^2 \geq \varepsilon^2$ et $|Z - E[Z]| \geq \varepsilon$ sont identiques, d'où :

$$P(|Z - E[Z]| \geq \varepsilon) \leq \frac{\text{Var}(Z)}{\varepsilon^2}$$

■

4.1.3. Application : consistance en probabilité de la moyenne empirique

Ces deux inégalités suffisent à établir la consistance de la moyenne empirique, qui est le prototype de la convergence du risque empirique vers le risque théorique.

Soit $Z_1, \dots, Z_n$ i.i.d. de moyenne $\mu = E[Z_1]$ et de variance $\sigma^2 = \text{Var}(Z_1) < +\infty$. On pose $\bar{Z}_n = \frac{1}{n} \sum_{i=1}^n Z_i$.

Par linéarité de l'espérance : $E[\bar{Z}_n] = \mu$.

Par indépendance : $\text{Var}(\bar{Z}_n) = \frac{\sigma^2}{n}$.

Par Bienaymé-Tchebychev :

$$P(|\bar{Z}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow +\infty} 0$$

Donc $\bar{Z}_n \xrightarrow{P} \mu$. En particulier, le risque empirique $R_n(h) = \frac{1}{n} \sum_{i=1}^n \ell(h(X_i), Y_i)$ vérifie pour tout h fixé :

$$P(|R_n(h) - R(h)| \geq \varepsilon) \leq \frac{R(h)(1 - R(h))}{(n\varepsilon^2)} \leq \frac{1}{4n\varepsilon^2}$$

où on a utilisé que $\text{Var}(\mathbb{1}_{h(X) \neq Y}) = R(h)(1 - R(h)) \leq \frac{1}{4}$.

Limitation : Cette borne est valable pour h fixé. Elle ne contrôle pas l'écart $\sup_{h \in \mathcal{H}} |R_n(h) - R(h)|$ sur une classe entière de classifieurs, ce qui est pourtant ce dont on a besoin en apprentissage puisqu'on ne prend pas un h arbitraire mais qu'on doit choisir parmi $\mathcal{H}$. C'est l'objet de la théorie de Vapnik-Chervonenkis.

4.2. Majoration de l'erreur de généralisation : cas fini

On suppose ici $|\mathcal{H}| < +\infty$. C'est le cadre le plus simple, mais il illustre déjà les deux ingrédients fondamentaux : concentration et union bound.

4.2.1. Cas séparable

On dit que $\mathcal{H}$ est **réalisable** (ou que le problème est **séparable**) s'il existe $h^* \in \mathcal{H}$ tel que $R(h^*) = 0$, c'est-à-dire que le classifieur de Bayes appartient à $\mathcal{H}$.

Dans ce cas, on n'a pas besoin d'inégalités de concentration : un argument purement combinatoire suffit.

Théorème 3.1 (Cas séparable, $|\mathcal{H}| < +\infty$)

On suppose qu'il existe $h^* \in \mathcal{H}$ tel que $R(h^*) = 0$ (hypothèse de réalisabilité). Soit $\hat{h}_{\mathcal{S}_n}$ le minimiseur du risque empirique sur un échantillon $\mathcal{S}_n = \{(X_i, Y_i)\}_{i=1}^n$ i.i.d. de loi $P_{X,Y}$:

$$\hat{h}_{\mathcal{S}_n} = \arg \min_{h \in \mathcal{H}} R_{\mathcal{S}_n}(h)$$

Alors pour tout $\varepsilon > 0$ et tout $\delta \in (0, 1)$:

$$P^n(R(\hat{h}_{\mathcal{S}_n}) > \varepsilon) \leq |\mathcal{H}| e^{-n\varepsilon}$$

où $P^n = P_{X,Y}^{\otimes n}$. En particulier, pour que cette probabilité soit inférieure à δ , il suffit que :

$$n \geq \frac{\log\left(\frac{|\mathcal{H}|}{\delta}\right)}{\varepsilon}$$

Démonstration :

Étape 1 — Réduction au cas des échantillons trompeurs.

Par l'hypothèse de réalisabilité, h^* commet zéro erreur sur tout échantillon, donc $R_{\mathcal{S}_n}(h^*) = 0$ p.s. Puisque $\hat{h}_{\mathcal{S}_n}$ minimise le risque empirique, on a nécessairement $R_{\mathcal{S}_n}(\hat{h}_{\mathcal{S}_n}) = 0$.

Ainsi, si $R(\hat{h}_{\mathcal{S}_n}) > \varepsilon$, c'est qu'un classifieur de risque réel supérieur à ε a réussi à obtenir un risque empirique nul — il a « trompé » l'algorithme. On formalise cela en introduisant :

- L'ensemble des **mauvais classifieurs** :

$$\mathcal{H}_{\text{bad}} = \{h \in \mathcal{H} : R(h) > \varepsilon\}$$

- L'ensemble des **échantillons trompeurs** :

$$\mathcal{M} = \{\mathcal{S}_n : \exists h \in \mathcal{H}_{\text{bad}}, R_{\mathcal{S}_n}(h) = 0\}$$

c'est-à-dire l'ensemble des échantillons sur lesquels au moins un mauvais classifieur semble parfait.

Puisque $R_{\mathcal{S}_n}(\hat{h}_{\mathcal{S}_n}) = 0$, l'événement $\{R(\hat{h}_{\mathcal{S}_n}) > \varepsilon\}$ implique que $\hat{h}_{\mathcal{S}_n} \in \mathcal{H}_{\text{bad}}$, donc que $\mathcal{S}_n \in \mathcal{M}$. On a l'inclusion :

$$\{\mathcal{S}_n : R(\hat{h}_{\mathcal{S}_n}) > \varepsilon\} \subset \mathcal{M}$$

et donc :

$$P^n(\{\mathcal{S}_n : R(\hat{h}_{\mathcal{S}_n}) > \varepsilon\}) \leq P^n(\mathcal{M})$$

Étape 2 — Union bound.

On réécrit $\mathcal{M}$ comme une union :

$$\mathcal{M} = \bigcup_{h \in \mathcal{H}_{\text{bad}}} \{\mathcal{S}_n : R_{\mathcal{S}_n}(h) = 0\}$$

Par l'*union bound* ($P(A \cup B) \leq P(A) + P(B)$, généralisé) :

$$\begin{aligned} P^n(\mathcal{M}) &= P^n\left(\bigcup_{h \in \mathcal{H}_{\text{bad}}} \{\mathcal{S}_n : R_{\mathcal{S}_n}(h) = 0\}\right) \\ &\leq \sum_{h \in \mathcal{H}_{\text{bad}}} P^n(\{\mathcal{S}_n : R_{\mathcal{S}_n}(h) = 0\}) \end{aligned}$$

Étape 3 — Borne sur chaque terme.

Soit $h \in \mathcal{H}_{\text{bad}}$, donc $R(h) > \varepsilon$. Les observations étant i.i.d., la probabilité que h ne commette aucune erreur sur S est :

$$\begin{aligned} P^n(R_{\mathcal{S}_n}(h) = 0) &= P^n(\forall i \in \{1, \dots, n\}, h(X_i) = Y_i) \\ &= \prod_{i=1}^n P(h(X_i) = Y_i) = (1 - R(h))^n \end{aligned}$$

Puisque $R(h) > \varepsilon$ et en utilisant $1 - x \leq e^{-x}$ pour $x \in [0, 1]$:

$$(1 - R(h))^n < (1 - \varepsilon)^n \leq e^{-n\varepsilon}$$

Étape 4 — Conclusion.

En combinant les étapes 2 et 3 :

$$P^n(R(\hat{h}_{\mathcal{S}_n}) > \varepsilon) \leq \sum_{h \in \mathcal{H}_{\text{bad}}} e^{-n\varepsilon} \leq |\mathcal{H}_{\text{bad}}| \cdot e^{-n\varepsilon} \leq |\mathcal{H}| e^{-n\varepsilon}$$

En posant $\delta = |\mathcal{H}| e^{-n\varepsilon}$ et en résolvant pour n :

$$e^{-n\varepsilon} = \frac{\delta}{|\mathcal{H}|} \Rightarrow n = \frac{\log\left(\frac{|\mathcal{H}|}{\delta}\right)}{\varepsilon}$$

Donc, $R(\hat{h}_{\mathcal{S}_n}) > \varepsilon$, avec probabilité au plus δ si $n \geq \frac{\log\left(\frac{|\mathcal{H}|}{\delta}\right)}{\varepsilon}$. ■

Remarque : Le terme $\log|\mathcal{H}|$ est le coût de la recherche dans $\mathcal{H}$: plus la classe est grande, plus il faut de données pour garantir que le minimiseur empirique est bon. Ce coût est cependant seulement **logarithmique** en $|\mathcal{H}|$ — doubler la taille de $\mathcal{H}$ ne coûte qu'une observation supplémentaire (à ε et δ fixés). Notons cependant, que lorsqu'on fait de la sélection de paramètres, la taille de $\mathcal{H}$ croît **exponentiellement** avec le nombre de paramètres.

Corollaire (Cas séparable, $|\mathcal{H}| < +\infty$)

On suppose qu'il existe $h^* \in \mathcal{H}$ tel que $R(h^*) = 0$ (hypothèse de réalisabilité). Soit $\hat{h}_S$ le minimiseur du risque empirique sur un échantillon $\mathcal{S}_n = \{(X_i, Y_i)\}_{i=1}^n$ i.i.d. de loi $P_{X,Y}$:

$$\hat{h}_{\mathcal{S}_n} = \arg \min_{h \in \mathcal{H}} R_{\mathcal{S}_n}(h)$$

Alors, pour tout $\delta \in (0, 1)$, avec probabilité $1 - \delta$, l'inégalité suivante est satisfaite :

$$R(\hat{h}_{\mathcal{S}_n}) \leq \frac{\log\left(\frac{|\mathcal{H}|}{\delta}\right)}{n}$$

Démonstration :

Laissée en exercice.

4.2.2. Cas non séparable

Sans hypothèse de réalisabilité, $\hat{h}_S$ peut avoir un risque empirique non nul, et l'argument précédent s'effondre : il n'y a plus d'échantillons « trompeurs » au sens strict. On a besoin d'un outil de concentration quantifiant l'écart entre $R_S(h)$ et $R(h)$ pour un h quelconque.

4.2.2.1. Rappel : inégalité de Hoeffding

Théorème (Hoeffding, 1963)

Soit $Z_1, \dots, Z_n$ des variables aléatoires **indépendantes** avec $Z_i \in [a_i, b_i]$ p.s. Alors pour tout $t > 0$:

$$P\left(\frac{1}{n} \sum_{i=1}^n (Z_i - E[Z_i]) \geq t\right) \leq \exp\left(-\frac{2n^2 t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$$

En particulier, si $Z_i \in [0, 1]$ p.s. pour tout i (cas homogène) :

$$P\left(\frac{1}{n} \sum_{i=1}^n Z_i - E[Z_1] \geq t\right) \leq e^{-2nt^2}$$

et en appliquant l'inégalité aux deux queues :

$$P\left(\left|\frac{1}{n} \sum_{i=1}^n Z_i - E[Z_1]\right| \geq t\right) \leq 2e^{-2nt^2}$$

Application au risque empirique. Pour $h \in \mathcal{H}$ fixé, on pose $Z_i = \mathbb{1}_{h(X_i) \neq Y_i} \in [0, 1]$. Les Z_i sont i.i.d. sous $P^n = P_{X,Y}^{\otimes n}$, avec $E[Z_i] = R(h)$ et $\frac{1}{n} \sum_{i=1}^n Z_i = R_{\mathcal{S}_n}(h)$. Hoeffding donne alors :

$$P^n(|R_{\mathcal{S}_n}(h) - R(h)| \geq t) \leq 2e^{-2nt^2}$$

Cette borne vaut pour h **fixé** : elle ne contrôle pas l'écart $\sup_{h \in \mathcal{H}} |R_{\mathcal{S}_n}(h) - R(h)|$ sur toute la classe $\mathcal{H}$, ce dont on a besoin pour garantir que $\hat{h}_{\mathcal{S}_n}$ est bon.

4.2.2.2. Théorème de généralisation

Théorème 3.2 (Cas non séparable, $|\mathcal{H}| < +\infty$)

Soit $\mathcal{H}$ fini, $\mathcal{S}_n = \{(X_i, Y_i)\}_{i=1}^n$ i.i.d. de loi $P_{X,Y}$, et $\hat{h}_{\mathcal{S}_n} = \arg \min_{h \in \mathcal{H}} R_{\mathcal{S}_n}(h)$. Pour tout $\delta \in (0, 1)$, avec probabilité $1 - \delta$ sous $P^n = P_{X,Y}^{\otimes n}$, **simultanément** pour tout $h \in \mathcal{H}$:

$$|R(h) - R_{\mathcal{S}_n}(h)| \leq \sqrt{\frac{\log|\mathcal{H}| + \log\left(\frac{2}{\delta}\right)}{2n}}$$

En particulier, le risque réel de $\hat{h}_{\mathcal{S}_n}$ est borné par :

$$R(\hat{h}_{\mathcal{S}_n}) \leq R_{\mathcal{S}_n}(\hat{h}_{\mathcal{S}_n}) + \sqrt{\frac{\log|\mathcal{H}| + \log\left(\frac{2}{\delta}\right)}{2n}}$$

Démonstration :

Étape 1 — Concentration pour h fixé.

Pour tout $h \in \mathcal{H}$ fixé, l'application de Hoeffding aux variables i.i.d. $Z_i = \mathbb{1}_{h(X_i) \neq Y_i} \in [0, 1]$ donne :

$$P^n(|R_{\mathcal{S}_n}(h) - R(h)| \geq t) \leq 2e^{-2nt^2}$$

Étape 2 — Passage à l'uniforme par union bound.

On cherche à contrôler non pas un h fixé, mais le pire cas sur $\mathcal{H}$:

$$\begin{aligned} P^n\left(\left\{\mathcal{S}_n : \exists h \in \mathcal{H}, |R_{\mathcal{S}_n}(h) - R(h)| \geq t\right\}\right) \\ = P^n\left(\bigcup_{h \in \mathcal{H}} \left\{\mathcal{S}_n : |R_{\mathcal{S}_n}(h) - R(h)| \geq t\right\}\right) \end{aligned}$$

Par *union bound* et Hoeffding :

$$\begin{aligned} P^n\left(\left\{\mathcal{S}_n : \exists h \in \mathcal{H}, |R_{\mathcal{S}_n}(h) - R(h)| \geq t\right\}\right) \\ \leq \sum_{h \in \mathcal{H}} P^n\left(\left\{\mathcal{S}_n : |R_{\mathcal{S}_n}(h) - R(h)| \geq t\right\}\right) \\ \leq 2|\mathcal{H}| e^{-2nt^2} \end{aligned}$$

En passant au complémentaire : avec probabilité d'**au moins** $1 - 2|\mathcal{H}| e^{-2nt^2}$ sous P^n , on a simultanément pour tout $h \in \mathcal{H}$:

$$|R_{\mathcal{S}_n}(h) - R(h)| < t$$

Étape 3 — Calibration en δ .

On veut pouvoir calibrer/contrôler la probabilité d'échec via δ .
On pose :

$$\delta = 2|\mathcal{H}| e^{-2nt^2}$$

et on résout pour t :

$$\begin{aligned} e^{-2nt^2} &= \frac{\delta}{2|\mathcal{H}|} \Leftrightarrow 2nt^2 = \log\left(2\frac{|\mathcal{H}|}{\delta}\right) \\ \Leftrightarrow t &= \sqrt{\frac{\log\left(2\frac{|\mathcal{H}|}{\delta}\right)}{2n}} = \sqrt{\frac{\log|\mathcal{H}| + \log\left(\frac{2}{\delta}\right)}{2n}} \end{aligned}$$

Donc avec une probabilité d'au moins $1 - \delta$ sous P^n , simultanément pour tout $h \in \mathcal{H}$:

$$|R(h) - R_{\mathcal{S}_n}(h)| \leq \sqrt{\frac{\log|\mathcal{H}| + \log\left(\frac{2}{\delta}\right)}{2n}}$$

Étape 4 — Application à $\hat{h}_{\mathcal{S}}$.

La borne de l'étape 3 est **uniforme** sur $\mathcal{H}$: elle tient simultanément pour tous les h , y compris pour $\hat{h}_{\mathcal{S}_n}$ qui est lui-même une fonction aléatoire de $\mathcal{S}_n$. On peut donc écrire sur l'événement de probabilité $1 - \delta$:

$$\begin{aligned}
R(\hat{h}_{\mathcal{S}_n}) &= R(\hat{h}_{\mathcal{S}_n}) - R_S(\hat{h}_{\mathcal{S}_n}) + R_S(\hat{h}_{\mathcal{S}_n}) \\
&\leq |R(\hat{h}_{\mathcal{S}_n}) - R_S(\hat{h}_{\mathcal{S}_n})| + R_S(\hat{h}_{\mathcal{S}_n}) \\
&\leq R_S(\hat{h}_{\mathcal{S}_n}) + \sqrt{\frac{\log|\mathcal{H}| + \log(\frac{2}{\delta})}{2n}}
\end{aligned}$$

■

Remarques :

- **Uniformité.** C'est l'apport central du théorème : la borne tient **simultanément** pour tous les $h \in \mathcal{H}$, ce qui est indispensable puisque $\hat{h}_S$ dépend de $\mathcal{S}_n$.
- **Complexité logarithmique.** Le coût du passage de h fixé à $\sup_{h \in \mathcal{H}}$ est un facteur $\log|\mathcal{H}|$ dans la borne. Doubler $|\mathcal{H}|$ ne coûte qu'une constante additive mais $|\mathcal{H}|$ croît souvent **exponentiellement** vite.
- **Vitesse.** La borne est en $O\left(\frac{1}{\sqrt{n}}\right)$, contre une convergence $O\left(\frac{1}{n}\right)$ dans le cas séparable. C'est le prix à payer pour l'absence d'hypothèse de réalisabilité.
- **Interprétation.** La borne $R(\hat{h}_{\mathcal{S}_n}) \leq R_S(\hat{h}_{\mathcal{S}_n}) + \varepsilon_n(\delta)$ dit que le risque réel de $\hat{h}_{\mathcal{S}_n}$ n'excède son risque empirique que d'une quantité $\varepsilon_n(\delta)$ qui tend vers 0 quand $n \rightarrow +\infty$.

4.3. Cas $|\mathcal{H}| = +\infty$: théorie de Vapnik-Chervonenkis

Lorsque $\mathcal{H}$ est infinie (par exemple, l'ensemble des hyperplans de $\mathbb{R}^d$), la borne du théorème 3.2 est inutilisable car $\log|\mathcal{H}| = +\infty$.

Il faut une notion de complexité plus fine, qui mesure non pas le cardinal de $\mathcal{H}$ mais sa capacité à **discriminer** des points.

4.3.1. Dimension de Vapnik-Chervonenkis

Définition (Brisure)

On dit que $\mathcal{H}$ **brise** un ensemble fini $C = \{x_1, \dots, x_m\} \subset \mathcal{X}$ si pour tout étiquetage $(y_1, \dots, y_m) \in \{0, 1\}^m$, il existe $h \in \mathcal{H}$ tel que $h(x_i) = y_i$ pour tout i . Autrement dit, $\mathcal{H}$ réalise toutes les dichotomies possibles sur C :

$$|\{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}| = 2^m$$

Définition (Dimension VC)

La dimension de Vapnik-Chervonenkis de $\mathcal{H}$ est :

$$\text{VCdim}(\mathcal{H}) = \sup\{m \in \mathbb{N} : \exists C \subset \mathcal{X}, |C| = m, \mathcal{H} \text{ brise } C\}$$

Si $\mathcal{H}$ brise des ensembles de taille arbitraire, on pose $\text{VCdim}(\mathcal{H}) = +\infty$.

Exemples.

- **Seuils sur $\mathbb{R}$** : $\mathcal{H} = \{x \mapsto \mathbb{1}_{x \geq \theta} : \theta \in \mathbb{R}\}$. Tout singleton $\{x_0\}$ est brisé ($\theta < x_0$ donne 1, $\theta > x_0$ donne 0). Mais aucune paire $\{x_1, x_2\}$ avec $x_1 < x_2$ n'est brisée : l'étiquetage $(1, 0)$ est impossible. Donc $\text{VCdim}(\mathcal{H}) = 1$.
- **Intervalles sur $\mathbb{R}$** : $\mathcal{H} = \{x \mapsto \mathbb{1}_{x \in [a, b]} : a \leq b\}$. La paire $\{x_1, x_2\}$ avec $x_1 < x_2$ est brisée (les 4 étiquetages sont réalisables). Mais aucun triplet n'est brisé : l'étiquetage $(1, 0, 1)$ est impossible pour trois points ordonnés. Donc $\text{VCdim}(\mathcal{H}) = 2$.

- **Hyperplans de $\mathbb{R}^d$** : $\mathcal{H} = \{x \mapsto \mathbb{1}_{w^\top x \geq b} : w \in \mathbb{R}^d, b \in \mathbb{R}\}$. On peut montrer que $\text{VCdim}(\mathcal{H}) = d + 1$.

4.3.2. Coefficient de brisure et lemme de Sauer-Shelah

La dimension VC permet de borner le nombre de dichotomies effectivement réalisables sur un échantillon fini, via le **coefficient de brisure**.

Définition (Coefficient de brisure)

Le coefficient de brisure de $\mathcal{H}$ sur m points est :

$$\Pi_{\mathcal{H}}(m) = \max_{C \subset \mathcal{X}, |C|=m} |\{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}|$$

C'est le nombre maximal de dichotomies que $\mathcal{H}$ peut réaliser sur m points. On a toujours $\Pi_{\mathcal{H}}(m) \leq 2^m$.

Lemme de Sauer-Shelah (1972)

Si $\text{VCdim}(\mathcal{H}) = d < +\infty$, alors pour tout $m \geq 1$:

$$\Pi_{\mathcal{H}}(m) \leq \sum_{i=0}^d \binom{m}{i}$$

En particulier, pour $m \geq d$:

$$\Pi_{\mathcal{H}}(m) \leq \left(\frac{em}{d}\right)^d$$

Le coefficient de brisure est donc **polynomial** en m dès que la dimension VC est finie, contre 2^m dans le cas général.

4.3.3. Théorème de généralisation VC

On peut maintenant énoncer **une** borne de généralisation pour $|\mathcal{H}| = +\infty$.

Théorème 3.3 (Borne VC)

Soit $\mathcal{H}$ de dimension VC finie $d = \text{VCdim}(\mathcal{H})$. Soit $\mathcal{S}_n = \{(X_i, Y_i)\}_{i=1}^n$ i.i.d. de loi $P_{X,Y}$. Pour tout $\delta \in (0, 1)$, avec probabilité $1 - \delta$ sous $P^n = P_{X,Y}^{\otimes n}$, simultanément pour tout $h \in \mathcal{H}$:

$$|R(h) - R_{\mathcal{S}_n}(h)| \leq \sqrt{\frac{8d \log(2e \frac{n}{d}) + 8 \log(\frac{4}{\delta})}{n}}$$

4.3.4. Application : borne VC pour le SVM

Le SVM (Support Vector Machine) est un classifieur linéaire qui cherche l'hyperplan de marge maximale. La théorie VC fournit une borne de généralisation particulièrement élégante dans ce cas, car la dimension VC dépend de la marge et non de la dimension ambiante.

Définition (Classifieur à marge)

Soit $\mathcal{X} = \mathbb{R}^d$. On dit que $h_{w,b}(x) = \text{sgn}(w^\top x - b)$ classe S avec marge $\gamma > 0$ si :

$$\forall i \in \{1, \dots, n\}, \quad Y_i(w^\top X_i - b) \geq \gamma$$

On note $\mathcal{H}_\gamma$ la classe des classifieurs linéaires de norme $\|w\|_2 = 1$ qui séparent les données avec marge γ .

Théorème 3.4 (Borne VC pour le SVM, Vapnik 1995)

Supposons que les données vérifient $\|X_i\|_2 \leq R$ p.s. Soit $h_{w,b} \in \mathcal{H}_\gamma$ un classifieur linéaire de marge $\gamma > 0$ avec $\|w\|_2 = 1$. Alors :

$$\text{VCdim}(\mathcal{H}_\gamma) \leq \left\lfloor \frac{R^2}{\gamma^2} \right\rfloor$$

En appliquant le théorème 3.3, pour tout $\delta \in (0, 1)$, avec probabilité $1 - \delta$ sous P^n :

$$|R(h) - R_{\mathcal{S}_n}(h)| \leq \sqrt{\frac{8 \left\lfloor \frac{R^2}{\gamma^2} \right\rfloor \log\left(2en \frac{\gamma^2}{R^2}\right) + 8 \log\left(\frac{4}{\delta}\right)}{n}}$$

Démonstration :

Laissée en exercice. Partir du théorème VC général.

4.4. Limites de la théorie VC pour les réseaux de neurones

Les bornes VC développées dans les sections précédentes sont des résultats fondamentaux, mais elles se heurtent à des limitations sérieuses dès qu'on les applique aux réseaux de neurones modernes.

4.4.1. Dimension VC des réseaux de neurones

Pour un réseau de neurones à L couches, n neurones et poids W , on peut montrer que :

Théorème (Bartlett, 1998)

Pour un réseau de neurones à fonctions d'activation seuil, à L couches et W paramètres :

$$\text{VCdim}(\mathcal{H}) = O(WL \log W)$$

La borne VC donne donc une erreur de généralisation de l'ordre de :

$$|R(h) - R_{\mathcal{S}_n}(h)| = O\left(\sqrt{\frac{WL \log W}{n}}\right)$$

Pour un réseau moderne, W est de l'ordre de 10^8 à 10^{11} paramètres. Pour que cette borne soit non triviale (inférieure à 1), il faudrait :

$$n \gg WL \log W \approx 10^{10}$$

ce qui est **astronomiquement** plus grand que les datasets d'entraînement habituels ($n \approx 10^6$ à 10^7). La borne VC est donc inutilisable en pratique pour les réseaux profonds.

4.4.2. Le paradoxe de la double descente

Ce qui rend la situation encore plus paradoxale, c'est que les réseaux de neurones modernes généralisent **bien** en pratique, même dans des régimes où :

- Le nombre de paramètres W dépasse largement n (**régime sur-paramétré**).
- Le risque empirique est exactement nul ($R_{\mathcal{S}_n}(\hat{h}) = 0$, **interpolation**).

Phénomène de double descente (Belkin et al., 2019)

En traçant le risque de généralisation en fonction de la complexité du modèle (nombre de paramètres), on observe non pas la courbe en U classique du compromis biais-variance, mais une **double descente** :

1. **Régime sous-paramétré** ($W \ll n$) : la courbe en U classique, le risque augmente quand le modèle est trop complexe.
2. **Seuil d'interpolation** ($W \approx n$) : le risque explose car le modèle commence à interpoler mais pas encore bien.
3. **Régime sur-paramétré** ($W \gg n$) : le risque **redescend** et peut atteindre des niveaux très bas, malgré l'interpolation.

Ce phénomène invalide la vision classique du compromis biais-variance et n'est pas expliqué par la théorie VC.




Fig. 1. — Illustration du phénomène de double descente pour la régression linéaire par pseudo-inverse en dimension $d = 50$, moyennée sur 50 répétitions. La ligne verticale pointillée indique $n = d = 50$, le seuil d'interpolation. Pour $n < d$ (régime sous-paramétré), le système est sous-déterminé : la pseudo-inverse trouve la solution de norme minimale parmi une infinité de solutions, et l'erreur de test est élevée. En $n = d$, le système est exactement déterminé : $\hat{\beta} = X^{-1}y$ interpole parfaitement les données ($R_{\mathcal{S}_n} = 0$) mais l'erreur de test explose car la matrice X est mal conditionnée. Pour $n > d$ (régime sur-paramétré), le système est sur-déterminé : la pseudo-inverse calcule la solution aux moindres carrés, l'erreur de test redescend et converge vers l'erreur de Bayes irréductible $\sigma^2 = 1$. Ce comportement illustre que la vision classique du compromis biais-variance (une seule montée de l'erreur de test) est insuffisante : le minimum global n'est pas atteint au seuil d'interpolation mais **après**, dans le régime sur-paramétré.

4.4.3. Pourquoi les réseaux généralisent-ils malgré tout ? Plusieurs pistes théoriques ont été explorées, sans qu'aucune ne fournisse une explication complète :

1. Régularisation implicite de la descente de gradient stochastique (SGD).

En pratique, on n'atteint pas le minimiseur global du risque empirique mais une solution trouvée par SGD. Il a été montré que SGD a un biais vers les solutions de **norme minimale** :

Résultat (Zhang et al., 2017 ; Soudry et al., 2018)

Pour la régression logistique sur des données linéairement séparables, la descente de gradient converge vers le classifieur de **marge maximale**, c'est-à-dire la solution SVM, même sans régularisation explicite.

Ce biais implicite de l'optimiseur vers des solutions régulières explique partiellement la bonne généralisation.

2. Bornes basées sur la norme des poids.

Plutôt que de compter les paramètres, on peut mesurer la complexité par la norme des poids. Bartlett et al. (2017) montrent :

Théorème (Bartlett, Foster, Telgarsky, 2017)

Pour un réseau à L couches de matrices de poids $W_1, \dots, W_L$, avec probabilité $1 - \delta$:

$$R(h) - R_{\mathcal{S}_n}(h) = \tilde{O} \left(\frac{\left(\prod_{l=1}^L \|W_l\|_{\text{op}} \right) \cdot \left(\sum_{l=1}^L \|W_l\|_F^{\frac{2}{3}} \right)^{\frac{3}{2}}}{\sqrt{n}} \right)$$

où $\|\cdot\|_{\text{op}}$ est la norme spectrale et $\|\cdot\|_F$ la norme de Frobenius.

Cette borne est **indépendante de la profondeur et de la largeur** du réseau en tant que tels, et dépend uniquement des normes des poids. Elle peut être non triviale même pour des réseaux très larges, si les poids restent petits.

3. Complexité de Rademacher.

Une alternative à la dimension VC est la **complexité de Rademacher**, qui mesure la capacité d'une classe à s'adapter à du bruit aléatoire :

Définition (Complexité de Rademacher empirique)

$$\hat{\mathfrak{R}}_n(\mathcal{H}) = E_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(X_i) \right]$$

où $\sigma_1, \dots, \sigma_n$ sont des variables de Rademacher i.i.d. ($P(\sigma_i = \pm 1) = \frac{1}{2}$), indépendantes de $\mathcal{S}_n$.

Théorème (Borne de Rademacher)

Avec probabilité $1 - \delta$ sous P^n :

$$\sup_{h \in \mathcal{H}} |R(h) - R_{\mathcal{S}_n}(h)| \leq 2\hat{\mathfrak{R}}_n(\mathcal{H}) + \sqrt{\frac{\log\left(\frac{2}{\delta}\right)}{2n}}$$

L'avantage de la complexité de Rademacher sur la dimension VC est qu'elle est **data-dependent** : elle dépend de l'échantillon $\mathcal{S}_n$ et pas seulement de la classe $\mathcal{H}$. Pour des réseaux dont les poids sont contraints en norme, elle peut être bornée indépendamment du nombre de paramètres.

5. Fonctions de perte calibrées

5.1. Motivation : pourquoi ne pas minimiser la perte 0-1 ?

Le classifieur de Bayes h^* minimise le risque 0-1 $R(h) = P(h(X) \neq Y)$. Il serait donc naturel de minimiser directement le risque empirique 0-1 :

$$\hat{h} = \arg \min_{h \in \mathcal{H}} R_S(h) = \arg \min_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{h(X_i) \neq Y_i}$$

Cependant, ce problème est **NP-difficile** en général : la perte 0-1 est non convexe, discontinue, et son gradient est nul presque partout. On ne peut pas l'optimiser par descente de gradient.

Exemple : deep learning. En pratique, on paramètre h par un réseau de neurones $f_\theta : \mathcal{X} \rightarrow \mathbb{R}$ et on pose $h_\theta(x) = \text{sgn}(f_\theta(x))$. On ne minimise pas :

$$\frac{1}{n} \sum_{i=1}^n \mathbb{1}_{y_i f_\theta(x_i) < 0}$$

mais la **perte logistique** (ou cross-entropy) :

$$\frac{1}{n} \sum_{i=1}^n \log(1 + e^{-y_i f_\theta(x_i)})$$

qui est convexe en $f_\theta(x_i)$, différentiable, et dont le gradient donne une direction de descente utile.

Exercice : équivalence entre perte logistique et cross-entropy

En classification binaire, on dispose de deux formulations de la perte :

- **Perte logistique** (convention $y \in \{-1, +1\}$, sortie $f(x) \in \mathbb{R}$) :

$$\ell_{\log}(y, f(x)) = \log(1 + e^{-yf(x)})$$

- **Cross-entropy** (convention $\tilde{y} \in \{0, 1\}$, sortie $\sigma(f(x)) \in (0, 1)$) :

$$\ell_{\text{CE}}(\tilde{y}, f(x)) = -\tilde{y} \log(\sigma(f(x))) - (1 - \tilde{y}) \log(1 - \sigma(f(x)))$$

où $\sigma(t) = \frac{1}{1+e^{-t}}$ est la fonction sigmoïde.

Montrer que ces deux pertes sont identiques à un changement de convention près.

Indication : Exprimer $\sigma(f(x))$ et $1 - \sigma(f(x))$ en fonction de $e^{f(x)}$, puis traiter séparément les cas $\tilde{y} = 1$ et $\tilde{y} = 0$, correspondant respectivement à $y = +1$ et $y = -1$.

Solution :

Étape 1 — Intuition.

Les deux formulations encodent la même idée : pénaliser le modèle quand il est confiant dans la mauvaise direction. La perte logistique le fait via la marge $yf(x)$ (négative quand f et y sont de signes opposés), et la cross-entropy via la log-vraisemblance d'un modèle de Bernoulli de paramètre $\sigma(f(x))$.

Étape 2 — Rappels sur la sigmoïde.

On note que :

$$\sigma(t) = \frac{1}{1 + e^{-t}} \quad \text{et} \quad 1 - \sigma(t) = \frac{e^{-t}}{1 + e^{-t}} = \frac{1}{1 + e^t} = \sigma(-t)$$

Donc :

$$\begin{aligned} \log(\sigma(t)) &= -\log(1 + e^{-t}) \quad \text{et} \quad \log(1 - \sigma(t)) \\ &= \log(\sigma(-t)) = -\log(1 + e^t) \end{aligned}$$

Étape 3 — Cas $\tilde{y} = 1$ (correspondant à $y = +1$).

$$\begin{aligned} \ell_{\text{CE}}(1, f(x)) &= -\log(\sigma(f(x))) \\ &= \log(1 + e^{-f(x)}) \\ &= \log(1 + e^{-yf(x)}) \\ &= \ell_{\log}(+1, f(x)) \quad \checkmark \end{aligned}$$

Étape 4 — Cas $\tilde{y} = 0$ (correspondant à $y = -1$).

$$\begin{aligned} \ell_{\text{CE}}(0, f(x)) &= -\log(1 - \sigma(f(x))) \\ &= -\log(\sigma(-f(x))) \\ &= \log(1 + e^{f(x)}) \\ &= \log(1 + e^{-(-1)f(x)}) \\ &= \log(1 + e^{-yf(x)}) \\ &= \ell_{\log}(-1, f(x)) \quad \checkmark \end{aligned}$$

Conclusion.

Les deux pertes sont identiques sous le changement de convention $\tilde{y} = \frac{y+1}{2} \in \{0, 1\} \Leftrightarrow y = 2\tilde{y} - 1 \in \{-1, +1\}$:

$$\ell_{\text{CE}}(\tilde{y}, f(x)) = \ell_{\log}(2\tilde{y} - 1, f(x)) = \log(1 + e^{-(2\tilde{y}-1)f(x)})$$

Interprétation probabiliste. La cross-entropy est la log-vraisemblance négative du modèle probabiliste :

$$P(Y = 1 \mid X = x) = \sigma(f(x))$$

Minimiser la cross-entropy revient donc à maximiser la vraisemblance du modèle logistique, ce qui justifie son usage en deep learning : on cherche les paramètres θ qui rendent les labels observés les plus probables sous le modèle $\sigma(f_\theta)$.

De même, le SVM minimise la perte charnière $\max(0, 1 - yf(x))$, et AdaBoost minimise implicitement la perte exponentielle $e^{-yf(x)}$.

La question fondamentale est : **minimiser une perte proxy φ conduit-il bien à un classifieur proche de h^* ?** C'est l'objet de la calibration.




Fig. 2. — Comparaison des fonctions de perte en fonction de la marge $t = yf(x)$. La perte 0-1 (discontinue) est le critère théorique optimal mais non optimisable par descente de gradient. Les pertes de substitution — charnière ($\max(0, 1 - t)$), logistique ($\log(1 + e^{-t})$), charnière adoucie ($\frac{1}{\beta} \log(1 + e^{-\beta(t-1)})$ avec $\beta = 3$) et Brier ($(1 - t)^2$) — en sont des majorantes convexes et différentiables. Toutes vérifient $\varphi'(0) < 0$, garantissant leur calibration au sens du théorème 4.1 : minimiser l'une d'elles conduit asymptotiquement au même classifieur que la minimisation du risque 0-1. Le score de Brier, équivalent à l'erreur quadratique moyenne sur les probabilités prédites, pénalise quadratiquement les marges inférieures à 1 et reste sensible aux grandes marges négatives, contrairement à la charnière qui est nulle pour $t \geq 1$.

5.2. Formalisation

On se place en classification binaire $\mathcal{Y} = \{-1, +1\}$. Un modèle est une fonction $f : \mathcal{X} \rightarrow \mathbb{R}$, et la décision associée est $h_f(x) = \text{sgn}(f(x))$. On remplace la perte 0-1 par une **perte de substitution** $\varphi : \mathbb{R} \rightarrow \mathbb{R}_+$ appliquée à la marge $yf(x)$:

$$\ell_\varphi(f(x), y) = \varphi(yf(x))$$

Vérification sur la perte 0-1. On pose $\varphi_{0-1}(t) = \mathbb{1}_{t < 0}$. Alors :

$$\ell_{\varphi_{0-1}}(f(x), y) = \mathbb{1}_{yf(x) < 0} = \mathbb{1}_{\text{sgn}(f(x)) \neq y}$$

ce qui redonne bien la perte 0-1 usuelle : la marge $yf(x)$ est négative si et seulement si $f(x)$ et y sont de signes opposés, c'est-à-dire quand le classifieur se trompe.

Le **φ -risque** est :

$$R_\varphi(f) = E[\varphi(Yf(X))]$$

et le **φ -risque de Bayes** est :

$$R_\varphi^* = \inf_{f: \mathcal{X} \rightarrow \mathbb{R}} R_\varphi(f)$$

Exemples de pertes usuelles.

Perte	Expression $\varphi(t)$	Usage
Logistique	$\log(1 + e^{-t})$	Régression logistique, deep learning
Charnière	$\max(0, 1 - t)$	SVM
Exponentielle	e^{-t}	AdaBoost

Carrée (Brier)	$(1 - t)^2$	Least-squares classification
----------------	-------------	------------------------------

5.3. Calibration

5.3.1. Définition et sens

Définition (Perte calibrée)

Une fonction de perte $\varphi : \mathbb{R} \rightarrow \mathbb{R}_+$ **convexe et positive** est dite **calibrée** si pour tout $\eta \in [0, 1]$ et toute suite (f_n) de fonctions mesurables :

$$R_\varphi(f_n) \xrightarrow{n \rightarrow +\infty} R_\varphi^* \implies R(h_{f_n}) \xrightarrow{n \rightarrow +\infty} R^*$$

Autrement dit, minimiser le φ -risque conduit bien à minimiser le risque 0-1.

L'idée est la suivante : si φ est calibrée, on peut travailler avec R_φ (convexe, différentiable) plutôt qu'avec R (discontinu), et la convergence dans l'espace des φ -risques entraîne la convergence dans l'espace des risques 0-1.

5.3.2. Condition de calibration ponctuelle

Par la loi des espérances totales, on peut écrire :

$$R_\varphi(f) = E_X[C_\varphi(f(X), \eta(X))]$$

où $\eta(x) = P(Y = 1 | X = x)$ et le risque conditionnel est :

$$C_\varphi(\alpha, \eta) = \eta\varphi(\alpha) + (1 - \eta)\varphi(-\alpha)$$

Le φ -risque de Bayes conditionnel est :

$$C_\varphi^*(\eta) = \inf_{\alpha \in \mathbb{R}} C_\varphi(\alpha, \eta)$$

Définition (Calibration ponctuelle)

φ est **ponctuellement calibrée** en η si tout minimiseur $\alpha^*(\eta)$ de $\alpha \mapsto C_\varphi(\alpha, \eta)$ vérifie :

$$\eta > \frac{1}{2} \iff \arg \min_{\alpha \in \mathbb{R}} C_\varphi(\alpha, \eta) \subset \mathbb{R}_+^*$$

$$\eta < \frac{1}{2} \iff \arg \min_{\alpha \in \mathbb{R}} C_\varphi(\alpha, \eta) \subset \mathbb{R}_-^*$$

c'est-à-dire que le signe du prédicteur optimal pour φ coïncide avec celui du classifieur de Bayes.

5.3.3. Théorème de calibration

Théorème 4.1 (Bartlett, Jordan, McAuliffe, 2006)

Soit $\varphi : \mathbb{R} \rightarrow \mathbb{R}_+$ convexe et positive. Alors φ est calibrée si et seulement si φ est différentiable en 0 et $\varphi'(0) < 0$.

Démonstration :

On étudie la calibration ponctuelle en η . Le risque conditionnel est :

$$C_\varphi(\alpha, \eta) = \eta\varphi(\alpha) + (1 - \eta)\varphi(-\alpha)$$

Puisque φ est convexe, $C_\varphi(\cdot, \eta)$ est convexe pour tout $\eta \in [0, 1]$. On caractérise la localisation des minimiseurs via les dérivées à gauche et à droite en 0.

Rappel : localisation des minimiseurs d'une fonction convexe.

Pour une fonction convexe $g : \mathbb{R} \rightarrow \mathbb{R}$, on a :

- $\arg \min g \subset \mathbb{R}_+^*$ si et seulement si $g'_+(0) < 0$
- $\arg \min g \subset \mathbb{R}_-^*$ si et seulement si $g'_-(0) > 0$

En effet, par convexité, g'_+ est croissante et $g'_-(t) \leq g'_+(t)$ pour tout t . Un minimiseur α^* vérifie $g'_-(\alpha^*) \leq 0 \leq g'_+(\alpha^*)$. Donc $\alpha^* > 0$ si et seulement si $g'_+(0) < 0$ (sinon 0 serait déjà minimiseur), et $\alpha^* < 0$ si et seulement si $g'_-(0) > 0$.

On calcule les dérivées à gauche et à droite de $C_\varphi(\cdot, \eta)$ en 0. Puisque φ est convexe, elle admet des dérivées à gauche et à droite en tout point, et en particulier en 0. Par la règle de dérivation de $\alpha \mapsto \varphi(-\alpha)$, dont les dérivées à gauche et à droite en 0 sont $-\varphi'_+(0)$ et $-\varphi'_-(0)$ respectivement :

$$(C_\varphi)_+(0)' = \eta\varphi'_+(0) - (1 - \eta)\varphi'_-(0)$$

$$(C_\varphi)_-(0)' = \eta\varphi'_-(0) - (1 - \eta)\varphi'_+(0)$$

On obtient ainsi les équivalences :

$$\arg \min_{\alpha \in \mathbb{R}} C_\varphi(\alpha, \eta) \subset \mathbb{R}_+^* \iff \eta\varphi'_+(0) - (1 - \eta)\varphi'_-(0) < 0$$

$$\arg \min_{\alpha \in \mathbb{R}} C_\varphi(\alpha, \eta) \subset \mathbb{R}_-^* \iff \eta\varphi'_-(0) - (1 - \eta)\varphi'_+(0) > 0$$

($\Rightarrow$) Si φ est calibrée, alors φ est différentiable en 0 et $\varphi'(0) < 0$.

Supposons φ calibrée. Pour tout $\eta > \frac{1}{2}$, la condition de calibration impose $\arg \min C_\varphi(\cdot, \eta) \subset \mathbb{R}_+^*$, soit :

$$\eta\varphi'_+(0) - (1 - \eta)\varphi'_-(0) < 0$$

Cette inégalité est stricte pour tout $\eta > \frac{1}{2}$. En faisant tendre $\eta \rightarrow \frac{1}{2}^+$, on obtient à la limite :

$$\frac{1}{2}\varphi'_+(0) - \frac{1}{2}\varphi'_-(0) \leq 0 \iff \varphi'_+(0) \leq \varphi'_-(0)$$

Or φ convexe implique toujours $\varphi'_-(0) \leq \varphi'_+(0)$. En combinant :

$$\varphi'_-(0) \leq \varphi'_+(0) \leq \varphi'_-(0)$$

donc $\varphi'_+(0) = \varphi'_-(0)$: φ est différentiable en 0.

Les dérivées à gauche et à droite de φ en 0 sont donc égales : φ est **différentiable en 0**, et on note $\varphi'(0) = \varphi'_+(0) = \varphi'_-(0)$.

Les équivalences deviennent alors :

$$(C_\varphi)'(0) = (2\eta - 1)\varphi'(0)$$

La condition de calibration pour $\eta > \frac{1}{2}$ impose $(2\eta - 1)\varphi'(0) < 0$, soit $\varphi'(0) < 0$ puisque $2\eta - 1 > 0$.

($\Leftarrow$) Si φ est différentiable en 0 et $\varphi'(0) < 0$, alors φ est calibrée.

Supposons $\varphi'(0) < 0$. Alors :

$$(C_\varphi)'(0) = (2\eta - 1)\varphi'(0)$$

- Si $\eta > \frac{1}{2}$: $(2\eta - 1) > 0$ et $\varphi'(0) < 0$, donc $(C_\varphi)'_+(0) = (2\eta - 1)\varphi'(0) < 0$, et : $\arg \min_{\alpha \in \mathbb{R}} C_\varphi(\alpha, \eta) \subset \mathbb{R}_+^*$ ✓

- Si $\eta < \frac{1}{2}$: $(2\eta - 1) < 0$ et $\varphi'(0) < 0$, donc $(C_\varphi)'_{-}(0) = (2\eta - 1)\varphi'(0) > 0$, et : $\arg \min_{\alpha \in \mathbb{R}} C_\varphi(\alpha, \eta) \subset \mathbb{R}_-^*$ ✓

Dans les deux cas, le minimiseur de $C_\varphi(\cdot, \eta)$ est du bon signe : φ est ponctuellement calibrée pour tout $\eta \neq \frac{1}{2}$, donc calibrée au sens de la définition ■.

Vérification sur les exemples.

- **Logistique** : $\varphi(t) = \log(1 + e^{-t})$, $\varphi'(t) = -\frac{e^{-t}}{1+e^{-t}}$, $\varphi'(0) = -\frac{1}{2} < 0$. ✓
- **Charnière** : $\varphi(t) = \max(0, 1 - t)$, $\varphi'(0^-) = -1 < 0$. ✓
- **Exponentielle** : $\varphi(t) = e^{-t}$, $\varphi'(0) = -1 < 0$. ✓
- **Carrée** : $\varphi(t) = (1 - t)^2$, $\varphi'(0) = -2 < 0$. ✓

5.4. Décomposition de l'erreur

On dispose maintenant de tous les outils pour décomposer l'erreur totale d'un algorithme qui minimise un φ -risque empirique sur une classe $\mathcal{F}$.

5.4.1. Mise en place

Soit $\hat{f}_{\mathcal{S}_n} = \arg \min_{f \in \mathcal{F}} R_{\varphi, \mathcal{S}_n}(f)$ le minimiseur du φ -risque empirique, où :

$$R_{\varphi, \mathcal{S}_n}(f) = \frac{1}{n} \sum_{i=1}^n \varphi(Y_i f(X_i))$$

On note :

- $f^* = \arg \min_{f \in \mathcal{F}} R_\varphi(f)$: le meilleur modèle dans $\mathcal{F}$
- $f^{**} : x \mapsto \arg \min_{\alpha \in \mathbb{R}} C_\varphi(\alpha, \eta(x))$: le minimiseur du φ -risque global (sans contrainte de classe)

- $R_\varphi^* = R_\varphi(f^{**})$: le φ -risque de Bayes

5.4.2. Décomposition en quatre termes

Théorème 4.2 (Décomposition de l'erreur)

L'excès de risque 0-1 se décompose comme :

$$\begin{aligned}
 R(h_{\hat{f}_S}) - R^* &= \underbrace{R(h_{\hat{f}_S}) - R(h_{f^*})}_A \\
 &\quad + \underbrace{R(h_{f^*}) - R(h_{f^{**}})}_B \\
 &\quad + \underbrace{R(h_{f^{**}}) - R^*}_C
 \end{aligned}$$

où :

- $\hat{f}_S = \arg \min_{f \in \mathcal{F}} R_{\varphi,S}(f)$ est le minimiseur du φ -risque empirique
- $f^* = \arg \min_{f \in \mathcal{F}} R_\varphi(f)$ est le meilleur modèle dans $\mathcal{F}$ pour le φ -risque
- f^{**} est le minimiseur global du φ -risque sur toutes les fonctions mesurables

Les trois termes ont les interprétations suivantes :

- **A : terme d'estimation** — écart dû à l'utilisation d'un échantillon fini plutôt que de la vraie distribution
- **B : terme de calibration** — écart entre le meilleur modèle dans $\mathcal{F}$ pour φ et le minimiseur global de φ , mesuré en risque 0-1 ; il est nul si $f^{**} \in \mathcal{F}$

- **C : terme d'approximation** — écart entre le minimiseur global du φ -risque et le classifieur de Bayes ; il est nul si φ est calibrée

Démonstration :

La décomposition est une identité algébrique :

$$\begin{aligned} R(h_{\hat{f}_S}) - R^* &= R(h_{\hat{f}_S}) - R(h_{f^*}) \\ &\quad + R(h_{f^*}) - R(h_{f^{**}}) \\ &\quad + R(h_{f^{**}}) - R^* \end{aligned}$$

Il reste à vérifier le signe de chaque terme.

- **Terme A** : Pas nécessairement positif terme à terme, mais contrôlé en espérance par les inégalités de concentration uniformes de la section 3.
- **Terme B** : f^* minimise R_φ sur $\mathcal{F}$, donc $R_\varphi(f^*) \leq R_\varphi(f^{**})$. Mais cela ne dit rien directement sur le risque 0-1. Ce terme mesure le **coût de la restriction à $\mathcal{F}$** lorsqu'on optimise φ plutôt que la perte 0-1 : même si $f^{**} \in \mathcal{F}$, le meilleur modèle pour φ dans $\mathcal{F}$ n'est pas nécessairement le meilleur pour la perte 0-1.
- **Terme C** : f^{**} minimise R_φ sans contrainte, donc $R_\varphi(f^{**}) = R_\varphi^*$. Si φ est calibrée, le minimiseur du φ -risque a le même signe que $\eta(x) - \frac{1}{2}$ pour presque tout x , donc $h_{f^{**}} = h^*$ p.s. et $C = 0$.

En particulier, si φ est calibrée et $f^{**} \in \mathcal{F}$, le terme C et le terme B sont tous deux nuls, et l'excès de risque se réduit au seul terme d'estimation A . ■

6. Bibliographie

6.1. Ouvrages de référence

Théorie de l'apprentissage statistique

- Devroye, L., Györfi, L., Lugosi, G. (1996). *A Probabilistic Theory of Pattern Recognition*. Springer.
- Shalev-Shwartz, S., Ben-David, S. (2014). *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press.
- Bach, F. (2024). *Learning Theory from First Principles*. MIT Press.
- Vapnik, V. (1995). *The Nature of Statistical Learning Theory*. Springer.
- Boucheron, S., Lugosi, G., Massart, P. (2013). *Concentration Inequalities: A Nonasymptotic Theory of Independence*. Oxford University Press.

6.2. Articles scientifiques cités

Résultats classiques

- Stone, C. J. (1977). Consistent nonparametric regression. *Annals of Statistics*, 5(4), 595–620.

- **Hoeffding, W.** (1963). Probability inequalities for sums of bounded random variables. *Journal of the American Statistical Association*, 58(301), 13–30.
- **Sauer, N.** (1972). On the density of families of sets. *Journal of Combinatorial Theory, Series A*, 13(1), 145–147.
- **Shelah, S.** (1972). A combinatorial problem; stability and order for models and theories in infinitary languages. *Pacific Journal of Mathematics*, 41(1), 247–261.

Calibration et pertes de substitution

- **Bartlett, P. L., Jordan, M. I., McAuliffe, J. D.** (2006). Convexity, classification, and risk bounds. *Journal of the American Statistical Association*, 101(473), 138–156.

Généralisation des réseaux de neurones

- **Bartlett, P. L.** (1998). The sample complexity of pattern classification with neural networks: the size of the weights is more important than the size of the network. *IEEE Transactions on Information Theory*, 44(2), 525–536.
- **Bartlett, P. L., Foster, D. J., Telgarsky, M.** (2017). Spectrally-normalized margin bounds for neural networks. *NeurIPS 2017*.
- **Zhang, C., Bengio, S., Hardt, M., Recht, B., Vinyals, O.** (2017). Understanding deep learning requires rethinking generalization. *ICLR 2017*.
- **Soudry, D., Hoffer, E., Nacson, M. S., Gunasekar, S., Srebro, N.** (2018). The implicit bias of gradient descent

on separable data. *Journal of Machine Learning Research*, 19(1), 2822–2878.

- **Belkin, M., Hsu, D., Ma, S., Mandal, S.** (2019). Reconciling modern machine-learning practice and the classical bias–variance trade-off. *PNAS*, 116(32), 15849–15854.