

■ DONNÉES SÉQUENTIELLES

Modèles de régression dynamique

MARINE DEMANGEOT



RÉGRESSION AVEC DES ERREURS

ARIMA

Modèles de régression standard

$$y_t = \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \varepsilon_t,$$

- Les erreurs ε_t sont supposées être des bruits blancs.
- Nous souhaitons maintenant que le bruit ε_t puisse être autocorrélé.

Modèles de régression standard

$$y_t = \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \varepsilon_t,$$

- Les erreurs ε_t sont supposées être des bruits blancs.
- Nous souhaitons maintenant que le bruit ε_t puisse être autocorrélé.

Exemple : erreurs ARIMA(1,1,1)

$$\begin{aligned} y_t &= \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \eta_t, \\ (1 - \phi_1 B)(1 - B)\eta_t &= (1 + \theta_1 B)\varepsilon_t, \end{aligned}$$

où ε_t est un bruit blanc

Exemple : $\eta_t = \text{ARIMA}(1,1,1)$

$$y_t = \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \eta_t,$$
$$(1 - \phi_1 B)(1 - B)\eta_t = (1 + \theta_1 B)\varepsilon_t,$$

Exemple : $\eta_t = \text{ARIMA}(1,1,1)$

$$y_t = \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \eta_t,$$
$$(1 - \phi_1 B)(1 - B)\eta_t = (1 + \theta_1 B)\varepsilon_t,$$

- Attention de bien distinguer η_t de ε_t .
- Seules les erreurs ε_t sont assumées être des bruits blancs.

Si $\sum \hat{\eta}_t^2$ est minimisée (comme en régression ordinaire) :

- 1** Les coefficients estimés $\hat{\beta}_0, \dots, \hat{\beta}_k$ ne sont plus optimaux puisque de l'information a été ignorée
- 2** Les test associés au modèle (e.g., t-tests sur les coefficients) sont incorrectes
- 3** Les p -valeurs associées aux coefficients sont généralement trop petites ("spurious regression'')

Si $\sum \hat{\eta}_t^2$ est minimisée (comme en régression ordinaire) :

- 1 Les coefficients estimés $\hat{\beta}_0, \dots, \hat{\beta}_k$ ne sont plus optimaux puisque de l'information a été ignorée
 - 2 Les test associés au modèle (e.g., t-tests sur les coefficients) sont incorrectes
 - 3 Les p -valeurs associées aux coefficients sont généralement trop petites ("spurious regression'')
-
- Minimiser $\sum \hat{\varepsilon}_t^2$ évite ces problèmes.
 - Maximiser la vraisemblance est équivalent à minimiser $\sum \hat{\varepsilon}_t^2$.

Modèle avec erreurs ARIMA(1,1,1)

$$y_t = \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \eta_t,$$
$$(1 - \phi_1 B)(1 - B)\eta_t = (1 + \theta_1 B)\varepsilon_t,$$

Modèle avec erreurs ARIMA(1,1,1)

$$y_t = \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \eta_t,$$
$$(1 - \phi_1 B)(1 - B)\eta_t = (1 + \theta_1 B)\varepsilon_t,$$

Équivalent au modèle avec erreurs ARIMA(1,0,1)

$$y'_t = \beta_1 x'_{1,t} + \cdots + \beta_k x'_{k,t} + \eta'_t,$$
$$(1 - \phi_1 B)\eta'_t = (1 + \theta_1 B)\varepsilon_t,$$

où $y'_t = y_t - y_{t-1}$, $x'_{t,i} = x_{t,i} - x_{t-1,i}$ et $\eta'_t = \eta_t - \eta_{t-1}$.

■ Régression avec des erreurs ARIMA



Toute régression avec une erreur ARIMA peut être réécrite comme une régression avec une erreur ARMA en différenciant toutes les variables (même opérateur que dans le modèle ARIMA)

■ Régression avec des erreurs ARIMA



Toute régression avec une erreur ARIMA peut être réécrite comme une régression avec une erreur ARMA en différenciant toutes les variables (même opérateur que dans le modèle ARIMA)

Données originales

$$y_t = \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \eta_t$$

où $\phi(B)(1 - B)^d \eta_t = \theta(B)\varepsilon_t$

Toute régression avec une erreur ARIMA peut être réécrite comme une régression avec une erreur ARMA en différenciant toutes les variables (même opérateur que dans le modèle ARIMA)

Données originales

$$y_t = \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \eta_t$$

où $\phi(B)(1-B)^d \eta_t = \theta(B)\varepsilon_t$

Après avoir différencié toutes les variables

$$y'_t = \beta_1 x'_{1,t} + \cdots + \beta_k x'_{k,t} + \eta'_t.$$

où $\phi(B)\eta'_t = \theta(B)\varepsilon_t$,

$$y'_t = (1-B)^d y_t, \quad x'_{i,t} = (1-B)^d x_{i,t}, \quad \text{et} \quad \eta'_t = (1-B)^d \eta_t$$

On regarde donc des modèles qui s'écrivent

$$y'_t = \beta x'_t + \eta'_t = \beta x'_t + \frac{\theta(B)}{\phi(B)} \varepsilon'_t$$

Dans la littérature, on retrouve aussi des modèles où le modèle ARMA est mis sur les y_t :

$$y_t = \beta x_t + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} - \cdots + \theta_q \varepsilon_{t-q}$$


i.e.

$$y_t = \frac{\beta}{\phi(B)} x_t + \frac{\theta(B)}{\phi(B)} \varepsilon_t$$

Dans ce deuxième cas, la valeur de β ne correspond pas à l'effet sur y_t lorsque x_t est augmenté d'une unité (comme c'est le cas en régression). La présence de valeurs retardées de la variable réponse du côté droit de l'équation signifie que β ne peut être interprété qu'en fonction des valeurs précédentes de la variable réponse, ce qui est loin d'être intuitif.

- Dans R, on peut spécifier un $\text{ARIMA}(p, d, q)$ pour les erreurs, et d niveaux de différenciation seront appliqués à toutes les variables $(y, x_{1,t}, \dots, x_{k,t})$
- Il faut vérifier que la série ε_t ressemble à un bruit blanc
- L'AICc peut être calculé pour le modèle final
- On peut répéter la procédure pour tous les sous-ensembles de prédicteurs à considérer et sélectionnez le modèle avec la plus basse valeur d'AICc.

■ Conso et revenus des ménages (USA)



■ Conso et revenus des ménages (USA)

```
fit <- us_change %>% model(ARIMA(Consumption ~ Income))  
report(fit)
```

```
## Series: Consumption  
## Model: LM w/ ARIMA(1,0,2) errors  
##  
## Coefficients:  
##          ar1      ma1      ma2  Income  intercept  
##          0.707  -0.617  0.2066  0.1976      0.595  
## s.e.    0.107    0.122  0.0741  0.0462      0.085  
##  
## sigma^2 estimated as 0.3113:  log likelihood=-163  
## AIC=338    AICc=339    BIC=358
```

■ Conso et revenus des ménages (USA)


```
fit <- us_change %>% model(ARIMA(Consumption ~ Income))
report(fit)
```

```
## Series: Consumption
## Model: LM w/ ARIMA(1,0,2) errors
##
## Coefficients:
##          ar1      ma1      ma2  Income  intercept
##          0.707  -0.617   0.2066  0.1976      0.595
## s.e.    0.107    0.122   0.0741  0.0462      0.085
##
## sigma^2 estimated as 0.3113:  log likelihood=-163
## AIC=338   AICc=339   BIC=358
```

Écrire l'équation du modèle ajusté


■ Conso et revenus des ménages (USA)

```
residuals(fit, type='regression') %>%  
  gg_tdisplay(.resid, plot_type = 'partial') +  
  labs(title = "Regression errors")
```



■ Conso et revenus des ménages (USA)

```
residuals(fit, type='innovation') %>%  
  gg_tsdisplay(.resid, plot_type = 'partial') +  
  labs(title = "ARIMA errors")
```




■ Conso et revenus des ménages (USA)

```
augment(fit) %>%  
  features(.resid, ljung_box, dof = 5, lag = 12)
```

```
## # A tibble: 1 x 3  
##   .model                                lb_stat lb_pvalue  
##   <chr>                                <dbl>    <dbl>  
## 1 ARIMA(Consumption ~ Income)         5.54      0.595
```

■ Conso et revenus des ménages (USA)

```
us_change_future <- new_data(us_change, 8) %>%  
  mutate(Income = mean(us_change$Income))  
forecast(fit, new_data = us_change_future) %>%  
  autoplot(us_change) +  
  labs(x = "Year", y = "Percentage change",  
title = "Forecasts from regression with ARIMA(1,0,2) errors")
```




- Pour prévoir un modèle de régression avec des erreurs ARIMA, nous devons prévoir la partie régression du modèle et la partie ARIMA du modèle, puis combiner les résultats.
- Certains prédictors sont connus à l'avance (par exemple, le temps, les variables muettes).
- Des modèles de prévision séparés peuvent être nécessaires pour d'autres prédictors.
- Les intervalles de prévision ignorent l'incertitude liée à la prévision des prédictors.

■ Demande quotidienne d'électricité




On peut modéliser la demande quotidienne d'électricité en fonction de la température en utilisant une régression quadratique avec des erreurs ARMA.

```
vic_elec_daily %>%  
  ggplot(aes(x = Temperature, y = Demand,  
    colour = Day_Type)) +  
  geom_point() +  
  labs(x = "Maximum temperature",  
    y = "Electricity demand (GW)")
```



■ Demande quotidienne d'électricité

```
vic_elec_daily %>%  
  pivot_longer(c(Demand, Temperature)) %>%  
  ggplot(aes(x = Date, y = value)) + geom_line() +  
  facet_grid(name ~ ., scales = "free_y") + ylab("")
```




■ Demande quotidienne d'électricité

```
fit <- vic_elec_daily %>%  
  model(ARIMA(Demand ~ Temperature + I(Temperature^2) +  
    (Day_Type=="Weekday")))  
report(fit)
```

```
## Series: Demand  
## Model: LM w/ ARIMA(2,1,2)(2,0,0)[7] errors  
##  
## Coefficients:  
##          ar1      ar2      ma1      ma2      sar1      sar2      Tem  
##      -0.1093  0.7226  -0.0182  -0.9381  0.1958  0.417  
## s.e.   0.0779  0.0739   0.0494   0.0493  0.0525  0.057  
##      I(Temperature^2)  Day_Type == "Weekday"TRUE  
##              0.1810                      30.40  
## s.e.              0.0085                      1.33  
##  
## sigma^2 estimated as 44.91:  log likelihood=-1206  
## AIC=2432   AICc=2433   BIC=2471
```

■ Demande quotidienne d'électricité

```
gg_tsresiduals(fit)
```



■ Demande quotidienne d'électricité



```
augment(fit) %>%  
  features(.resid, ljung_box, dof = 9, lag = 14)%>%pull(lb_pva)  
  
## [1] 3.04e-05
```


■ Demande quotidienne d'électricité

```
fit <- vic_elec_daily |>
model(arima = ARIMA(log(Demand) ~ Temperature + I(Temperature
(Day_Type == "Weekday")), stepwise = FALSE,
order_constraint = (p+q <=8 & P+Q <=5)))
report(fit)
```

```
## Series: Demand
## Model: LM w/ ARIMA(5,1,3)(2,0,0)[7] errors
## Transformation: log(Demand)
##
## Coefficients:
##          ar1          ar2          ar3          ar4          ar5          ma1          ma2
##      0.0262    -0.029    0.539    -0.087    0.185    -0.212    -0.141
## s.e.  0.2311     0.148    0.117     0.061    0.071     0.230     0.179
##          sar2 Temperature  I(Temperature^2)  Day_Type == "V
##      0.3866          -0.0311                8e-04
## s.e.  0.0593           0.0004                0e+00
##
## sigma^2 estimated as 0.0008747:  log likelihood=769
## AIC=-1511    AICc=-1510    BIC=-1456
```

■ Demande quotidienne d'électricité

```
gg_tsresiduals(fit)
```



■ Demande quotidienne d'électricité



```
# Forecast one day ahead
vic_next_day <- new_data(vic_elec_daily, 1) |>
  mutate(Temperature = 26, Day_Type = "Holiday")
forecast(fit, vic_next_day)
```

```
## # A tibble: 1 x 6 [1D]
## # Key:           .model [1]
##   .model Date                Demand .mean Temperature Da
##   <chr>   <date>                <dbl> <dbl>         <dbl> <c
## 1 arima  2015-01-01 t(N(5.1, 0.00087)) 163.         26 Ho
```


■ Demande quotidienne d'électricité



```
vic_elec_future <- new_data(vic_elec_daily, 14) |>
  mutate(
    Temperature = 26,
    Holiday = c(TRUE, rep(FALSE, 13)),
    Day_Type = case_when(
      Holiday ~ "Holiday",
      wday(Date) %in% 2:6 ~ "Weekday",
      TRUE ~ "Weekend"
    )
  )
```

■ Demande quotidienne d'électricité

```
forecast(fit, new_data = vic_elec_future) |>  
  autoplot(vic_elec_daily) + labs(y = "GW")
```





RÉGRESSION HARMONIQUE DYNAMIQUE


On peut combiner **des termes de Fourier** avec **des erreurs ARIMA**

Avantages

- Cela permet une saisonnalité de n'importe quelle longueur.
- Pour des données avec plus d'une période saisonnière, on peut inclure des termes de Fourier de différentes fréquences.
- Le motif saisonnier est lisse pour de petites valeurs de K (mais une saisonnalité plus ondulée peut être gérée en augmentant K).
- Les dynamiques à court terme sont facilement gérées avec une simple erreur ARMA.

■ Dépenses pour les repas à l'extérieur

```
aus_cafe <- aus_retail %>% filter(  
  Industry == "Cafes, restaurants and takeaway food services"  
  year(Month) %in% 2004:2018  
) %>% summarise(Turnover = sum(Turnover))  
aus_cafe %>% autoplot(Turnover)
```




■ Dépenses pour les repas à l'extérieur


```
fit <- aus_cafe %>% model(
  `K = 1` = ARIMA(log(Turnover) ~ fourier(K = 1) + PDQ(0, 0, 0),
  `K = 2` = ARIMA(log(Turnover) ~ fourier(K = 2) + PDQ(0, 0, 0),
  `K = 3` = ARIMA(log(Turnover) ~ fourier(K = 3) + PDQ(0, 0, 0),
  `K = 4` = ARIMA(log(Turnover) ~ fourier(K = 4) + PDQ(0, 0, 0),
  `K = 5` = ARIMA(log(Turnover) ~ fourier(K = 5) + PDQ(0, 0, 0),
  `K = 6` = ARIMA(log(Turnover) ~ fourier(K = 6) + PDQ(0, 0, 0),
  glance(fit)
```

.model	sigma2	log_lik	AIC	AICc	BIC
K = 1	0.002	317	-616	-615	-588
K = 2	0.001	362	-700	-698	-661
K = 3	0.001	394	-763	-761	-725
K = 4	0.001	427	-822	-818	-771
K = 5	0.000	474	-919	-917	-875
K = 6	0.000	474	-920	-918	-875


■ Dépenses pour les repas à l'extérieur




■ Dépenses pour les repas à l'extérieur




■ Dépenses pour les repas à l'extérieur




■ Dépenses pour les repas à l'extérieur



■ Dépenses pour les repas à l'extérieur



■ Dépenses pour les repas à l'extérieur




■ Ex : production d'essence hebdomadaire


```
fit <- us_gasoline %>%  
  model(ARIMA(Barrels ~ fourier(K = 13) + PDQ(0,0,0)))  
report(fit)
```

```
## Series: Barrels  
## Model: LM w/ ARIMA(0,1,1) errors  
##  
## Coefficients:  
##          ma1  fourier(K = 13)C1_52  fourier(K = 13)S1_52  
##      -0.8934          -0.1121          -0.2300  
## s.e.   0.0132          0.0123          0.0122  
##      fourier(K = 13)C2_52  fourier(K = 13)S2_52  
##              0.0420              0.0317  
## s.e.         0.0099              0.0099  
##      fourier(K = 13)C3_52  fourier(K = 13)S3_52  
##              0.0832              0.0346  
## s.e.         0.0094              0.0094  
##      fourier(K = 13)C4_52  fourier(K = 13)S4_52  
##              0.0185              0.0398  
## s.e.         0.0092              0.0092  
##      fourier(K = 13)C5_52  fourier(K = 13)S5_52  
##              -0.0315              0.0009
```

■ Ex : production d'essence hebdomadaire

```
forecast(fit, h = "3 years") %>%  
  autoplot(us_gasoline)
```



Three vertical gray bars of varying heights and widths are positioned in the background, creating a stylized 'H' shape. The bars are light gray and have a slightly curved, tapered appearance.

PRÉDICTEURS RETARDÉS

Parfois, un changement dans x_t n'affecte pas y_t de manière instantanée.

Parfois, un changement dans x_t n'affecte pas y_t de manière instantanée.

- y_t = ventes, x_t = publicité
- y_t = débit du cours d'eau, x_t = pluie
- y_t = taille du troupeau, x_t = Nombre animaux de reproduction.

Parfois, un changement dans x_t n'affecte pas y_t de manière instantanée.

- y_t = ventes, x_t = publicité
- y_t = débit du cours d'eau, x_t = pluie
- y_t = taille du troupeau, x_t = Nombre animaux de reproduction.

Le modèle inclut les valeurs présentes et passées de la variable explicative :
 $x_t, x_{t-1}, x_{t-2}, \dots$

$$y_t = a + \gamma_0 x_t + \gamma_1 x_{t-1} + \dots + \gamma_k x_{t-k} + \eta_t$$

où η_t est un processus ARIMA.

Le modèle inclut les valeurs présentes et passées de la variable explicative :
 $x_t, x_{t-1}, x_{t-2}, \dots$

$$y_t = a + \gamma_0 x_t + \gamma_1 x_{t-1} + \dots + \gamma_k x_{t-k} + \eta_t$$

où η_t est un processus ARIMA.

Réécriture

$$\begin{aligned} y_t &= a + (\gamma_0 + \gamma_1 B + \gamma_2 B^2 + \dots + \gamma_k B^k) x_t + \eta_t \\ &= a + \gamma(B) x_t + \eta_t. \end{aligned}$$

Le modèle inclut les valeurs présentes et passées de la variable explicative :
 $x_t, x_{t-1}, x_{t-2}, \dots$

$$y_t = a + \gamma_0 x_t + \gamma_1 x_{t-1} + \dots + \gamma_k x_{t-k} + \eta_t$$

où η_t est un processus ARIMA.

Réécriture

$$\begin{aligned} y_t &= a + (\gamma_0 + \gamma_1 B + \gamma_2 B^2 + \dots + \gamma_k B^k) x_t + \eta_t \\ &= a + \gamma(B) x_t + \eta_t. \end{aligned}$$

- $\gamma(B)$ est appelé une *fonction de transfert* puisque cela décrit la manière dont un changement dans x_t est transféré à y_t .
 - x peut influencer y , mais y n'est pas autorisée à influencer x .

■ Ex : Devis d'assurance et pub. télévisées


insurance %>%

```
pivot_longer(Quotes:TVadverts) %>%
```


```
ggplot(aes(x = Month, y = value)) + geom_line() +
```

```
facet_grid(vars(name), scales = "free_y") +
```

```
labs(y = NULL, title = "Insurance advertising and quotations")
```



■ Ex : Devis d'assurance et pub. télévisées



■ Ex : Devis d'assurance et pub. télévisées



```
fit <- insurance %>%  
  # Restrict data so models use same fitting period  
  mutate(Quotes = c(NA,NA,NA,Quotes[4:40])) %>%  
  # Estimate models  
  model(  
    ARIMA(Quotes ~ pdq(d = 0) + TVadverts),  
    ARIMA(Quotes ~ pdq(d = 0) + TVadverts + lag(TVadverts)),  
    ARIMA(Quotes ~ pdq(d = 0) + TVadverts + lag(TVadverts) +  
      lag(TVadverts, 2)),  
    ARIMA(Quotes ~ pdq(d = 0) + TVadverts + lag(TVadverts) +  
      lag(TVadverts, 2) + lag(TVadverts, 3))  
  )
```

■ Ex : Devis d'assurance et pub. télévisées



```
glance(fit)
```

Lag order	sigma2	log_lik	AIC	AICc	BIC
0	0.265	-28.3	66.6	68.3	75.0
1	0.209	-24.0	58.1	59.9	66.5
2	0.215	-24.0	60.0	62.6	70.2
3	0.206	-22.2	60.3	65.0	73.8

■ Ex : Devis d'assurance et pub. télévisées

```
fit_best <- insurance %>%  
  model(ARIMA(Quotes ~ pdq(d=0) + TVadverts + lag(TVadverts))  
  report(fit_best)
```

```
## Series: Quotes  
## Model: LM w/ ARIMA(1,0,2) errors  
##  
## Coefficients:  
##          ar1      ma1      ma2  TVadverts  lag(TVadverts)  inter  
##          0.512   0.917   0.459      1.2527           0.1464  
## s.e.    0.185   0.205   0.190      0.0588           0.0531  
##  
## sigma^2 estimated as 0.2166:  log likelihood=-23.9  
## AIC=61.9   AICc=65.4   BIC=73.7
```

■ Ex : Devis d'assurance et pub. télévisées

```
fit_best <- insurance %>%  
  model(ARIMA(Quotes ~ pdq(d=0) + TVadverts + lag(TVadverts))  
  report(fit_best)
```


```
## Series: Quotes  
## Model: LM w/ ARIMA(1,0,2) errors  
##  
## Coefficients:  
##          ar1      ma1      ma2  TVadverts  lag(TVadverts)  inter  
##          0.512   0.917   0.459      1.2527           0.1464  
## s.e.    0.185   0.205   0.190      0.0588           0.0531  
##  
## sigma^2 estimated as 0.2166:  log likelihood=-23.9  
## AIC=61.9   AICc=65.4   BIC=73.7
```

$$y_t = 2.155 + 1.253x_t + 0.146x_{t-1} + \eta_t,$$

$$\eta_t = 0.512\eta_{t-1} + \varepsilon_t + 0.917\varepsilon_{t-1} + 0.459\varepsilon_{t-2},$$


■ Ex : Devis d'assurance et publ. télévisées

```
advert_a <- new_data(insurance, 20) %>%  
  mutate(TVadverts = 10)  
forecast(fit_best, advert_a) %>% autoplot(insurance)
```



■ Ex : Devis d'assurance et pub. télévisées

```
advert_b <- new_data(insurance, 20) %>%  
  mutate(TVadverts = 8)  
forecast(fit_best, advert_b) %>% autoplot(insurance)
```



■ Ex : Devis d'assurance et pub. télévisées

```
advert_c <- new_data(insurance, 20) %>%  
  mutate(TVadverts = 6)  
forecast(fit_best, advert_c) %>% autoplot(insurance)
```

