

Le Copilote Financier : un outil d'aide à la décision pour le pilotage des opérations de promotion

Yasmina Saoud — Master MIASHS, Université Paul Valéry Montpellier III

Année universitaire 2025-2026

Note de rédaction. Ce chapitre a été préparé avec l'aide d'un assistant : c'est une base de travail factuelle, à reformuler avant intégration au mémoire. Tous les chiffres proviennent des notebooks exécutés du dépôt **MemoireM2S2** (branche principale).

Ce chapitre présente le projet Data Science annoncé dans mon mémoire de mi-parcours : le « Copilote Financier », un outil d'aide à la décision construit sur les données de gestion du groupe Angelotti. Le dépôt du projet contient davantage que ce qui est raconté ici : sept notebooks y déroulent, pour les besoins de la validation académique, l'ensemble des méthodes du Master, y compris des vérifications d'implémentation et des comparaisons de modèles sans enjeu décisionnel. Ce chapitre fait un choix assumé : raconter le travail qui sert la décision de l'entreprise, et réduire le reste à ce qu'il est — des garde-fous. Le fil conducteur du projet tient en une phrase : sur un jeu de données de cette taille, un petit nombre de modèles simples et bien compris vaut mieux qu'un grand appareillage, et le projet en apporte plusieurs preuves chiffrées.

Contexte

Le groupe Angelotti conçoit, finance et commercialise des programmes immobiliers en Occitanie et en région PACA. Chaque opération de promotion est portée par une société dédiée et vit sur un cycle long : un budget est arrêté à l'engagement, puis le chantier et la commercialisation le font dériver — appels d'offres plus chers qu'anticipé, désistements, rythme de vente ralenti par la conjoncture. La direction financière pilote ces dérives opération par opération, sur tableurs, sans vision transverse.

Problème métier

Trois questions structurent les revues de gestion. Quelles opérations examiner en priorité, parce que leur marge d'engagement dérive — sur quels postes, pour combien d'euros ? Quel rythme de vente budgéter pour 2026, alors que la période récente a montré la sensibilité de la demande au coût du crédit (le taux moyen des crédits habitat est passé d'environ 1,1 % à un pic de 3,6 % fin 2023, avant de refluer vers 3,1 % mi-2026, et le rythme groupe est tombé d'environ 150 à moins de 115 réservations par mois en 2023) ? Et quels lots du stock repricer, sachant que 45 % des 2 157 désistements enregistrés ont pour motif un problème de financement ou un refus de prêt, et que les remises sont aujourd'hui accordées au cas par cas ? C'est un problème de contrôle de gestion outillé par la donnée, pas un problème de machine learning à grande échelle : 267 opérations, quatre exports Excel totalisant 32 Mo, une photographie à date.

Besoins par axe et exigences non fonctionnelles

Les besoins ont été formalisés en trois axes, plus un axe transverse :

- **Axe A — risque de marge** : un score de tri des opérations par risque de dérive, le détail en euros des postes déjà en dépassement, et la comparaison d'une opération à ses semblables ;
- **Axe B — vitesse d'écoulement** : quantifier l'effet du taux d'intérêt sur le rythme de réservation, séparé de l'effet propre de chaque programme, et simuler des scénarios de taux 2026 ;
- **Axe C — prix** : estimer un prix de marché par lot, signaler le stock hors marché, et proposer une règle de remise argumentée ;
- **Axe transverse** : tirer des signaux simples des commentaires de vente et de la structure du réseau de vendeurs.

Quatre exigences non fonctionnelles ont cadré le travail : la reproductibilité (tout se reconstruit depuis les exports bruts par un seul script), l'interprétabilité (chaque score est accompagné des variables qui le déterminent), la confidentialité (aucune donnée nominative de client affichée ni modélisée) et l'acceptation d'un petit échantillon — à cette taille, des modèles simples validés en validation croisée, pas d'architectures complexes.

Objectif du dashboard

Le livrable final est une application web pour la direction financière, qui traduit les modèles en décisions. Un retour de l'entreprise en cours de projet a imposé une clarification utile : la première version de l'interface, trop marquée par le vocabulaire de la modélisation, a été entièrement réécrite en langage de gestion — niveaux d'alerte, dépassements en euros, prix de marché estimé — et son périmètre restreint aux 147 opérations de promotion immobilière, l'aménagement foncier relevant d'une logique économique différente. Les métriques de validation restent dans les notebooks ; l'écran ne montre que ce qui se décide.

Données disponibles

Données internes

Quatre exports du système de gestion constituent le point de départ :

Export	Grain	Volumétrie	Usage
Grille de Prix Avec Désistements	lot × dossier de vente	16 467 lignes, 196 opérations	ventes, prix, dates, désistements
Budget & EFR	poste analytique	65 000 lignes, 267 opérations	budget, engagé, facturé par poste
A_DM_BUDGET_MONTANT_BUDGET_LIVE	poste budgétaire	79 106 lignes	contrôle de cohérence
06_Informations Lots	dossier désisté	2 164 lignes	détail des désistements

Comprendre ces exports a demandé plus de temps que les modéliser, et c'est normal : c'est là que se jouait la fiabilité de tout le reste. Trois constats l'illustrent. Le fichier « 06_Informations Lots », malgré son nom, ne contient que des dossiers désistés (2 157 « Désisté », 7 « Résolution de vente ») : la table maîtresse des lots est en réalité la grille de prix. Le fichier « Budget & EFR » affiche 65 000 lignes, un chiffre rond qui évoquait une troncature ; la réconciliation avec le fichier LIVE a montré le

contraire — totaux identiques à l’euro près sur les 118 opérations jointes (écart médian nul), les 65 000 lignes se décomposant en 64 788 postes de détail et 212 lignes de synthèse. Enfin, le nettoyage a traité les défauts classiques : natures de lot harmonisées (« appt », « Appartement », « stat »... regroupés en huit familles), doublons orthographiques de communes fusionnés (91 orthographes pour 90 communes), surfaces et prix à zéro convertis en valeurs manquantes plutôt que traités comme des zéros réels.

Données externes

Trois sources publiques, récupérées par script pour rester re-téléchargeables : le taux moyen des crédits habitat en France (série mensuelle de la Banque centrale européenne, 2015 à 2026), l’indicateur de confiance des ménages (Eurostat, 2015 à 2026) et un référentiel des 90 communes d’implantation (population, coordonnées, via l’API publique geo.api.gouv.fr), enrichi d’une distance au littoral calculée.

Architecture technique

L’architecture tient en une chaîne courte et entièrement rejouable : les quatre exports et les sources externes alimentent un script de nettoyage, qui charge une base **SQLite** en schéma en étoile — trois dimensions (opérations, communes, conjoncture mensuelle), quatre tables de faits (64 788 lignes budgétaires, 14 123 lots, 14 428 dossiers de vente, 2 164 désistements) — sur laquelle s’appuient les notebooks et l’application. Trois vues SQL y encapsulent les calculs partagés : marge budgétée contre engagée par opération, réservations par opération et par mois, état du stock. C’est un choix structurant : la définition de la marge est écrite une seule fois, et les notebooks comme la plateforme consomment la même. La commande `python src/base_sql.py` reconstruit l’ensemble en quelques secondes ; les notebooks sont générés et ré-exécutés de bout en bout par des scripts versionnés, de sorte que chaque chiffre de ce chapitre correspond à une cellule réellement exécutée.

Notebooks et résultats

Exploration et nettoyage des données brutes

Au-delà du nettoyage décrit en section 2, l’exploration a produit deux résultats qui ont orienté la modélisation.

Le premier concerne les prix : le prix au mètre carré des appartements est fortement asymétrique (coefficient d’asymétrie de 19,2), mais devient proche d’une loi normale après passage au logarithme (asymétrie 0,39, diagramme quantile-quantile presque rectiligne, Figure 1). L’axe C modélisera donc le logarithme du prix.

Le second est une leçon de méthode qui a évité une conclusion fausse. La corrélation entre les réservations mensuelles du groupe et le taux des crédits habitat est quasi nulle (+0,07) : à première vue, la conjoncture n’expliquerait rien. En réalité, la série brute est brouillée par la croissance du portefeuille — le nombre d’opérations en commercialisation a fortement augmenté, ce qui soutient le volume total même quand la demande par programme s’effondre. Rapportées au nombre d’opérations actives, les réservations racontent l’inverse (Figure 2) : la corrélation passe à -0,34 avec le taux et +0,44 avec la confiance des ménages. Tout l’axe B repose sur cette correction.




Figure 1: Figure 1 — Prix au m² des appartements : distribution brute et après transformation logarithmique (notebook 00).




Figure 2: Figure 2 — Intensité de vente (réservations par opération active) : l'effet de la remontée des taux apparaît une fois l'effet portefeuille neutralisé (notebook 00).

SQL et Spark

Le vrai livrable de cette étape est la base SQL décrite en section 3 : les vues métier partagées, les index, et un contrôle croisé des agrégats qui retrouve les mêmes totaux par deux moteurs indépendants (1 561,8 M€ de dépenses budgétées, 1 754,8 M€ de recettes, à l'arrondi près).

Spark a été évalué comme piste de montée en charge, avec une conclusion négative assumée : sur notre volumétrie (64 788 lignes, 9 Mo en mémoire), l'agrégation chronométrée est environ cinquante fois plus lente qu'avec pandas (rapport mesuré de 58, après 24 secondes de démarrage de la machine virtuelle Java ; une exécution antérieure donnait 28 — le chiffre varie avec la machine, la conclusion non). SQLite et pandas sont la bonne architecture à cette échelle ; le chemin de montée en charge existe si le périmètre s'étendait un jour au groupe Nexity entier, et c'est tout ce qu'il fallait établir.

Axe A

La difficulté de l'axe A était moins le modèle que la **définition de la cible**. Les exports sont une photographie à date, sans historique des révisions budgétaires : j'ai donc mesuré la dérive par les dépassements déjà engagés, poste par poste — les dépenses à terminaison sont estimées par le maximum de l'engagé et du budget de chaque poste (« un dépassement engagé est acquis, le budget restant sera dépensé »), et la variation de marge rapporte la marge ainsi recalculée à la marge budgétée. Les variables explicatives n'utilisent que le budget initial et les signaux commerciaux, jamais l'engagé ni le facturé qui définissent la cible : sans cette précaution, le modèle aurait « prédit » sa propre définition.

Sur le périmètre exploitable — 123 opérations engagées à au moins 60 %, de marge budgétée supérieure à 50 k€ — plus d'un tiers des opérations (36,6 %) n'a aucun dépassement engagé, mais 28 % franchissent le seuil de dérive matérielle fixé à 2 % de la marge, avec deux cas extrêmes au-delà de la moitié de la marge budgétée (Figure 3).




Figure 3: Figure 3 — Distribution de la variation de marge « committée » sur les 123 opérations du périmètre, et seuil de dérive matérielle à -2 % (notebook 03).

Il faut le dire simplement : la partie la plus utile de cet axe pour l'entreprise n'est pas un modèle appris, c'est le **tableau descriptif des dépassements engagés en euros, par opération et par poste**, calculé en SQL pur — c'est lui qui alimente la page « Alertes marge » de la plateforme. La modélisation vient en complément, comme score de tri : une régression du taux de variation atteint un R^2 de 0,08 sur l'échantillon test — résultat modeste et honnête, la structure du budget initial prédispose à la dérive mais ne la détermine pas, l'aléa de chantier fait le reste — et une

classification des opérations « à risque » (dérive au-delà de 2 %) atteint un F1 de l'ordre de 0,30 à 0,34 en validation croisée selon le modèle (régression logistique 0,28, SVM 0,30, arbre 0,34, forêt aléatoire 0,31), contre 0 pour la base de référence qui ne détecte rien. À 123 observations, ces écarts entre modèles sont dans le bruit de la validation croisée : j'ai retenu un modèle interprétable (la forêt, dont les probabilités alimentent les niveaux d'alerte), sans prétendre que le tournoi de modèles départageait quoi que ce soit — un perceptron multicouche testé en contrôle confirme d'ailleurs le sur-ajustement attendu à cette taille (F1 de 0,91 en apprentissage contre 0,26 en validation). Le système est un outil de hiérarchisation de l'attention, pas un oracle.

Axe B

C'est la section la plus solide du projet, et celle dont le résultat sert le plus directement la décision.

Le rythme de vente est modélisé sur le panel opération $\times$ mois : 3 230 observations sur 160 opérations, en réintroduisant les mois à zéro réservation entre la première et la dernière vente de chaque programme (les omettre surestimerait le rythme). Un modèle à effets aléatoires y sépare ce qui revient à l'opération de ce qui revient à la conjoncture : les deux tiers de la variance tiennent au programme lui-même (coefficient de corrélation intraclasse de 0,66), et l'effet du taux d'intérêt est fortement significatif — **une hausse d'un point de taux réduit les réservations mensuelles d'environ 19 %** (coefficient -0,216, p-value inférieure à 10^{-15}). La régression naïve qui ignore la structure en panel surestime cet effet ; le modèle à effets aléatoires le corrige.

Un garde-fou mérite d'être raconté, parce qu'il fonde la construction des scénarios : sur la série agrégée du groupe (114 mois), une régression dynamique à erreurs ARIMA, menée dans les règles (résidus assimilables à un bruit blanc d'abord, sélection par AICc ensuite), ne parvient pas à identifier l'effet du taux — le coefficient y est indiscernable de zéro (p-value 0,82), car les variations du taux sont trop lentes pour une seule série de cette longueur. Ce résultat négatif dit deux choses : la significativité du panel n'est pas un artefact de régression fallacieuse, et les scénarios doivent combiner les deux modèles — la série temporelle fournit la trajectoire de référence (dynamique et saisonnalité), et l'élasticité du panel traduit chaque scénario de taux en effet sur le rythme. Sur cette base (Figure 4), une détente à 2,5 % fin 2026 redonnerait environ +6 % de rythme en moyenne sur douze mois ; une remontée à 3,5 % en retirerait 3 %.




Figure 4: Figure 4 — Prévision d'intensité de vente à douze mois sous trois scénarios de taux 2026, avec intervalle à 80 % (notebook 04).

Enfin, à l'échelle d'un programme, la courbe des réservations cumulées suit une forme en S ajustée par une fonction logistique à trois paramètres : sur les 28 opérations terminées du périmètre, cet ajustement bat la droite dans 25 cas (Figure 5) et fournit un indicateur directement utile à la trésorerie — le délai d'atteinte de 90 % du potentiel, de médiane proche de vingt mois. Sa limite est connue et vérifiée : en début de commercialisation, le potentiel n'est pas identifiable, l'outil n'est donc proposé que sur les programmes avancés.




Figure 5: Figure 5 — Réservations cumulées et courbes logistiques ajustées sur quatre opérations terminées, avec le repère des 90 % du potentiel (notebook 04).

Axe C

Le modèle de prix est volontairement le plus simple qui fonctionne : une régression linéaire du logarithme du prix au mètre carré des 5 064 appartements transigés depuis 2016, sur leurs caractéristiques (surface, étage, exposition, type de produit, agence, commune, littoral) et leur année de réservation. Elle explique 88,6 % de la variance sur l'échantillon test, avec une erreur type d'environ 11 % sur le prix, et ses coefficients se lisent comme des prix implicites : prime d'étage (+6 %), prime d'exposition sud, décote de 63 % du logement social (prix réglementés), et un effet millésime d'environ +19 points entre 2016 et 2023 suivi d'un plateau (Figure 6) — les prix du neuf n'ont pas baissé avec la remontée des taux, c'est le volume qui s'est ajusté, en parfaite cohérence avec l'axe B. Une variante régularisée a été testée sans gain : avec cinq mille observations pour une trentaine de coefficients, il n'y avait rien à stabiliser.

Appliqué aux 127 appartements en stock, le modèle sert de détecteur : 103 sont dans le marché, 8 au-dessus et 16 en dessous du prix estimé, au seuil d'une erreur type (Figure 7).

La recommandation de remise est ensuite posée comme une petite optimisation sous contrainte : maximiser le revenu attendu à douze mois d'une opération en ajustant chaque prix dans des bornes




Figure 6: Figure 6 — Effet millésime du modèle de prix (prime par année de réservation, référence 2016) (notebook 05).




Figure 7: Figure 7 — Stock d'appartements : prix grille contre prix de marché estimé, bande à plus ou moins une erreur type (notebook 05).

commerciales (-10 à +5 %), sous un objectif d'accélération de l'écoulement, la demande réagissant au prix avec une élasticité fixée à -1. Ce paramètre est la fragilité assumée de l'axe : l'estimation interne (-0,81) a le bon signe mais n'est pas significative sur 95 opérations, et la valeur retenue vient de la littérature sur le logement neuf. Le résultat, lui, est robuste et contre-intuitif : à cette élasticité, la remise optimale est **uniforme en euros** sur tous les lots — environ 23 k€ par lot sur l'opération d'application — donc proportionnellement plus forte sur les petits lots, à l'inverse de la pratique actuelle des remises au cas par cas. Sur l'opération test (18 appartements en stock), viser +8 % d'écoulement déplace le volume attendu de 6,8 à 7,4 lots pour un revenu quasi inchangé (-0,3 %) : l'intérêt est la vitesse et l'économie de frais de portage, que l'objectif ne compte pas.

Signaux faibles (texte et réseau)

Trois constats simples, obtenus avec des moyens simples, complètent le dispositif. D'abord, un moteur de recherche par similarité sur les 9 688 commentaires libres de vente : une requête comme « refus de prêt banque » ou « remise prix hors pack » remonte les dossiers concernés — un outil d'audit des remises non structurées réellement utilisable. Ensuite, le profil des motifs de désistement par agence révèle un problème de qualité de saisie plus qu'un fait commercial : à Salon-de-Provence, 90 % des motifs sont enregistrés en « Autres motifs », ce qui rend les désistements de cette agence inanalysables tant que la saisie n'est pas fiabilisée. Enfin, la structure du réseau de vente est très concentrée : deux acteurs — le réseau interne et un prescripteur externe — portent 51,6 % des dossiers attribués, avec des taux de désistement allant du simple au triple (9 % pour le réseau interne, 29,6 % pour le prescripteur externe) ; chaque commission versée sur un dossier qui n'aboutit pas est une dépense sans recette. Une tentative de prédire le désistement à partir du seul texte du commentaire a aussi été menée, avec un contrôle de fuite soigneux : elle plafonne à un F1 de 0,34 — le texte seul ne suffit pas, et il est traité comme signal d'appoint.

Plateforme Streamlit

L'application finale est la meilleure réponse au risque de sur-complexité : ce qui est livré au métier est simple. Cinq pages, périmètre restreint aux 147 opérations de promotion, aucun terme de modélisation à l'écran.

La **Vue d'ensemble** (Figure 8) donne la situation en quelques secondes : 147 opérations suivies, 10 en alerte et 2 à surveiller sur les 68 opérations en cours suffisamment engagées, 421 lots principaux en stock, un rythme récent de 4,8 réservations par opération et par mois pour un taux de crédit à 3,11 %. La page **Alertes marge** (Figure 9) classe les opérations par niveau d'alerte — le score de l'axe A traduit en trois niveaux — et surtout affiche, pour chaque opération, les dépassements déjà engagés en euros et les postes concernés : c'est la partie la plus consultée, et elle repose sur du SQL, pas sur un modèle. La page **Rythme de vente** transpose l'axe B en simulateur : un curseur de taux 2026 produit une phrase de résultat fondée sur l'élasticité du panel, et la trajectoire d'écoulement de chaque programme donne son délai estimé. La page **Pilotage des prix** affiche le diagnostic du stock et la grille d'ajustement recommandée sous un objectif d'accélération choisi au curseur. La page **Qualité commerciale** reprend les signaux faibles, alerte de saisie comprise.

Chaque page a été vérifiée par le cadre de test de Streamlit (exécution sans exception, y compris aux bornes des curseurs et sur les sélections vides), et l'ensemble se reconstruit depuis les exports bruts.




Figure 8: Figure 8 — Plateforme, page « Vue d'ensemble ».

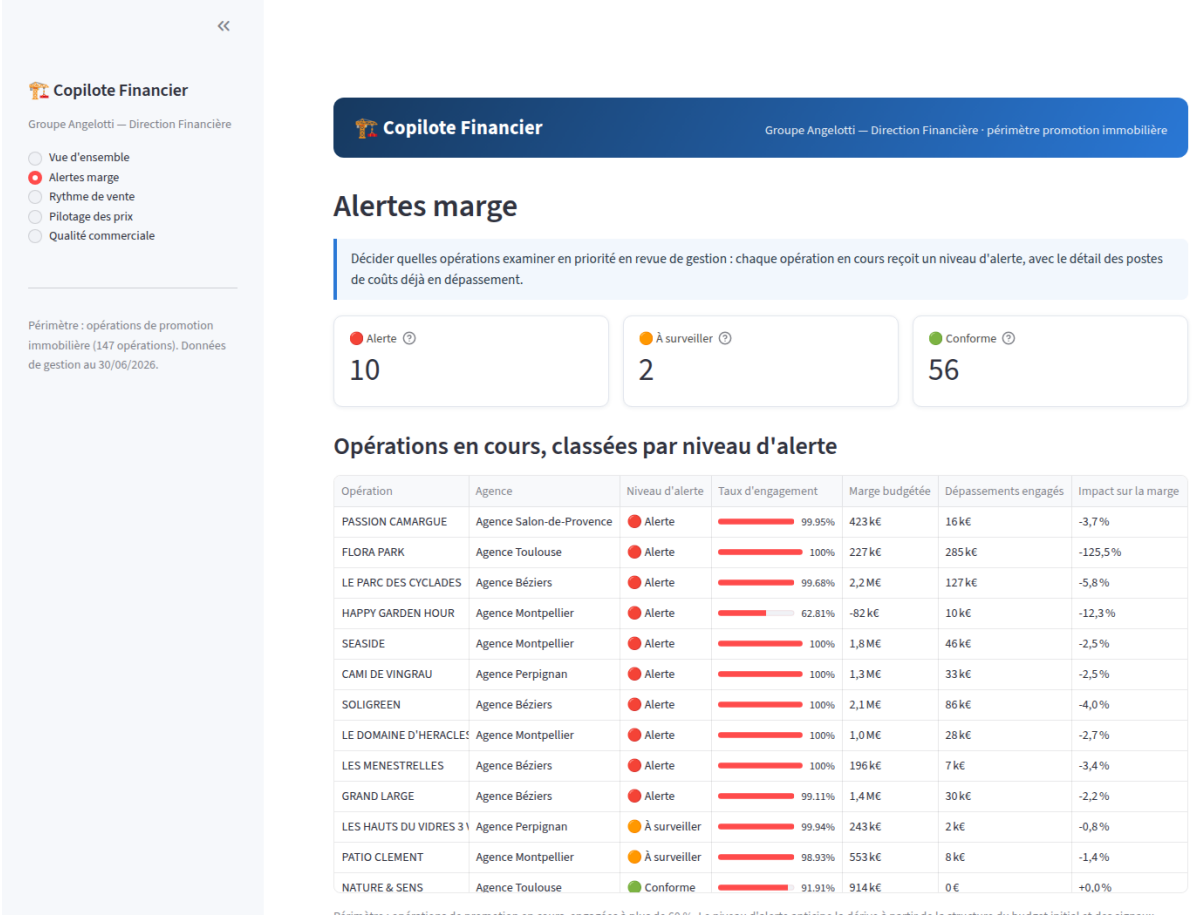


Figure 9: Figure 9 — Plateforme, page « Alertes marge » : niveaux d’alerte et dépassements engagés en euros.

Périmètre et limites

La limite principale est structurelle et commande la suite du projet : les données budgétaires sont une photographie à date, sans historique des révisions. C'est elle qui plafonne l'axe A (un R^2 de 0,08 en régression, des F1 de l'ordre de 0,3 en classification) : on ne peut pas apprendre la dynamique d'une dérive sur une image fixe. Ma première recommandation à l'entreprise est donc d'**historiser les exports mensuels** dans le nouvel ERP — au bout d'un an, le score statique deviendra un vrai suivi de trajectoire.

Les autres limites sont assumées et documentées : l'échantillon de l'axe A est petit (123 opérations) et les écarts entre modèles y sont indiscernables, d'où le choix d'un modèle interprétable unique ; l'élasticité de l'axe C n'a pas pu être estimée significativement en interne et vient de la littérature — les recommandations de prix sont des aides à la décision, non opposables, et la grille reste sous le contrôle de la direction commerciale ; les intervalles de prévision de l'axe B ignorent l'incertitude sur les taux futurs eux-mêmes, raison pour laquelle la plateforme présente des scénarios plutôt qu'une prévision unique ; le texte des commentaires est un signal d'appoint, pas un prédicteur. Enfin, la plateforme couvre la promotion (147 opérations) et exclut l'aménagement foncier, dont la logique économique justifierait un traitement dédié ; les notebooks conservent les 267 opérations, et la frontière entre les deux activités y ressort d'ailleurs d'elle-même dès l'analyse exploratoire — validation involontaire du choix de périmètre.