



UFR 6

Université Paul Valéry, Montpellier III

Mémoire de fin d'études

La structure de la donnée commande ce que la modélisation peut en tirer

Reprise de données, reporting et aide à la décision au sein du groupe Angelotti

Présenté par : **SAOUD Yasmina**

Master MIAHS – Année universitaire 2025-2026

Septembre 2026

En collaboration avec : **Holding SPA, Groupe Angelotti**

Tutrice en entreprise : **Mme Cruanas**

Tutrice universitaire : **Mme Trottier**

Résumé :

Reprise des données vers le nouvel ERP SPO, maintien du système décisionnel et projet de Data Science au service de la direction financière du groupe Angelotti.

Mots-clés :

Ingénierie des données, migration d'ERP, interfaces de programmation, déduplication, reporting, aide à la décision

Remerciements

Je souhaite exprimer ma sincère gratitude à toutes les personnes qui ont contribué à mon intégration et à ma progression professionnelle tout au long de mon alternance au sein de la Holding SPA du groupe Angelotti.

En premier lieu, je remercie chaleureusement ma tutrice en entreprise, Sabine Cruanas, pour son accompagnement constant, sa bienveillance et le partage de ses connaissances. Son expertise et son soutien ont été déterminants dans ma montée en compétences, tant sur le plan technique que méthodologique.

Je tiens également à remercier Mme Trottier, ma tutrice universitaire, pour son suivi rigoureux et ses conseils avisés. Je remercie aussi l'ensemble des équipes d'Angelotti avec lesquelles j'ai collaboré, en particulier la direction financière et les équipes commerciales, dont la disponibilité et les retours constructifs ont été essentiels pour adapter mes réalisations aux besoins concrets de l'entreprise. C'est en écoutant leurs objections que la plupart de mes livrables ont pris leur forme définitive.

Enfin, je remercie le groupe Angelotti pour m'avoir offert cette opportunité d'alternance dans un environnement professionnel enrichissant, ainsi que mon université et l'équipe pédagogique du Master MIASHS pour leur accompagnement tout au long de ce parcours. Merci à toutes et à tous pour votre confiance et votre soutien.

Résumé

Ce mémoire présente les travaux que j’ai conduits durant ma deuxième année de Master MIASHS, en alternance au sein de la Holding SPA du groupe Angelotti, promoteur-aménageur implanté en Occitanie et en région PACA. L’année a été dominée par une transformation structurante du système d’information : le remplacement de l’ERP historique Grimmo par la solution SPO, éditée par Salvia.

Le premier semestre a été celui de l’ingénierie des données. J’y ai conçu et industrialisé la reprise des données opérationnelles vers le nouvel ERP, sur un périmètre de 283 opérations immobilières, en m’appuyant sur les interfaces de programmation de l’éditeur. J’y expose les difficultés algorithmiques rencontrées, notamment la gestion des identifiants dynamiques et du versionnement des données budgétaires, ainsi que la stratégie de déploiement en « coquilles vides » adoptée pour garantir la continuité de la facturation. En parallèle, j’ai assuré le maintien du système décisionnel et participé au déploiement du Single Sign-On sur deux périmètres du groupe.

Le second semestre a prolongé ce travail de structure, puis l’a valorisé. J’ai d’abord conduit la reprise des tiers, c’est-à-dire des clients acquéreurs, en concevant une chaîne de traitement entièrement pilotée par formules qui a permis de créer 1 434 tiers dans SPO à partir de 1 602 lignes brutes, sans doublon détecté par les trois clés d’unicité retenues. J’ai ensuite mené de bout en bout un projet de Data Science, le « Copilote Financier », qui outille la direction financière sur trois questions de gestion : le risque de dérive des marges, le rythme d’écoulement des programmes et le pilotage des prix du stock.

Ce mémoire relit ensuite ces quatre missions transversalement, sous l’angle de la conduite de projet, des technologies et des méthodes employées, des régimes de preuve mobilisés pour évaluer chaque livrable et des difficultés rencontrées.

De cette année, il tire une thèse qu’il s’attache à démontrer plutôt qu’à énoncer : la structure de la donnée commande ce que la modélisation peut en tirer. Il se termine par une réflexion sur le métier de data scientist tel que je l’ai pratiqué, et sur le projet professionnel qui en découle.

Table des matières

Remerciements	i
Glossaire des termes immobiliers	v
Liste des figures	vii
Introduction	1
1 La reprise des données vers SPO : des opérations aux tiers	3
1.1 Ce que le changement d'ERP imposait	4
1.2 La migration des opérations	5
1.2.1 Méthode et industrialisation des flux	5
1.2.2 Deux contraintes de l'ERP, et la documentation qui en est sortie . .	5
1.2.3 Le déploiement en « coquilles vides » et le bilan du semestre	6
1.3 La reprise des tiers	6
1.3.1 Contexte et enjeux de la reprise des tiers	6
1.3.2 Conception du fichier de travail : une chaîne de traitement pilotée par formules	7
1.3.3 Les trois mécanismes algorithmiques	9
1.3.4 De la préparation à l'injection : procédure et contraintes techniques	11
1.3.5 Traitement des cas particuliers et arbitrages	12
1.3.6 Bilan de l'import et points de vigilance pour la suite	13
1.4 Ce que ces deux reprises ont en commun	14
2 Reporting et missions SI transverses	15
2.1 Le maintien opérationnel du reporting	16
2.2 Le déploiement du Single Sign-On	17
2.3 Ce que les missions filées coûtent et ce qu'elles rapportent	17
3 Le Copilote Financier	19
3.1 Contexte	20
3.1.1 Problème métier	20
3.1.2 Objectifs du dashboard	21
3.2 Données disponibles	22
3.2.1 Données internes	22
3.2.2 Données externes	22

3.3	Architecture technique	23
3.4	Notebooks et résultats	23
3.4.1	Exploration et nettoyage des données brutes	23
3.4.2	SQL et Spark	24
3.4.3	Axe A : risque de dérive de marge	25
3.4.4	Axe B : vitesse d'écoulement	26
3.4.5	Axe C : prix du stock	27
3.4.6	Signaux faibles (texte et réseau)	28
3.5	Plateforme Streamlit	28
3.6	Périmètre et limites	30
3.7	Méthode, évaluation et limites du projet	30
3.8	Conclusion du chapitre	31
4	Réflexion sur le métier, perspectives et projet professionnel	32
4.1	Réflexion sur le métier	33
4.2	Perspectives et projet professionnel	36
	Conclusion	37
	Bibliographie	38

Glossaire

Terme	Définition
Acte de vente	Document légal qui officialise la vente d'un bien immobilier entre un vendeur et un acquéreur.
ADV	Dossier de vente lié à un lot immobilier, ouvert lors d'une réservation et suivi jusqu'à l'acte de vente. Par extension, désigne dans nos extractions l'acquéreur principal du dossier.
Aménagement foncier	Opération qui consiste à diviser un terrain en plusieurs lots viabilisés, destinés à la vente pour la construction.
API	Interface de programmation applicative, qui permet à deux logiciels d'échanger des données sans passer par leur interface utilisateur.
CRM	<i>Customer Relationship Management</i> , outil de gestion de la relation client. Chez Angelotti, il s'agit de Vadimm.
Dashboard	Tableau de bord. Le mémoire emploie le terme au chapitre 5 pour désigner le livrable tel que la direction financière l'a demandé ; le corps du texte parle ensuite d'application web ou de plateforme.
Désistement	Renoncement d'un acquéreur à une réservation avant l'acte de vente.
DirectAPI	Module de l'éditeur Salvia permettant d'injecter dans l'ERP des fichiers plats, sans passer par la saisie manuelle.
EFR	État Financier de Référence, l'un des exports budgétaires du système de gestion, qui donne pour chaque poste le budget, l'engagé et le facturé.
ERP	<i>Enterprise Resource Planning</i> , progiciel de gestion intégré couvrant l'ensemble des processus de l'entreprise.
Fiabilisation des données	Ensemble des vérifications et corrections visant à garantir la cohérence et la justesse des données.
GED	Gestion Électronique des Documents.
Grimmo	ERP métier historique du groupe, remplacé cette année par SPO.
Lot	Terrain ou logement mis en vente, issu d'un découpage foncier ou d'un programme immobilier.
Macro-lot	Ensemble de lots vendus groupés, souvent destiné à un promoteur ou investisseur pour un projet plus large.
MyReport	Outil décisionnel du groupe, qui requête les bases de données sources et produit les tableaux de bord des services.
Promotion immobilière	Activité consistant à concevoir, financer, construire et commercialiser des logements ou bâtiments neufs.

Terme	Définition
Reporting	Création de tableaux de bord ou d'indicateurs à partir des données de gestion, souvent automatisée.
Salvia	Éditeur de logiciels spécialisés dans la gestion immobilière, dont SPO.
SPO	Suivi des Programmes Opérationnels, l'ERP métier qui remplace Grimmo depuis cette année.
SSO	<i>Single Sign-On</i> , authentification unique donnant accès à plusieurs applications.
Surface habitable	Surface mesurée en mètres carrés, utilisée pour évaluer la taille d'un lot et estimer son prix.
Tiers	Dans SPO, entité désignant un client, une société ou un partenaire, à laquelle sont rattachés des rôles, des adresses et des coordonnées.
Tranche	Subdivision d'une opération immobilière, distinguée selon qu'elle relève des travaux ou de la commercialisation.

Table des figures

1.1	Les outils du système d'information et la circulation de la donnée	4
1.2	La séquence d'injection imposée par l'intégrité référentielle de l'ERP	6
1.3	La chaîne de traitement à trois étages du fichier de travail	8
1.4	De 1 602 lignes de départ à 1 434 tiers créés : l'effet des deux filtres successifs	10
1.5	Répartition des 1 434 tiers créés selon leur nature	13
2.1	La règle de facturation juridique traduite en calcul de rang, exécuté à chaque génération du tableau	16
3.1	Prix au mètre carré des appartements : distribution brute et après trans- formation logarithmique	24
3.2	Intensité de vente, mesurée en réservations par opération active : l'effet de la remontée des taux apparaît une fois l'effet de portefeuille neutralisé . . .	24
3.3	Distribution de la variation de marge « committée » sur les 123 opérations du périmètre, et seuil de dérive matérielle à -2 %	25
3.4	Prévision d'intensité de vente à douze mois sous trois scénarios de taux 2026, avec intervalle à 80 %	26
3.5	Réservations cumulées et courbes logistiques ajustées sur quatre opérations terminées, avec le repère des 90 % du potentiel	27
3.6	Plateforme, page « Vue d'ensemble »	29
3.7	Plateforme, page « Alertes marge » : niveaux d'alerte et dépassements engagés en euros	29
4.1	Les trois régimes de preuve employés selon la nature du livrable	35

Introduction

Le groupe Angelotti est un acteur de l'aménagement et de la promotion immobilière implanté en Occitanie et en région PACA. Ces deux métiers n'ont pas la même logique économique : dans l'aménagement, la valeur naît de la transformation du foncier ; dans la promotion, de la construction. Ils produisent deux structures de coûts et deux rythmes de commercialisation différents, et cette frontière ressortira d'elle-même de l'analyse exploratoire du chapitre 3. Chaque opération étant par ailleurs portée par une société dédiée, le suivi financier est nativement cloisonné et toute vision transverse doit être reconstruite.

Une opération vit sur un cycle qui se compte en années. Un budget est arrêté à l'engagement, puis le chantier et la commercialisation le font dériver. Cette dérive est le fonctionnement normal du métier ; ce qui pose problème, c'est de la mesurer à temps, car sur une marge de quelques centaines de milliers d'euros, quelques mois de retard suffisent à transformer un ajustement en perte.

À mon arrivée en deuxième année, le système d'information reposait sur trois outils — **Grimmo**, l'ERP métier historique, pour la gestion des opérations ; **Vadimm**, le CRM, pour la relation commerciale ; **MyReport**, l'outil décisionnel, pour les tableaux de bord — et sur une quatrième couche moins visible, **les tableurs**, qui faisaient le lien partout où les trois premiers ne se parlaient pas.

Le contexte data de mes missions se résume alors à un paradoxe que j'ai mis plusieurs mois à formuler : l'entreprise ne manquait pas de données. Elle disposait de l'historique complet de ses opérations, ventes, désistements et budgets sur plusieurs années. Ce qui manquait, c'était la possibilité de s'en servir, et trois obstacles se cumulaient. L'**absence d'identifiant partagé** d'abord : un acquéreur du CRM et un tiers de l'ERP ne se reconnaissent pas, et les rapprocher suppose de reconstruire une clé d'identité. L'**absence de définition partagée** ensuite : la marge d'une opération peut se calculer sur le budget, sur l'engagé ou sur le facturé, et tant que la définition n'est écrite nulle part, chaque tableau de bord porte implicitement la sienne, deux services pouvant afficher deux chiffres différents sans que ni l'un ni l'autre ait tort. L'**absence de profondeur temporelle** enfin : les exports du système de gestion disent où en est un budget aujourd'hui, pas comment il y est arrivé. Ces trois obstacles ont un point commun : aucun ne relève de la modélisation. Ce sont des problèmes de structure, et ils se règlent avant tout modèle.

C'est dans ce décor que s'inscrit mon année. Après une première année d'alternance consacrée à la migration du CRM Vadimm, ma deuxième année de Master MIASHS au sein de la Holding SPA a coïncidé avec l'étape la plus lourde de la modernisation du système d'information : la refonte complète de l'ERP métier, passant de Grimmo à la solution SPO éditée par Salvia. Un changement d'ERP n'est pas un changement d'outil,

c'est un changement de modèle de données : les objets ne portent plus les mêmes noms, ne s'articulent plus de la même façon et n'acceptent plus les mêmes valeurs. Ce changement d'échelle m'a conduit d'un rôle d'assistance opérationnelle vers des missions d'ingénierie, centrées sur l'interopérabilité des systèmes.

Rattachée à la Holding SPA, j'ai travaillé au contact direct des services métiers — direction financière, service juridique, équipes commerciales — tout en intervenant sur les outils du système d'information. Cette position intermédiaire a une conséquence pratique constante : la formulation du besoin fait partie du travail. Un service ne demande presque jamais un livrable technique ; il décrit une gêne, un tableau qu'il refait à la main chaque mois, une question à laquelle il ne sait pas répondre.

Ce mémoire présente les travaux réalisés durant cette année, du premier jour de la migration jusqu'à la livraison d'une application d'aide à la décision. Il témoigne d'un mouvement en deux temps : le passage de la Data Science exploratoire au Data Engineering appliqué, puis le retour à la modélisation une fois les données reconstituées. L'ordre compte, et c'est de lui que je tire la thèse de ce mémoire, énoncée d'emblée pour que le lecteur puisse en juger au fil des chapitres : **la structure de la donnée commande ce que la modélisation peut en tirer**. Ce n'est pas une position théorique, c'est un constat que l'année a produit deux fois. La première en creux, lorsque la charge de la migration a repoussé le projet de Machine Learning au second semestre. La seconde en plein, lorsque ce projet a donné des résultats solides là où les données avaient une profondeur temporelle, et modestes là où elles n'étaient qu'une photographie à date.

Quatre chapitres suivent la progression de mes responsabilités. Le chapitre 1 expose le chantier le plus lourd de l'année, la reprise des données vers le nouvel ERP, d'abord les opérations puis les tiers. Le chapitre 2 présente les missions filées menées en parallèle sur les deux semestres : le maintien du système décisionnel et la contribution au déploiement du Single Sign-On. Le chapitre 3 expose le projet de Data Science conduit au second semestre, le Copilote Financier. Le chapitre 4, enfin, livre la réflexion que ces missions ont produite sur le métier, et présente les perspectives et mon projet professionnel.

Chapitre 1

La reprise des données vers SPO : des opérations aux tiers

Sommaire

1.1	Ce que le changement d'ERP imposait	4
1.2	La migration des opérations	5
1.2.1	Méthode et industrialisation des flux	5
1.2.2	Deux contraintes de l'ERP, et la documentation qui en est sortie	5
1.2.3	Le déploiement en « coquilles vides » et le bilan du semestre .	6
1.3	La reprise des tiers	6
1.3.1	Contexte et enjeux de la reprise des tiers	6
1.3.2	Conception du fichier de travail : une chaîne de traitement pilotée par formules	7
1.3.3	Les trois mécanismes algorithmiques	9
1.3.4	De la préparation à l'injection : procédure et contraintes techniques	11
1.3.5	Traitement des cas particuliers et arbitrages	12
1.3.6	Bilan de l'import et points de vigilance pour la suite	13
1.4	Ce que ces deux reprises ont en commun	14

Ce chapitre expose le chantier le plus lourd de l'année : la reconstitution, dans le nouvel ERP, du socle de données du groupe. Il s'est déroulé en deux temps. Le premier semestre a porté sur les structures de gestion, opérations, tranches et budgets, migrées depuis la base historique Grimmo. Le second a porté sur les tiers, c'est-à-dire les clients acquéreurs, repris depuis le CRM Vadimm. Les deux missions partagent une méthode et se distinguent par la question qu'elles posent : injecter des structures suppose de comprendre un modèle de données inconnu ; injecter des personnes suppose de décider ce qui fait qu'une personne est la même.

1.1 Ce que le changement d'ERP imposait

Le remplacement de Grimmo par SPO a commandé le calendrier de toute l'année, et trois contraintes en découlaient. Une contrainte de **volumétrie** d'abord : 283 opérations devaient être reprises avec leurs subdivisions et leurs budgets, échelle à laquelle une saisie manuelle intégrale était exclue. Une contrainte de **continuité de service** ensuite : les utilisateurs devaient pouvoir facturer dès le basculement, une interruption de deux semaines étant déjà inacceptable. Une contrainte de **conformité au modèle cible** enfin : SPO impose ses propres règles d'intégrité, qui n'étaient pas toutes documentées et qu'il a fallu découvrir en les heurtant.

La Figure 1.1 situe ces deux reprises dans le système d'information du groupe. Les trois outils et leurs usages métier occupent le haut du schéma, reliés par les flèches qui figurent la circulation normale de la donnée ; les tableurs forment la bande du bas, et les traits pointillés qui les rattachent à chacun d'eux marquent les échanges qui ne passent par aucun système. On y lit le problème que les deux missions de ce chapitre attaquent : le même client pouvait exister dans le CRM et dans l'ERP sans qu'aucun lien ne les rattache.




FIGURE 1.1 – Les outils du système d'information et la circulation de la donnée

À ces contraintes s'ajoute une perspective absente du calendrier initial : le passage prochain vers l'infrastructure technique du groupe Nexity, qui a influé sur certains choix techniques, notamment lorsqu'il a fallu évaluer si l'architecture retenue pour le projet de

Data Science tiendrait à une échelle supérieure.

1.2 La migration des opérations

Cette mission, conduite au premier semestre, est exposée en détail dans mon mémoire de mi-parcours. Je n'en reprends ici que ce dont la suite a besoin : la méthode, les deux contraintes que l'ERP impose, et l'état dans lequel le socle se trouvait à la fin du semestre.

1.2.1 Méthode et industrialisation des flux

Face aux 283 opérations du périmètre, une saisie manuelle intégrale était exclue. Nous avons retenu une stratégie hybride : injection automatisée des gros volumes structurels via les API, traitement manuel des cas historiques ne pouvant entrer dans les gabarits. Vouloir tout automatiser aurait conduit à écrire des règles pour des cas uniques, ce qui coûte plus cher que de les traiter à la main.

J'ai d'abord analysé la documentation technique de l'API de Salvia [2], puis testé manuellement les *endpoints* pour décortiquer la mécanique de création d'une donnée. Nous avons ensuite déployé le module DirectAPI, dont j'ai construit le pipeline d'alimentation sous la forme de maquettes Excel en trois étapes : **extraction** de la base source par My-Report Builder, **transformation et mapping** par formules RechercheX, **chargement** via DirectAPI. La transformation concentre l'essentiel du travail, la nomenclature de SPO étant stricte : un libellé de poste budgétaire ou un type de tranche non reconnu fait rejeter la ligne. Excel a été retenu parce que la maquette reste relisible par les personnes qui connaissent le métier et non le code.


Le processus a été sécurisé par une validation itérative : 3 opérations pilotes, puis un lot de 12, avant la migration de masse. Cette progression par paliers rend les erreurs lisibles, et c'est elle que j'ai reconduite au second semestre.

1.2.2 Deux contraintes de l'ERP, et la documentation qui en est sortie

La première est l'ordre strict d'injection, contrainte d'intégrité référentielle que la documentation de l'éditeur n'explicitait pas. Je l'ai découverte en analysant les codes d'erreur renvoyés par l'API : il faut créer l'opération, puis les tranches de travaux, puis les tranches commerciales, puis le budget. La Figure 1.2 représente cette séquence ; toute injection qui ne la respecte pas échoue, le système ne trouvant pas l'objet parent.

J'ai alors rédigé une documentation interne cartographiant cette séquence et les pré-requis de chaque objet, parce que ces règles n'existaient nulle part ailleurs que dans mes notes de test. C'est le premier livrable écrit de mon année qui n'était pas un fichier de données, et c'est celui qui a le plus servi aux autres : la reprise des tiers, exposée plus bas, s'est appuyée directement dessus.

La seconde tient aux identifiants. Invisibles dans l'interface, ils changent à chaque mise à jour : l'API ne remplace pas un budget, elle clôture la version précédente et en crée une nouvelle. Ne pouvant me fier à aucun identifiant statique, j'ai conçu un



Toute injection qui ne respecte pas cet ordre est rejetée : le système ne trouve pas l'objet parent.

FIGURE 1.2 – La séquence d'injection imposée par l'intégrité référentielle de l'ERP

requêtage dynamique en trois temps — un appel GET pour lister les versions, un tri pour retenir la plus récente, un appel POST sur cet identifiant. J'en retire une leçon plus générale : une API ne se contente pas d'exposer des données, elle impose un modèle de comportement, et comprendre l'intention derrière la contrainte est ce qui permet de la contourner proprement.

1.2.3 Le déploiement en « coquilles vides » et le bilan du semestre

Les utilisateurs devaient facturer dès le basculement, notamment pour le lien avec la Gestion Électronique des Documents (GED). Nous avons donc adopté une stratégie de déploiement en « coquilles vides », qui dissocie le contenant — la structure de l'opération — du contenu, c'est-à-dire les données budgétaires détaillées, en injectant d'abord le code opération et le libellé.

C'est la décision dont j'ai le plus appris en conduite de projet. Elle suppose d'accepter qu'un système soit temporairement incomplet et de le documenter comme tel : une donnée manquante que personne ne signale finit par être considérée comme absente pour de bon. Tenir la liste de ce qui restait à reprendre a transformé une dette implicite en dette suivie.

Objet du modèle SPO	État à la fin du premier semestre
Opérations	Créées pour l'ensemble du périmètre, 283 dossiers
Tranches de travaux	Créées
Tranches commerciales	Création en cours
Budgets détaillés	Reportés, stratégie des « coquilles vides »
Historique des factures	Non repris

Sur un chantier de reprise, l'avancement ne se mesure pas au nombre d'enregistrements créés mais à la part du modèle cible réellement couverte : créer 283 opérations sans leurs budgets, ce n'est pas avoir fait la moitié du travail, c'est avoir rendu la seconde moitié possible.

1.3 La reprise des tiers

Conduite au second semestre, cette mission prolonge directement la précédente et constitue le premier pas vers l'interopérabilité entre l'ERP et le CRM : elle transfère le référentiel client, la synchronisation permanente sans double saisie restant à construire. Elle change toutefois de nature : il ne s'agit plus d'injecter des structures de gestion, mais des personnes, avec ce que cela implique de risques de doublons et d'exigence de qualité.

1.3.1 Contexte et enjeux de la reprise des tiers

générique de *tiers* : la même entité de base représente un acquéreur particulier comme une société, et se voit attribuer un ou plusieurs rôles. Reprendre les tiers, c'était alimenter le socle sur lequel toute la gestion commerciale allait s'appuyer.

Le périmètre était d'importer l'ensemble des clients ayant déjà acheté chez Angelotti. La matière première venait du CRM Vadimm, sous la forme de deux extractions complémentaires : celle des ventes enregistrées, qui porte 1 557 lignes, et celle des coordonnées des acquéreurs et co-acquéreurs, qui en porte 1 602. Les deux ne se recouvrent donc pas exactement ; l'écart de 45 lignes n'est pas documenté dans les fichiers sources et s'explique vraisemblablement par des contacts renseignés sans vente correspondante. J'ai retenu le plus large des deux totaux pour ne perdre aucun acquéreur : le périmètre de travail compte **1 602 lignes**.

La difficulté ne tenait pas au volume mais à la nature de la donnée. Une ligne de l'extraction ne décrit pas un client, elle décrit une vente : un acquéreur qui a acheté trois lots apparaît trois fois, et rien dans le fichier ne le signale. Transformer un fichier de ventes en référentiel de personnes suppose de reconstituer l'identité de chacune, ce que le système source ne faisait pas à ma place.

L'enjeu central : créer sans dupliquer

L'enjeu se résume à une contrainte simple à énoncer et difficile à tenir : créer chaque client une fois et une seule. Deux sources de duplication se cumulaient, et elles n'appelaient pas la même parade.

La première est interne au fichier : chaque ligne correspondant à une vente, un client fidèle y figure autant de fois qu'il a acheté. Importer le fichier tel quel aurait créé autant de fiches que d'achats, rendant impossible de reconstituer son historique ou de lui adresser un courrier unique. La seconde est externe : au moment de préparer l'import, SPO n'était pas vide, environ 13 000 tiers y ayant déjà été créés par saisie ou par d'autres canaux. Injecter les 1 602 lignes sans les confronter à cet existant aurait produit des doublons plus insidieux, opposant une fiche importée et une fiche saisie, toutes deux légitimes en apparence.

Une reprise manuelle était donc exclue : vérifier ligne à ligne qu'un acquéreur n'existe ni ailleurs dans le fichier ni déjà dans un référentiel de 13 000 tiers représentait un volume de contrôles incompatible avec les délais, et un risque d'erreur que rien n'aurait permis de tracer. J'ai construit un fichier de travail qui automatise ces contrôles par formules, de sorte que la décision d'importer une ligne soit calculée et non prise au cas par cas.

1.3.2 Conception du fichier de travail : une chaîne de traitement pilotée par formules

Une architecture en trois temps : sources, feuille pivot, feuilles de sortie

Le fichier ne se présente pas comme un tableur de saisie mais comme une chaîne de traitement, dans la lignée des maquettes d'injection du premier semestre : les données entrent d'un côté sous leur forme brute et ressortent de l'autre sous la forme attendue par

SPO, sans qu’aucune donnée soit recopiée à la main. La Figure 1.3 en présente les trois étages.

1. **Les feuilles sources**, en lecture seule : **VADIMM** porte les 1 557 lignes de ventes, **Builder coordonnée** les 1 602 lignes de coordonnées, et **SPO** l’extraction des tiers déjà existants, qui sert de référentiel de comparaison.
2. **La feuille pivot BuilderTiers**, cœur du dispositif : elle reçoit l’intégralité des lignes sources et y adjoint les colonnes de calcul qui déterminent, pour chacune, s’il s’agit d’un tiers nouveau, d’un doublon interne ou d’un tiers déjà présent dans SPO.
3. **Les six feuilles de sortie**, une par fichier d’import attendu par SPO, entièrement générées par formules et destinées à être exportées en CSV.




FIGURE 1.3 – La chaîne de traitement à trois étages du fichier de travail

Une règle figure en tête de la note de procédure : on ne modifie jamais directement une feuille de sortie. Ces feuilles étant calculées, toute correction saisie dedans serait écrasée au recalcul suivant, sans laisser de trace. Toute intervention passe donc par **BuilderTiers** ou par la feuille de coordonnées. C’est la contrepartie de l’automatisation : elle garantit qu’à tout moment le contenu des fichiers d’import résulte des règles décrites et non d’une retouche oubliée.

Le modèle de données des tiers dans SPO : couples, personnes physiques, personnes morales

Avant d’automatiser, il fallait comprendre comment SPO représente un tiers, par lecture de la documentation puis tests unitaires de création. Deux caractéristiques ont structuré tout le reste du travail.

La première est que SPO distingue trois **natures** de tiers, et que la nature commande la manière dont l’identité est portée. Une **personne morale** est une société, identifiée par sa raison sociale et son SIRET. Une **personne physique** est un individu, identifié par nom, prénom et date de naissance. Un **couple** est une entité particulière : le tiers n’est ni l’un ni l’autre des conjoints, il les regroupe, et les deux personnes qui le composent sont enregistrées comme ses *représentants*. Cette nature est de loin la plus fréquente, l’essentiel de nos ventes se faisant à des couples acquéreurs.

La seconde est qu’un tiers n’est pas un enregistrement unique mais un ensemble d’objets liés : la fiche principale ne porte que l’identité, tandis que l’adresse, le courriel, le

téléphone, les représentants et les rôles sont autant d'objets rattachés, avec chacun son fichier d'import. C'est ce qui explique que mon fichier produise six feuilles de sortie et non une seule. Cela explique aussi une asymétrie décisive : adresses, courriels et téléphones se rattachent directement à une personne physique ou morale, mais pour un couple ils se rattachent aux représentants. Cette différence, anodine sur le papier, s'est révélée être la principale contrainte technique de l'import.

1.3.3 Les trois mécanismes algorithmiques

La feuille pivot repose sur trois mécanismes qui s'enchaînent : identifier les doublons internes, écarter les tiers déjà créés dans SPO, puis distribuer les lignes retenues vers les six feuilles de sortie. Ce sont eux qui distinguent un fichier de mise en forme d'un outil de reprise, puisqu'ils déplacent la décision d'importer une ligne de l'opérateur vers une règle écrite.

La déduplication par clés d'unicité différenciées selon la nature du tiers

Dédupliquer suppose de répondre à une question qui n'est pas technique : à partir de quoi décide-t-on que deux lignes désignent la même personne ? C'est le point sur lequel j'ai le plus hésité, et celui qui commande la qualité du résultat.

Une clé unique appliquée à tout le fichier ne pouvait pas convenir, précisément parce que les trois natures de tiers ne s'identifient pas de la même façon : deux sociétés peuvent porter des raisons sociales très proches sans être la même entité, alors qu'il est très improbable que deux lignes partageant nom, prénom, date de naissance et adresse désignent deux personnes distinctes. J'ai donc retenu **trois clés d'unicité distinctes**, une par nature, calculées chacune dans sa propre colonne :

1. **Pour un couple** : nom et prénom de l'acquéreur principal, désigné ADV dans nos extractions, complétés du nom et du prénom du co-acquéreur, désigné CO. C'est la combinaison des deux identités qui fait l'unicité, et non chacune prise isolément.
2. **Pour une personne physique** : le nom, le prénom, la date de naissance et l'adresse. La date de naissance sépare les homonymes, l'adresse ajoute un second point de comparaison.
3. **Pour une personne morale** : la raison sociale et le SIRET, identifiant légal de l'établissement, la raison sociale le doublant lorsqu'il fait défaut.

Chaque colonne calcule un **rang** : la première occurrence d'un tiers reçoit le rang 1, les suivantes les rangs 2, 3, et ainsi de suite. Seules les lignes de rang 1 sont retenues, les autres correspondant à des achats successifs d'un client déjà compté. Le rang a un avantage sur une suppression : aucune ligne n'est effacée, les doublons restent visibles, et l'on peut à tout moment vérifier pourquoi une ligne n'a pas été importée.

Ce choix de trois clés différenciées est le véritable cœur méthodologique du travail, parce qu'il traduit une idée simple : la règle d'unicité n'est pas une propriété du fichier, c'est une propriété du métier. Chercher une clé universelle aurait conduit soit à fusionner des tiers distincts, soit à en dupliquer, et dans les deux cas l'erreur n'aurait été découverte que bien plus tard, dans l'usage quotidien de l'ERP.

L'exclusion des tiers déjà présents dans SPO

Pour chaque ligne de la feuille pivot, trois formules de recherche interrogent l'extraction des tiers déjà créés dans SPO : les **personnes morales** par leur raison sociale, les **personnes physiques** par leur nom et leur prénom, et les **couples** par les quatre noms qui les composent, **en testant les deux ordres possibles** entre l'acquéreur et le co-acquéreur.

Ce dernier point illustre le genre de détail qui décide de la réussite d'une reprise. Rien ne garantit que l'ordre des deux conjoints soit le même dans Vadimm et dans SPO ; une recherche à sens unique laisserait donc passer une partie des doublons, et les tiers concernés seraient créés une seconde fois sans que personne s'en aperçoive avant longtemps.

Lorsqu'une de ces formules renvoie un code tiers de SPO, du type T00012666, la ligne est exclue de l'import. **40 tiers** ont ainsi été détectés comme déjà existants. Rapporté aux 1 474 tiers uniques, le volume peut sembler faible, mais chacun de ces 40 cas aurait produit un doublon durable dans le référentiel client.

La Figure 1.4 récapitule l'effet cumulé de ces deux mécanismes : des 1 602 lignes de départ, la déduplication interne en écarte 128 qui correspondent à des achats répétés, ramenant le total à 1 474 tiers uniques ; l'exclusion en retire 40 de plus, pour **1 434 tiers à créer**. Chaque étage correspond à une règle explicite, écrite dans une colonne, donc vérifiable et reproductible.




FIGURE 1.4 – De 1 602 lignes de départ à 1 434 tiers créés : l'effet des deux filtres successifs

La propagation vers les feuilles de sortie par numérotation séquentielle

Les six feuilles de sortie n'ont ni la même population ni le même nombre de lignes : celle des tiers reçoit un enregistrement par tiers créé, celle des adresses ne concerne que les personnes physiques et morales, celle des courriels seulement celles dont le courriel est renseigné, celle des représentants deux lignes par couple plus une par société. Il fallait donc à chaque feuille une numérotation propre.

Le mécanisme retenu attribue à chaque ligne de la feuille pivot un **numéro séquentiel par destination** : une ligne sans vocation à alimenter une feuille ne reçoit pas de numéro pour elle, les autres sont numérotées de 1 à n . Chaque feuille de sortie n'a plus qu'à chercher, pour sa ligne i , celle de **BuilderTiers** portant le numéro i dans la colonne qui la concerne.

Ce détour rend les six feuilles indépendantes tout en les gardant synchronisées avec une source unique : si une ligne est corrigée ou si une exclusion apparaît, les six numérotations

se recalculent et les fichiers restent cohérents. C'est exactement le problème qui, en saisie manuelle, produit les incohérences les plus difficiles à détecter — une adresse rattachée au mauvais tiers parce qu'une ligne a été insérée sans que le reste suive.

La volumétrie des six feuilles traduit directement le modèle de données décrit en 1.3.2, et le tableau de la section 1.3.6 la récapitule : 1 434 lignes pour la liste maîtresse des tiers et autant pour le rôle « Client », mais 1 871 représentants puisque chaque couple en compte deux, et seulement 553 adresses, 538 téléphones et 469 courriels, ces trois fichiers ne portant que les personnes physiques et morales.

À insérer — figure. Capture d'écran de la feuille **BuilderTiers**, montrant côte à côte les colonnes de données reprises et les colonnes calculées : les trois rangs de déduplication avec des valeurs 1 et 2 visibles, et une ligne portant un code SPO dans les colonnes de rapprochement. Anonymiser les noms d'acquéreurs. Les figures suivantes sont à renuméroter après insertion.

1.3.4 De la préparation à l'injection : procédure et contraintes techniques

Génération et normalisation des fichiers d'import

Transformer les six feuilles en fichiers réellement acceptés par SPO a mobilisé quatre contraintes de format que la documentation ne mentionnait pas et que les premiers rejets ont fait apparaître : un encodage UTF-8 avec le point-virgule pour séparateur ; la conversion en ASCII pur de tous les noms, prénoms, adresses et professions, SPO refusant les caractères accentués ; la suppression de la seconde ligne d'en-tête ; et le découpage en lots de 200 tiers au maximum, homogènes en nature. Cette dernière règle explique que l'import des couples se soit fait en cinq lots successifs, puisqu'un même fichier ne peut mélanger les natures. Le détail figure en annexe A.

Ces contraintes sont consignées dans la note de procédure remise à l'équipe, avec la marche à suivre pour rejouer l'import s'il devait être différé : d'autres tiers pouvant être créés entre la préparation et l'injection, la procédure prévoit de redemander une extraction actualisée, de remplacer la feuille de référence et de recalculer, les tiers devenus existants sortant automatiquement du périmètre. Le fichier reste ainsi utilisable dans le temps, ce qui était l'un de mes objectifs de conception.

Le contournement par API : 872 requêtes PATCH pour les coordonnées des couples

C'est ici qu'est apparue la contrainte la plus structurante du projet. Le format d'import CSV ne permet pas de porter les courriels et les téléphones des couples : pour un couple, ces coordonnées ne sont pas des attributs du tiers mais de ses représentants, et les fichiers d'import de coordonnées ne savent viser qu'un tiers. Sur les 881 couples créés, les CSV pouvaient donc produire l'identité et les représentants, mais pas les coordonnées de contact — plus de six tiers sur dix seraient arrivés dans l'ERP sans adresse électronique ni téléphone.

Saisir ces coordonnées à la main représentait plusieurs centaines de saisies et reconduisait le risque d'erreur que le fichier automatisé visait à supprimer. J'ai donc retenu la seconde voie, l'API de SPO, déjà pratiquée au premier semestre. Elle expose une opération de modification partielle au format **JSON Patch**, normalisé par la RFC 6902 [3], qui décrit une modification non pas en renvoyant l'objet entier mais sous la forme d'opérations élémentaires indiquant l'action, le chemin de la propriété visée et la valeur à appliquer. C'était exactement ce qu'il fallait : ajouter un courriel et un téléphone sur un représentant déjà créé, sans toucher au reste de sa fiche.

J'ai construit le corps de chaque requête à partir de la feuille **Builder** *coordonnée*, puis regroupé l'ensemble dans une collection Postman de **872 requêtes PATCH**, organisées en cinq lots correspondant aux cinq fichiers d'import de couples. Les cinq lots ont été exécutés après la création des couples, et l'intégralité des requêtes est passée sans erreur.

À insérer — figure. Capture d'écran de la collection Postman : arborescence des cinq lots et vue d'une requête PATCH sur son onglet *Body*, montrant la structure JSON Patch. Masquer l'adresse du serveur et les identifiants. Les figures suivantes sont à renuméroter après insertion.

Ce contournement m'a appris quelque chose que je n'avais pas formulé aussi clairement : dans un projet de reprise, la limite d'un format d'import n'est pas nécessairement une limite du système. Le fichier plat et l'API sont deux portes d'entrée vers le même modèle de données, et savoir basculer de l'une à l'autre au bon moment, plutôt que d'accepter une perte de données ou de retomber dans la saisie manuelle, est une compétence que la reprise du premier semestre n'avait pas eu l'occasion de mobiliser.

1.3.5 Traitement des cas particuliers et arbitrages

Une chaîne pilotée par formules ne traite pas tout. Neuf tiers ont demandé une intervention manuelle, répartis en quatre familles : trois adresses hors de France, que SPO refusait de créer avec un pays étranger et qui ont été créées en France puis rectifiées ; trois tiers dont la nature était mal renseignée dans Vadimm, corrigée dans la feuille pivot avant génération puisque la nature commande la clé d'unicité et la feuille de sortie ; un tiers relevant d'une opération de dation, déjà présent dans SPO ; et deux doublons portant deux adresses divergentes. L'annexe B donne le détail de chaque cas.

Ce dernier est le seul qui ait demandé un arbitrage véritable : la déduplication savait dire qu'il s'agissait de la même personne, elle ne pouvait pas dire où cette personne habite aujourd'hui. Après vérification des dates dans Vadimm, nous avons conservé l'adresse rattachée à la vente la plus récente.

Ces neuf cas délimitent précisément ce que l'automatisation peut et ne peut pas faire : les formules savent appliquer une règle, elles ne savent pas décider laquelle de deux adresses également plausibles est la bonne. La valeur du fichier n'est pas d'avoir supprimé la décision humaine, mais de l'avoir concentrée sur une poignée de cas identifiés au lieu de la diluer sur 1 602 lignes.

1.3.6 Bilan de l'import et points de vigilance pour la suite

L'intégralité des imports CSV et des requêtes PATCH a été exécutée avec succès.

Objet créé dans SPO	Volume	Canal
Tiers	1 434	Import CSV
Adresses	553	Import CSV
Courriels (personnes physiques et morales)	469	Import CSV
Téléphones (personnes physiques et morales)	538	Import CSV
Représentants (couples et sociétés)	1 871	Import CSV
Rôles « Client »	1 434	Import CSV
Coordonnées des couples	872	Requêtes PATCH

Les 1 434 tiers se répartissent en **881 couples**, **462 personnes physiques** et **91 personnes morales**, répartition que représente la Figure 1.5. Cette structure justifie a posteriori l'attention portée aux couples, qui représentent plus de six tiers sur dix et concentrent la contrainte de format qui a imposé le recours à l'API.




FIGURE 1.5 – Répartition des 1 434 tiers créés selon leur nature

À insérer — figure. Capture d'écran d'une fiche de couple dans SPO, onglet des représentants ouvert, montrant les deux personnes du couple et les coordonnées ajoutées par requête PATCH sur l'une d'elles. Anonymiser les noms.

Quatre manipulations cassent le fichier sans produire le moindre message d'erreur : modifier une feuille de sortie, modifier les colonnes calculées de la feuille pivot, insérer une ligne au milieu d'une feuille, et trier la feuille pivot, dont la logique de rang est cumulative sur l'ordre des lignes. La note de procédure les énonce avant même d'expliquer comment se servir du fichier.

Les pièges de formule rencontrés relèvent tous du même défaut, et c'est l'enseignement principal que j'en tire : dans une chaîne pilotée par formules, l'erreur ne se manifeste presque jamais par un message d'erreur, mais par un compteur qui ne tombe pas juste. Chaîne vide comptée comme une valeur, code de mois interprété comme des minutes, heures parasites rendant différentes deux dates identiques, cellule vide confondue avec chaîne vide : chacun a produit des compteurs surévalués ou des faux positifs, et aucun n'a signalé quoi que ce soit (annexe C). J'ai donc ajouté à la feuille pivot un panneau de

compteurs que la procédure impose de vérifier avant tout export : c'est le seul dispositif de détection dont je disposais. Avec environ 60 000 cellules de formules, elle recommande enfin de travailler en calcul manuel puis de forcer un recalcul complet avant chaque export.

1.4 Ce que ces deux reprises ont en commun

Les deux chantiers ont suivi la même méthode, que je n'avais pas choisie a priori : elle s'est imposée parce que le modèle cible était inconnu. On ne peut pas spécifier complètement une reprise dont on ignore les règles d'acceptation ; on avance donc par paliers de volume croissant, en traitant chaque rejet comme une information sur le modèle cible plutôt que comme une erreur à corriger. Sa propriété la plus utile est que **le coût d'une erreur y est proportionnel au palier où on la découvre** ; sa limite est qu'elle démarre lentement et produit d'abord une documentation interne plutôt que des données dans le système.

Les difficultés techniques se ramènent presque toutes à une même situation : un système imposait une règle qui n'était écrite nulle part. L'ordre d'injection en est le cas le plus net, le versionnement des budgets le second, le refus des caractères accentués et l'impossibilité de porter les coordonnées des couples en CSV relèvent de la même famille.

Le régime de preuve de ces deux missions est celui de la **réconciliation** : la question n'est pas si un modèle est performant, mais si ce qui est arrivé correspond à ce qui est parti. Elle a pris la forme de la validation par paliers sur la migration et du panneau de compteurs sur la reprise des tiers. Son angle mort mérite d'être nommé : elle prouve qu'une donnée est arrivée, pas qu'elle est juste. Si une clé d'unicité était mal choisie, l'erreur passerait le contrôle sans être vue, puisque les compteurs tomberaient juste.

Le référentiel commercial est ainsi reconstitué selon des règles écrites et rejouables. Le chantier n'est pas clos pour autant : la reprise des historiques budgétaires reste devant nous, et le fichier devra être rejoué avant la bascule définitive.

Chapitre 2

Reporting et missions SI transverses

Sommaire

2.1	Le maintien opérationnel du reporting	16
2.2	Le déploiement du Single Sign-On	17
2.3	Ce que les missions filées coûtent et ce qu'elles rapportent .	17

Pendant que les deux reprises du chapitre précédent se déroulaient, j’ai maintenu mes activités de gestionnaire d’information : les demandes de reporting des services et une contribution à l’infrastructure système. Conduites sur les deux semestres, elles sont exposées en détail dans mon mémoire de mi-parcours ; je n’en retiens ici que ce qui éclaire la suite, car c’est en les menant que j’ai rencontré, sous une forme miniature, le problème qui commande le projet de Data Science du chapitre 3 : lorsqu’une règle de gestion n’a nulle part où être écrite, elle finit par être recalculée partout, différemment.

2.1 Le maintien opérationnel du reporting

Ces demandes consistent à traduire des besoins métier parfois abstraits en indicateurs fiables. Le travail commence rarement par une spécification : il commence par une gêne exprimée en réunion, ou par un tableau que quelqu’un refait à la main tous les mois. Reformuler la demande jusqu’à ce qu’elle soit calculable — de quelles lignes parle-t-on, sur quelle période, que fait-on des cas limites ? — est la partie que je sous-estimais en arrivant, et c’est celle qui décide de l’utilité du résultat.

La demande du service juridique en donne l’exemple le plus significatif. Le besoin portait sur le suivi des commandes clients, avec une règle de gestion en alternance stricte : la première commande est payante, la deuxième gratuite, la troisième payante, et ainsi de suite. La difficulté tient à ce que cette règle ne porte pas sur une ligne mais sur la position d’une ligne dans une séquence : aucune colonne de la base ne contient l’information « c’est la deuxième commande de ce client sur ce lot », qui n’existe que si on la calcule et change dès qu’une commande est ajoutée ou annulée.

Deux contraintes interdisaient de stocker le résultat : je ne possédais pas les droits d’écriture permettant de créer un champ de statut dans la base SQL, et les fichiers Excel sources étaient écrasés à chaque mise à jour. Il fallait donc un calcul dynamique, exécuté à la génération du tableau : identifier les opérations et les lots, classer les commandes par ordre chronologique, attribuer un rang, puis appliquer la règle — rang impair, statut « Payant » ; rang pair, « Gratuit ». La Figure 2.1 représente cette chaîne de calcul.




FIGURE 2.1 – La règle de facturation juridique traduite en calcul de rang, exécuté à chaque génération du tableau

Cette approche répond au besoin sans altérer les données sources, mais elle a un coût : la règle est recalculée à chaque affichage et n’existe nulle part ailleurs que dans la définition du tableau. Si un autre service a besoin de la même notion, rien ne garantit qu’elle sera implantée à l’identique. C’est exactement le problème que le projet du chapitre 3 résoudra,

en écrivant les définitions partagées une seule fois dans des vues de base de données. Le régime de preuve retenu ici est celui de la **recette par l'usage** : seul le service demandeur pouvait juger de la conformité de la règle appliquée, et cette validation ne dit rien, à court terme, de l'utilité de l'outil dans la durée.

2.2 Le déploiement du Single Sign-On

J'ai par ailleurs collaboré avec l'administratrice des systèmes et outils SI au déploiement du SSO (*Single Sign-On*) sur les postes de deux périmètres, l'agence de Perpignan et le service financier du siège : installation du connecteur, vérification de la synchronisation avec l'annuaire d'entreprise, accompagnement des utilisateurs à leur première connexion. Nous avons volontairement commencé par ces deux périmètres avant d'envisager une généralisation.

Cette mission m'a appris quelque chose que je n'attendais pas d'un déploiement. L'annuaire d'entreprise sur lequel repose le SSO est un référentiel d'identités : il répond, pour les collaborateurs, à la question que je me posais pour les clients au chapitre 1, à savoir comment garantir qu'une personne n'existe qu'une fois et qu'on sait la reconnaître. Voir ce problème résolu du côté de l'infrastructure éclaire par contraste la situation côté données de gestion, où aucun référentiel de ce type n'existait avant la reprise des tiers. L'accompagnement des utilisateurs a été instructif à sa manière : une solution techniquement correcte qui déroute l'utilisateur au moment de s'en servir n'est pas une solution livrée.

2.3 Ce que les missions filées coûtent et ce qu'elles rapportent

Ces missions transverses fragmentent le temps, et un chantier de reprise interrompu trois fois dans la journée pour une demande de tableau de bord se reprend mal, puisqu'il faut à chaque fois reconstituer où l'on en était dans une logique de formules imbriquées. Cette fragmentation a été la difficulté la plus constante de l'année, et ce que j'ai fini par mettre en place tient en peu de choses : réserver les plages longues aux travaux qui ne se découpent pas, regrouper les demandes courtes, et surtout écrire où j'en étais avant d'interrompre une tâche.

Elles rapportent cependant trois choses que je n'aurais pas obtenues autrement : une **connaissance du métier** que la fréquentation des bases ne donne pas, car on ne comprend pas ce qu'est une commande gratuite en lisant une table ; une **crédibilité** auprès des services, qui a rendu possible au second semestre un échange direct avec la direction financière ; et une **vision de l'architecture** du système d'information, depuis l'authentification des postes jusqu'aux tableaux de bord, qui m'a permis de concevoir le projet du second semestre comme une chaîne complète plutôt que comme une suite de modèles.

Ces solutions restent des contournements : une règle recalculée à chaque affichage tient tant que personne d'autre n'en a besoin. Elles auront néanmoins maintenu le système décisionnel en état de marche pendant les douze mois qu'a duré la reconstruction du

socle. Ce socle étant désormais fiable, le chapitre suivant expose ce qu'il devient possible d'en faire.

Chapitre 3

Le Copilote Financier

Sommaire

3.1	Contexte	20
3.1.1	Problème métier	20
3.1.2	Objectifs du dashboard	21
3.2	Données disponibles	22
3.2.1	Données internes	22
3.2.2	Données externes	22
3.3	Architecture technique	23
3.4	Notebooks et résultats	23
3.4.1	Exploration et nettoyage des données brutes	23
3.4.2	SQL et Spark	24
3.4.3	Axe A : risque de dérive de marge	25
3.4.4	Axe B : vitesse d'écoulement	26
3.4.5	Axe C : prix du stock	27
3.4.6	Signaux faibles (texte et réseau)	28
3.5	Plateforme Streamlit	28
3.6	Périmètre et limites	30
3.7	Méthode, évaluation et limites du projet	30
3.8	Conclusion du chapitre	31

Ce chapitre présente le projet de Data Science annoncé à la fin du premier semestre : le « Copilote Financier », un outil d'aide à la décision construit sur les données de gestion du groupe Angelotti pour sa direction financière. Le périmètre envisagé au départ, la prédiction de la rentabilité des opérations d'aménagement, a été redéfini en cours de projet : la prédiction de la marge à terminaison subsiste comme premier axe de travail, mais le besoin exprimé par la direction financière l'a élargie à deux autres questions, et la restitution a finalement été restreinte à la promotion immobilière. J'y expose d'abord le besoin métier tel qu'il m'a été formulé, puis les données dont je disposais réellement, l'architecture retenue pour les rendre exploitables, les trois axes d'analyse et leurs résultats, la plateforme qui les restitue aux contrôleurs de gestion, et enfin les limites que je considère comme faisant partie du livrable.

Une décision a orienté tout le projet : la taille des données disponibles, 267 opérations et quatre exports totalisant 32 Mo, ne justifie pas un empilement de modèles. J'ai donc retenu un petit nombre de méthodes simples, chacune choisie pour une question précise et validée sérieusement, plutôt qu'un catalogue d'algorithmes dont aucun n'aurait pu être correctement évalué à cette échelle.

3.1 Contexte

Le groupe Angelotti conçoit, finance et commercialise des programmes immobiliers en Occitanie et en région PACA. Chaque opération de promotion y est portée par une société dédiée et vit sur un cycle long : un budget est arrêté au moment de l'engagement, puis le chantier et la commercialisation le font dériver au fil des mois. Les appels d'offres reviennent plus chers qu'anticipé, des acquéreurs se désistent, le rythme de vente ralentit sous l'effet de la conjoncture.

La direction financière suit ces dérives opération par opération, sur tableurs, sans vision transverse. Personne ne dispose d'une vue d'ensemble permettant de dire, à un instant donné, quelles opérations méritent l'attention en priorité. C'est ce manque qui a motivé le projet.

3.1.1 Problème métier

Trois questions structurent les revues de gestion, et les tableurs actuels n'y répondent pas.

La première porte sur la **marge** : quelles opérations examiner en priorité parce que leur marge d'engagement dérive, sur quels postes et pour combien d'euros ? Y répondre suppose de comparer des dizaines d'opérations entre elles, ce qu'aucun tableur individuel ne permet.

La deuxième porte sur le **rythme de vente** : quel volume de réservations budgéter pour 2026 ? La période récente a montré la sensibilité de la demande au coût du crédit, le taux moyen des crédits habitat étant passé d'environ 1,1 % à un pic de 3,6 % fin 2023 avant de refluer vers 3,1 % mi-2026, tandis que le rythme du groupe tombait d'environ 150 à moins de 115 réservations par mois en 2023. Reste à savoir ce qui, dans cette chute, revient à la conjoncture et ce qui revient aux programmes eux-mêmes.

La troisième porte sur le **prix** : quels lots du stock faut-il réviser, à la hausse ou à la baisse ? La question n'est pas théorique, puisque 45 % des 2 157 désistements enregistrés ont pour motif un problème de financement ou un refus de prêt, et que les remises sont aujourd'hui accordées au cas par cas.

Ces trois questions ont un point commun. Face à des besoins de ce type, la tentation serait de partir sur un projet d'apprentissage automatique de grande ampleur ; c'est pourtant un problème de contrôle de gestion outillé par la donnée, et rien d'autre, le matériau disponible se résumant à 267 opérations et quatre exports Excel, soit une photographie à date.

Besoins par axe et exigences non fonctionnelles

J'ai formalisé ces besoins en trois axes de travail, complétés d'un axe transverse :

1. **Axe A, risque de marge** : un score permettant de trier les opérations par risque de dérive, le détail en euros des postes déjà en dépassement, et la possibilité de comparer une opération à ses semblables.
2. **Axe B, vitesse d'écoulement** : quantifier l'effet du taux d'intérêt sur le rythme de réservation, en le séparant de l'effet propre à chaque programme, et simuler des scénarios de taux pour 2026.
3. **Axe C, prix** : estimer un prix de marché par lot, signaler le stock qui s'en écarte, et proposer une règle de remise argumentée.
4. **Axe transverse** : tirer des signaux simples des commentaires de vente et de la structure du réseau de vendeurs.

Quatre exigences non fonctionnelles ont cadré le travail. La **reproductibilité** d'abord : tout doit se reconstruire depuis les exports bruts par un seul script, sans étape manuelle intermédiaire. L'**interprétabilité** ensuite : chaque score doit être accompagné des variables qui le déterminent. La **confidentialité** également : aucune donnée nominative de client n'est affichée ni modélisée. L'**acceptation d'un petit échantillon** enfin : à cette taille, des modèles simples validés en validation croisée valent mieux que des architectures complexes dont on ne saurait pas mesurer la performance réelle.

3.1.2 Objectifs du dashboard

Le livrable final est une application web destinée à la direction financière, dont la fonction est de traduire les modèles en décisions. Un retour de l'entreprise, reçu en cours de projet, a imposé une clarification utile : la première version de l'interface était trop marquée par le vocabulaire de la modélisation, ses écrans parlant de scores, de probabilités et d'intervalles là où les utilisateurs attendaient des niveaux d'alerte, des dépassements en euros et un prix de marché estimé. J'ai donc entièrement réécrit l'interface en langage de gestion, et nous en avons restreint le périmètre aux 147 opérations de promotion immobilière, l'aménagement foncier relevant d'une logique économique différente. Les métriques de validation restent dans les notebooks : l'écran ne montre que ce qui se décide.

Ce retour a été l'un des enseignements les plus utiles du projet. Un modèle correctement validé mais restitué dans le vocabulaire du modélisateur reste inutilisable par le

métier, et cette distance ne se comble pas par de la pédagogie, elle se comble en changeant les mots affichés.

3.2 Données disponibles

3.2.1 Données internes

Quatre exports du système de gestion constituent le point de départ. Leur périmètre de 267 opérations ne recouvre pas exactement les 283 opérations reprises au chapitre 1 : ce sont deux extractions distinctes, faites à des dates différentes, et les exports de gestion ne portent que les opérations disposant d'un budget analytique au moment de l'extraction.

Export	Grain	Volumétrie	Usage
Grille de prix	lot × dossier de vente	16 467 lignes, 196 opérations	ventes, prix, dates, désistements
Budget & EFR	poste analytique	65 000 lignes, 267 opérations	budget, engagé et facturé par poste
Budget LIVE	poste budgétaire	79 106 lignes	contrôle de cohérence
06_ Informations Lots	dossier désisté	2 164 lignes	détail des désistements

Deux intitulés sont abrégés : l'export de la grille de prix s'appelle « Grille de Prix Avec Désistements » dans le système de gestion, et le fichier de contrôle « A_DM_BUDGET_MONTANT_G » désigné ci-après comme le fichier LIVE.

Comprendre ces exports m'a demandé plus de temps que les modéliser, et c'est normal : c'est à cette étape que se jouait la fiabilité de tout le reste. Trois constats l'illustrent. Le fichier « 06_ Informations Lots » ne contient pas les lots malgré son nom : il ne porte que des dossiers désistés, 2 157 au motif « Désisté » et 7 au motif « Résolution de vente », la table maîtresse des lots étant en réalité la grille de prix. Le fichier « Budget & EFR » affiche 65 000 lignes, chiffre rond qui évoquait une troncature ; la réconciliation avec le fichier LIVE a montré le contraire, les totaux étant identiques à l'euro près sur les 118 opérations jointes, et les 65 000 lignes se décomposant en 64 788 postes de détail et 212 lignes de synthèse. Le nettoyage, enfin, a traité les défauts classiques d'un export de gestion : natures de lot harmonisées en huit familles, doublons orthographiques de communes fusionnés puisque 91 orthographes désignaient 90 communes, et surfaces ou prix à zéro convertis en valeurs manquantes, un zéro de surface n'ayant aucun sens économique.

3.2.2 Données externes

Trois sources publiques complètent les données internes, toutes récupérées par script pour qu'elles restent re-téléchargeables et que l'analyse puisse être rejouée sur des séries actualisées : le **taux moyen des crédits habitat en France**, série mensuelle de la Banque centrale européenne [4] de 2015 à 2026 ; l'**indicateur de confiance des ménages**

publié par Eurostat [5] sur la même période ; et un **référentiel des 90 communes d’implantation** du groupe, avec population et coordonnées géographiques, obtenu par l’API publique `geo.api.gouv.fr` [6] et enrichi d’une distance au littoral que j’ai calculée.

3.3 Architecture technique

L’architecture tient en une chaîne courte et entièrement rejouable. Les quatre exports et les trois sources externes alimentent un script de nettoyage qui charge une base SQL-Lite en schéma en étoile, c’est-à-dire autour de tables de faits rattachées à des tables de dimensions : trois dimensions — opérations, communes, conjoncture mensuelle — et quatre tables de faits, soit 64 788 lignes budgétaires, 14 123 lots, 14 428 dossiers de vente et 2 164 désistements. Les notebooks d’analyse et l’application s’appuient tous deux sur cette base.

Trois vues SQL y encapsulent les calculs partagés : marge budgétée contre marge engagée par opération, réservations par opération et par mois, état du stock. Ce choix est plus structurant qu’il n’y paraît : la définition de la marge est écrite une seule fois, dans la vue, et les notebooks comme la plateforme consomment la même. C’est la situation inverse de celle du chapitre 2, où la règle de facturation juridique, ne pouvant être écrite nulle part, devait être recalculée à chaque génération du tableau.

Une seule commande reconstruit l’ensemble depuis les exports bruts, en quelques secondes. Tous les résultats présentés ici sont donc reproductibles — contrainte que je me suis imposée avant d’écrire la première ligne d’analyse, et qui distingue un travail vérifiable d’une suite de manipulations dont personne ne saurait refaire le chemin.

3.4 Notebooks et résultats

3.4.1 Exploration et nettoyage des données brutes

L’exploration a produit deux résultats qui ont directement orienté la modélisation.

Le premier concerne la distribution des prix. Le prix au mètre carré des appartements est fortement asymétrique, avec un coefficient d’asymétrie de 19,2, ce qui le rendait impropre à une modélisation linéaire directe ; après passage au logarithme, le coefficient tombe à 0,39 et le diagramme quantile-quantile devient presque rectiligne. La Figure 3.1 rassemble les deux distributions. C’est ce constat qui a conduit l’axe C à modéliser le logarithme du prix.

Le second est une leçon de méthode, et c’est le passage du projet dont j’ai le plus appris. En calculant la corrélation entre les réservations mensuelles du groupe et le taux des crédits habitat, j’obtenais une valeur quasi nulle, de +0,07 : prise au premier degré, elle signifiait que la conjoncture n’explique rien du rythme de vente, ce qui contredit tout ce que l’on sait du marché. En réalité, la série brute est brouillée par la croissance du portefeuille, le nombre d’opérations en commercialisation ayant fortement augmenté sur la période. Rapportées au nombre d’opérations actives, les réservations racontent l’inverse : la Figure 3.2 donne cette série d’intensité corrigée, dont la corrélation avec le taux d’intérêt




FIGURE 3.1 – Prix au mètre carré des appartements : distribution brute et après transformation logarithmique

passé à -0,34 et celle avec la confiance des ménages à +0,44. Tout l’axe B repose sur cette correction ; sans elle, j’aurais conclu à l’absence d’effet de la conjoncture, et j’aurais eu tort.



FIGURE 3.2 – Intensité de vente, mesurée en réservations par opération active : l’effet de la remontée des taux apparaît une fois l’effet de portefeuille neutralisé

3.4.2 SQL et Spark

Le livrable de cette étape est la base décrite plus haut : vues métier partagées, index, et un contrôle croisé des agrégats qui retrouve les mêmes totaux par deux moteurs indépendants, soit 1 561,8 M€ de dépenses budgétées et 1 754,8 M€ de recettes, à l’arrondi près. Ce contrôle garantit que la base chargée dit bien la même chose que les exports d’origine.

J’ai ensuite évalué Spark comme piste de montée en charge, l’entreprise appartenant à un groupe dont le périmètre de données dépasse largement le sien. Le test aboutit à une conclusion négative, et c’est en cela qu’il est utile : sur nos 64 788 lignes, soit 9 Mo en mémoire, l’agrégation est environ cinquante fois plus lente qu’avec pandas — un rapport mesuré de 58, après 24 secondes de démarrage de la machine virtuelle Java. SQLite et pandas constituent donc la bonne architecture à cette échelle, et le chemin de montée en charge est identifié si le périmètre devait un jour s’étendre à celui du groupe Nexity.

3.4.3 Axe A : risque de dérive de marge

La difficulté de cet axe n'était pas le modèle mais la définition de la cible. Les exports étant une photographie à date, sans historique des révisions budgétaires, je ne peux pas observer comment un budget a évolué, seulement où il en est. J'ai donc mesuré la dérive par les dépassements déjà engagés, poste par poste : les dépenses à terminaison sont estimées par le maximum de l'engagé et du budget de chaque poste, selon un principe simple — un dépassement engagé est acquis, et le budget restant sera dépensé — et la variation de marge rapporte la marge ainsi recalculée à la marge budgétée. Cette grandeur est appelée dans le projet la variation de marge « committée », par emprunt à la notion comptable de coût engagé : elle ne mesure pas une dérive anticipée, mais la part de dérive que les engagements déjà pris rendent acquise.

Cette définition impose une précaution sur les variables explicatives : le modèle n'utilise que le budget initial et les signaux commerciaux, jamais l'engagé ni le facturé, qui définissent la cible. Sans cela, il aurait « prédit » sa propre définition.

Sur le périmètre exploitable, soit les 123 opérations engagées à au moins 60 % et dont la marge budgétée dépasse 50 k€, 36,6 % des opérations n'ont aucun dépassement engagé, 28 % franchissent le seuil de dérive matérielle que j'ai fixé à 2 % de la marge, et deux cas extrêmes dépassent la moitié de la marge budgétée. La Figure 3.3 donne la distribution complète et situe ce seuil.




FIGURE 3.3 – Distribution de la variation de marge « committée » sur les 123 opérations du périmètre, et seuil de dérive matérielle à -2 %

La partie la plus utile de cet axe pour l'entreprise n'est pas un modèle appris : c'est le tableau descriptif des dépassements engagés en euros, par opération et par poste, calculé en SQL pur, qui alimente la page « Alertes marge » de la plateforme.

La modélisation vient en complément, comme score de tri. Une régression du taux de variation atteint un coefficient de détermination de 0,08 sur l'échantillon test : résultat modeste, que je présente tel quel, la structure du budget initial prédisposant à la dérive sans la déterminer. Une classification des opérations « à risque », dont la dérive dépasse 2 %, atteint un score F1 — qui combine la capacité à détecter les cas à risque et celle à ne pas en signaler à tort — de 0,30 à 0,34 en validation croisée stratifiée, contre 0 pour la référence majoritaire qui ne détecte rien. J'ai confronté quatre classifieurs classiques : régression logistique, séparateur à vaste marge, arbre de décision et forêt aléatoire. À 123 observations, leurs écarts ne sont pas significatifs ; le choix s'est porté sur la forêt aléatoire, dont les probabilités alimentent les niveaux d'alerte. Il faut donc lire ce dispositif pour ce qu'il est : un outil de hiérarchisation de l'attention, pas un oracle.

3.4.4 Axe B : vitesse d'écoulement

Budgéter les réservations de 2026 suppose de distinguer, dans le rythme de vente, ce qui relève de la conjoncture et ce qui relève du programme. C'est l'axe dont les résultats sont les plus solides.

Le rythme est modélisé sur un panel opération $\times$ mois, soit 3 230 observations portant sur 160 opérations, en réintroduisant les mois à zéro réservation entre la première et la dernière vente de chaque programme : les omettre reviendrait à ne compter que les mois où quelque chose s'est passé, donc à surestimer le rythme.

Un modèle à effets aléatoires sépare alors ce qui revient à l'opération de ce qui revient à la conjoncture, et deux enseignements en ressortent. Les deux tiers de la variance tiennent au programme lui-même, avec un coefficient de corrélation intraclasse de 0,66. Et l'effet du taux d'intérêt est fortement significatif : **une hausse d'un point de taux réduit les réservations mensuelles d'environ 19 %**, pour un coefficient de -0,216 associé à une p-valeur inférieure à 10^{-15} . La régression naïve, qui ignore la structure en panel, surestime cet effet.

J'ai posé un garde-fou méthodologique. Sur la série agrégée du groupe, qui compte 114 mois, une régression dynamique à erreurs ARIMA — dont les résidus sont eux-mêmes modélisés comme une série temporelle, avec vérification qu'ils sont assimilables à un bruit blanc et sélection par le critère AICc — ne parvient pas à identifier l'effet du taux, dont le coefficient γ est indiscernable de zéro, avec une p-valeur de 0,82. Les variations du taux sont trop lentes pour être identifiées sur une seule série de cette longueur.

Ce résultat négatif dit deux choses. Il confirme que la significativité obtenue sur le panel n'est pas un artefact de régression fallacieuse, puisque la voie temporelle, plus exigeante sur ce point, ne produit pas d'effet mesurable. Et il indique que les scénarios doivent combiner les deux modèles : la série temporelle fournit la trajectoire de référence, avec sa dynamique et sa saisonnalité, et l'élasticité estimée sur le panel traduit chaque scénario de taux en effet sur le rythme. Sur cette base, présentée en Figure 3.4, une détente à 2,5 % fin 2026 redonnerait environ +6 % de rythme en moyenne sur douze mois, tandis qu'une remontée à 3,5 % en retirerait 3 %.




FIGURE 3.4 – Prévision d'intensité de vente à douze mois sous trois scénarios de taux 2026, avec intervalle à 80 %

À l'échelle d'un programme, la courbe des réservations cumulées suit une forme en S, que j'ai ajustée par une fonction logistique à trois paramètres. Sur les 28 opérations terminées du périmètre, cet ajustement bat la droite dans 25 cas, comme l'illustre la

Figure 3.5. Il fournit surtout un indicateur utile à la trésorerie : le délai d'atteinte de 90 % du potentiel de vente, dont la médiane est proche de vingt mois. Sa limite est connue et vérifiée : en début de commercialisation, le potentiel n'est pas identifiable, et l'outil n'est donc proposé que sur les programmes suffisamment avancés.




FIGURE 3.5 – Réservations cumulées et courbes logistiques ajustées sur quatre opérations terminées, avec le repère des 90 % du potentiel

3.4.5 Axe C : prix du stock

Repricer le stock suppose de savoir à quel prix chaque lot devrait se vendre. Le modèle retenu est volontairement le plus simple qui fonctionne : une régression linéaire du logarithme du prix au mètre carré des 5 064 appartements transigés depuis 2016, expliqué par la surface, l'étage, l'exposition, le type de produit, l'agence, la commune, la proximité du littoral et l'année de réservation. Il explique 88,6 % de la variance sur l'échantillon test, avec une erreur type d'environ 11 % sur le prix.

Son intérêt principal n'est pas sa performance mais sa lisibilité : ses coefficients se lisent comme des prix implicites, ce qui permet de les discuter avec la direction commerciale. On y lit une prime d'étage de +6 %, une prime d'exposition sud, une décote de 63 % pour le logement social qu'expliquent des prix réglementés, et un effet millésime d'environ +19 points entre 2016 et 2023, suivi d'un plateau. Ce plateau recoupe l'axe B : les prix du neuf n'ont pas baissé avec la remontée des taux, c'est le volume qui s'est ajusté. Une variante régularisée n'apporte rien, avec cinq mille observations pour une trentaine de coefficients.

Appliqué aux 127 appartements en stock, ce modèle sert de détecteur : au seuil d'une erreur type, 103 lots sont dans le marché, 8 au-dessus du prix estimé et 16 en dessous. La recommandation de remise est ensuite posée comme une optimisation sous contrainte : maximiser le revenu attendu à douze mois, en ajustant chaque prix dans des bornes commerciales de -10 à +5 %, sous un objectif d'accélération de l'écoulement, la demande réagissant au prix avec une élasticité fixée à -1.

Ce paramètre est la fragilité assumée de l'axe, et je préfère l'exposer que la laisser découvrir : mon estimation interne donne -0,81, valeur qui a le bon signe mais n'est pas significative sur les 95 opérations disponibles, et la valeur retenue vient de la littérature sur le logement neuf.

Le résultat, lui, est robuste et contre-intuitif. À cette élasticité, la remise optimale est uniforme en euros sur tous les lots, de l'ordre de 23 k€ par lot sur l'opération d'application ; elle est donc proportionnellement plus forte sur les petits lots, à l'inverse de la pratique actuelle. Sur l'opération test, qui compte 18 appartements en stock, viser +8 % d'écoulement déplace le volume attendu de 6,8 à 7,4 lots pour un revenu quasi inchangé, en recul de 0,3 %. L'intérêt de la manœuvre n'est donc pas le revenu immédiat mais la vitesse, et l'économie de frais de portage que l'objectif ne compte pas.

3.4.6 Signaux faibles (texte et réseau)

Trois constats simples, obtenus avec des moyens simples, complètent le dispositif. Un moteur de recherche par similarité, construit sur les 9 688 commentaires libres de vente, remonte les dossiers concernés à partir d'une requête en langage courant, comme « refus de prêt banque » : c'est un outil d'audit des remises non structurées réellement utilisable. L'analyse des motifs de désistement par agence révèle ensuite un problème de qualité de saisie plus qu'un fait commercial : à Salon-de-Provence, 90 % des motifs sont enregistrés en « Autres motifs », ce qui rend ces désistements inanalysables. La structure du réseau de vente, enfin, se révèle très concentrée : deux acteurs, le réseau interne et un prescripteur externe, portent 51,6 % des dossiers attribués, avec des taux de désistement allant de 9 % pour le premier à 29,6 % pour le second — écart à traduction financière immédiate, chaque commission versée sur un dossier qui n'aboutit pas étant une dépense sans recette.

J'ai enfin tenté de prédire le désistement à partir du seul texte du commentaire, avec un contrôle de fuite soigneux. Cette tentative plafonne à un score F1 de 0,34 : le texte seul ne suffit pas, et il est traité comme un signal d'appoint, non comme un prédicteur.

3.5 Plateforme Streamlit

L'application est la meilleure réponse au risque de sur-complexité évoqué en ouverture : ce qui est livré au métier est simple. Cinq pages, un périmètre restreint aux 147 opérations de promotion, et aucun terme de modélisation à l'écran.

La page **Vue d'ensemble**, présentée en Figure 3.6, donne la situation en quelques secondes : 147 opérations suivies, dont 10 en alerte et 2 à surveiller parmi les 68 opérations en cours suffisamment engagées, les 56 autres étant conformes, 421 lots principaux en stock, un rythme récent de 4,8 réservations par opération et par mois, pour un taux de crédit à 3,11 %.

La page **Alertes marge**, présentée en Figure 3.7, classe les opérations par niveau d'alerte, le score de l'axe A étant traduit en trois niveaux, et affiche pour chacune les dépassements déjà engagés en euros et les postes concernés. C'est la page la plus consultée, et il faut redire qu'elle repose sur du SQL et non sur un modèle.

Les trois autres pages transposent les axes restants. **Rythme de vente** fait de l'axe B un simulateur, où un curseur de taux 2026 produit une phrase de résultat fondée sur l'élasticité du panel. **Pilotage des prix** affiche le diagnostic du stock et la grille d'ajustement recommandée. **Qualité commerciale** reprend les signaux faibles, alerte de saisie comprise. Chaque page a été vérifiée par le cadre de test de Streamlit, y compris




FIGURE 3.6 – Plateforme, page « Vue d'ensemble »




FIGURE 3.7 – Plateforme, page « Alertes marge » : niveaux d'alerte et dépassements engagés en euros

aux bornes des curseurs et sur les sélections vides, et l'ensemble se reconstruit depuis les exports bruts.

3.6 Périmètre et limites

L'énoncé des limites fait partie du livrable, au même titre que les résultats : c'est ce qui permet à la direction financière de savoir jusqu'où elle peut s'appuyer sur l'outil.

La limite principale est structurelle et commande la suite du projet : les données budgétaires sont une photographie à date, sans historique des révisions. C'est elle qui plafonne l'axe A. Ma première recommandation à l'entreprise est donc d'historiser les exports mensuels dans le nouvel ERP : au bout d'un an, le score statique deviendra un véritable suivi de trajectoire.

Les autres limites sont assumées : l'échantillon de l'axe A est petit, 123 opérations, et les écarts entre modèles y sont indiscernables, ce qui a motivé le choix d'un modèle interprétable unique ; l'élasticité de l'axe C vient de la littérature, si bien que les recommandations de prix sont des aides à la décision non opposables, la grille restant sous le contrôle de la direction commerciale ; les intervalles de prévision de l'axe B ignorent l'incertitude sur les taux futurs, raison pour laquelle la plateforme présente des scénarios plutôt qu'une prévision unique ; et le texte des commentaires reste un signal d'appoint.

La plateforme couvre enfin la promotion, soit 147 opérations, et exclut l'aménagement foncier, dont la logique économique justifierait un traitement dédié. L'analyse, elle, couvre les 267 opérations des exports de gestion. La frontière entre les deux activités ressort d'ailleurs d'elle-même dès l'analyse exploratoire, ce qui valide involontairement le choix de périmètre demandé par l'entreprise.

3.7 Méthode, évaluation et limites du projet

Ce projet a suivi une logique différente de celle des reprises du chapitre 1, en trois temps séparés : le **cadrage**, qui formule les questions de gestion avant de regarder les données et pose les exigences non fonctionnelles ; l'**exploration et la modélisation**, chaque question étant traitée par la méthode la plus simple qui y réponde ; la **restitution**, qui traduit les résultats dans le langage de l'utilisateur. Le point d'articulation le plus délicat se situe entre les deux dernières étapes : la première version de l'interface, trop marquée par le vocabulaire de la modélisation, a dû être entièrement réécrite, et cette réécriture a changé ce que l'écran affiche, donc ce sur quoi l'utilisateur décide.

Le régime de preuve applicable ici est celui de la **validation statistique** : la question n'est pas si la donnée est bien arrivée, mais si le résultat tient hors de l'échantillon sur lequel il a été construit. J'y ai systématiquement associé un échantillon test distinct, une comparaison à une référence naïve et un contrôle des fuites. La comparaison à la référence est celle qui m'a le plus servi : un score F1 de 0,3 ne veut rien dire dans l'absolu, mais il prend un sens précis lorsque la référence majoritaire ne détecte rien. Son angle mort est qu'il mesure une performance sur des données passées, dans une conjoncture donnée.

Trois difficultés relèvent enfin de la donnée elle-même : l'**absence d'historique**, déjà

évoquée ; la **qualité de saisie**, dont le cas de Salon-de-Provence a produit une recommandation opérationnelle immédiate ; et l'**impossibilité d'estimer certains paramètres en interne**, l'élasticité de la demande au prix ayant le bon signe dans nos données sans y être significative.

3.8 Conclusion du chapitre

Le Copilote Financier répond aux trois questions posées en ouverture, mais pas avec la même force, et il est plus honnête de le dire que de présenter un ensemble homogène. L'axe B est solide : l'effet du taux d'intérêt sur le rythme de réservation est mesuré, séparé de l'effet propre à chaque programme, et confirmé par un garde-fou méthodologique qui aurait pu l'invalider. L'axe C est lisible et directement discutable avec la direction commerciale, à la réserve près d'un paramètre d'élasticité emprunté à la littérature. L'axe A ne dépasse pas le stade du score de tri, et sa partie la plus utilisée n'est pas un modèle mais une requête SQL.

Ce déséquilibre n'est pas un accident de parcours, c'est une conséquence directe de la donnée disponible : là où j'avais une profondeur temporelle, le modèle a produit un résultat exploitable ; là où je n'avais qu'une photographie à date, il n'a pas pu en produire. C'est l'apport principal du projet, et il vérifie la thèse annoncée en introduction. Les deux recommandations formulées plus haut, historiser les exports mensuels et fiabiliser la saisie des motifs de désistement, sont d'ailleurs de la même nature que les chantiers du chapitre 1 : des travaux de structure, faits pour rendre possible une analyse à venir.

Une succession de récits de mission ne fait pourtant pas un bilan. Comment ces projets ont-ils été conduits, avec quelles méthodes, comment ai-je su que le résultat était bon, et qu'est-ce qui n'a pas fonctionné ? Le chapitre suivant relit transversalement les quatre missions sous ces angles.

Chapitre 4

Réflexion sur le métier, perspectives et projet professionnel

Sommaire

4.1	Réflexion sur le métier	33
4.2	Perspectives et projet professionnel	36

Ce dernier chapitre quitte le récit des missions pour livrer la réflexion qu’elles ont produite, puis le projet professionnel qui en découle.

4.1 Réflexion sur le métier

Un traducteur avant d’être un modélisateur. L’image que j’avais de ce métier en entrant en Master 2 était celle que donne le cursus : on reçoit un jeu de données et une question, on choisit une méthode, on évalue, on livre un modèle. Cette image n’est pas fausse, elle est simplement très minoritaire dans le temps réel. Sur les quatre missions de l’année, une seule y correspond, et encore partiellement ; le poste que j’ai réellement occupé se rapproche de celui de gestionnaire d’applications tel que le décrivent les référentiels métier [1]. Ce qui a occupé le reste, c’est un travail de traduction dans les deux sens : traduire une gêne exprimée par un service en question calculable, puis traduire un résultat statistique en information sur laquelle quelqu’un peut décider.

Cette traduction est le vrai travail, et elle est difficile pour une raison précise : les deux langues n’ont pas les mêmes catégories. Le service juridique parle de commandes payantes et gratuites ; la base ne connaît que des lignes sans position dans une séquence. La direction financière parle d’opérations qui dérivent ; les exports ne contiennent qu’un budget et un engagé à une date. Chaque fois, il a fallu construire la catégorie manquante, et ce sont ces constructions qui engagent le plus, parce qu’elles décident de ce que l’entreprise pourra observer ensuite.

Les outils comptent moins que les méthodes. Le tableau suivant récapitule les technologies et les méthodes effectivement employées, en distinguant ce qui relève de l’outil de ce qui relève de la méthode.

Mission	Technologies	Méthodes
Migration des opérations	Excel et RechercheX, MyReport Builder, API REST de Salvia, module DirectAPI	Rétro-ingénierie du modèle cible par les codes d’erreur, mapping par tables de correspondance, validation itérative par paliers
Reprise des tiers	Excel, environ 60 000 cellules de formules, CSV, API REST, JSON Patch, Postman	Déduplication par clés d’unicité différenciées, exclusion par rapprochement, numérotation séquentielle par destination
Reporting et SSO	MyReport, SQL en lecture, annuaire d’entreprise	Modélisation dynamique par calcul de rang, accompagnement utilisateur

Mission	Technologies	Méthodes
Copilote Financier	Python et pandas, SQLite en schéma en étoile, PySpark évalué, Streamlit	Régression linéaire et logistique, arbre, forêt aléatoire, séparateur à vaste marge, modèle à effets aléatoires sur panel, régression dynamique à erreurs ARIMA, ajustement logistique, recherche par similarité, optimisation sous contrainte

La colonne des outils est beaucoup moins intéressante que celle des méthodes, ce qui est contre-intuitif quand on sort d'un cursus où l'on apprend des technologies. Excel figure dans deux missions sur quatre, non qu'il soit le bon outil dans l'absolu, mais parce que c'est celui que l'entreprise sait relire, corriger et maintenir sans moi. Un script Python aurait produit les mêmes fichiers plus vite, et personne n'aurait pu le reprendre après mon départ.

La place réelle de la modélisation. Le constat suivant est plus inconfortable, et je le formule d'autant plus volontiers qu'il va contre ce que j'espérais démontrer en commençant le projet du second semestre. Dans le Copilote Financier, la page la plus consultée par les contrôleurs de gestion ne repose sur aucun modèle appris : c'est un tableau descriptif de dépassements en euros, calculé en SQL. La sophistication des méthodes décroît quand on se rapproche de l'utilisateur, et ce n'est pas un échec de la modélisation, c'est sa place réelle dans un outil de gestion.

J'en tire deux choses plus précises. La première est que **la valeur d'un projet data ne se mesure pas au degré de sophistication des méthodes employées**, mais à l'écart entre ce que l'entreprise savait avant et après. La seconde est que **le choix de la méthode se déduit de la donnée disponible, jamais de l'ambition du projet** : sur le rythme de vente, la profondeur temporelle autorisait un modèle exigeant, et il a donné un résultat solide ; sur le risque de marge, l'absence d'historique interdisait tout modèle dynamique, et aucune sophistication n'aurait compensé cette absence.

Le régime de preuve se déduit de la nature du livrable. C'est l'enseignement transversal le plus utile de l'année, et il n'apparaît que dans la comparaison entre les missions : une reprise de données, un tableau de bord et un modèle statistique ne se prouvent pas de la même manière. La Figure 4.1 représente les trois régimes que j'ai employés, chacun étant exposé au chapitre où il s'applique — la réconciliation au chapitre 1, la recette par l'usage au chapitre 2, la validation statistique au chapitre 3.

Appliquer à une reprise de données les critères d'un modèle statistique, ou l'inverse, revient à ne rien prouver du tout. Un second enseignement transversal s'y ajoute : l'arbitrage entre exhaustivité et continuité de service est revenu dans les quatre missions — les « coquilles vides », le traitement manuel des cas particuliers, le calcul dynamique, le périmètre restreint à la promotion. Dans les quatre cas, la décision a consisté à livrer quelque chose d'utile et d'incomplet plutôt que rien de complet, et ce qui distingue cet arbitrage d'un renoncement est uniquement le fait d'écrire ce qui a été laissé de côté. Une




FIGURE 4.1 – Les trois régimes de preuve employés selon la nature du livrable

dette documentée est une dette suivie ; une dette implicite devient, quelques mois plus tard, une donnée que tout le monde croit absente.

Documenter est un acte technique. J'ai longtemps considéré la documentation comme une formalité qui suit le travail. Deux épisodes m'ont fait changer d'avis : la note interne sur la séquence d'injection, qui a servi à la reprise des tiers six mois plus tard et aurait servi à quelqu'un d'autre si je n'avais pas été là ; et la note de procédure de l'import des tiers, qui énonce les manipulations à ne jamais faire avant d'expliquer comment utiliser le fichier. J'en retire une formulation que j'assume : **documenter, ce n'est pas décrire ce qu'on a fait, c'est rendre le travail reprenable par quelqu'un d'autre.**

Livrer, c'est faire adopter. La leçon la plus nette de l'année tient en un épisode : la première version de l'interface du Copilote Financier, techniquement correcte, était inutilisable par ceux à qui elle était destinée, parce qu'elle parlait de scores et de probabilités là où l'on attendait des niveaux d'alerte et des euros. Un livrable n'existe qu'à partir du moment où quelqu'un s'en sert, et la distance entre un résultat juste et un résultat utilisé ne se comble pas par de la pédagogie : elle se comble en changeant le livrable. C'est aussi pourquoi j'ai fait de l'énoncé des limites une partie du livrable, au même titre que les résultats. Dans un exercice universitaire, présenter un modèle faible est un mauvais résultat ; dans une entreprise, présenter un modèle faible **sans le dire** est bien pire, parce que quelqu'un décidera dessus.

Le tableau suivant récapitule ce qui a été livré et se trouve aujourd'hui en service.

Livrable	Volume ou périmètre
Opérations créées dans SPO, hors budgets détaillés	283
Tiers créés dans SPO, avec leurs objets rattachés	1 434
Adresses, courriels et téléphones importés	553, 469 et 538
Représentants des couples et des sociétés	1 871
Coordonnées ajoutées par requête API	872 requêtes, toutes passées
Documentation interne produite	Séquence d'injection, procédure d'import des tiers
Reportings maintenus et faits évoluer	Sur l'ensemble des services demandeurs
Postes équipés du SSO	Agence de Perpignan et service financier du siège

Livrable	Volume ou périmètre
Base de données analytique	Trois dimensions, quatre tables de faits, trois vues métier
Application d'aide à la décision livrée	Cinq pages, 147 opérations de promotion suivies

Ces chiffres ne disent pourtant pas l'essentiel. Ce que l'année a produit de plus durable n'est aucun de ces volumes : ce sont trois définitions écrites quelque part. La séquence d'injection valide pour l'ERP, la clé qui décide qu'un client est le même client, et la formule qui dit ce qu'est la marge d'une opération. Les données se réinjectent ; ces trois décisions-là, il faut les reprendre depuis le début si elles se perdent.

4.2 Perspectives et projet professionnel

Achever la reprise et historiser les données. Aucun des chantiers de cette année n'est achevé. La migration vers SPO reste prioritaire : la stratégie des « coquilles vides », si elle a sauvé le démarrage de la facturation, doit laisser place à une reprise exhaustive — historiques budgétaires complets, contrôle de cohérence comptable et tests finaux avant la bascule définitive. Le fichier de reprise des tiers devra être rejoué avant cette bascule, pour écarter les tiers créés entre-temps par les équipes commerciales.

S'y ajoute la recommandation la plus structurante que je laisse à l'entreprise : **historiser les exports mensuels dans le nouvel ERP**. C'est l'absence de cet historique qui plafonne aujourd'hui l'analyse du risque de marge. Au bout d'un an de conservation, le score statique deviendrait un véritable suivi de trajectoire. Cette recommandation ne coûte presque rien à mettre en œuvre ; elle coûte seulement d'y penser maintenant plutôt que dans deux ans.

Faire vivre le Copilote Financier. L'application livrée est fonctionnelle et reproductible, mais elle reste une photographie. Trois évolutions la rendraient durable : l'historisation déjà évoquée, qui transformerait le score de risque en suivi ; l'extension à l'aménagement foncier, dont la logique économique différente suppose un traitement dédié plutôt qu'une simple levée de filtre ; et la fiabilisation de la saisie des motifs de désistement, sans laquelle les analyses commerciales resteront partielles sur une partie du réseau.

L'intégration à l'infrastructure Nexity. Une mission structurante, non prévue initialement, s'ajoute à cette feuille de route : le passage vers l'infrastructure technique du groupe Nexity, qui engendrera des adaptations de nos outils — reconfiguration des connecteurs de bases, protocoles de sécurité pour les accès distants, migration de scripts d'automatisation. Cette perspective a déjà influé sur mes choix techniques : le test de montée en charge conduit dans le projet analytique n'avait pas d'autre objet que de savoir si l'architecture retenue tiendrait à une échelle supérieure.

Le positionnement que je vise. Ces deux années ont déplacé mon projet. J'y suis entrée en visant la data science au sens strict, la modélisation prédictive ; j'en sors en visant un positionnement plus large : **construire et fiabiliser les chaînes de données**

qui rendent la décision possible, puis les outiller. Il croise trois domaines que l'année m'a fait pratiquer ensemble : l'**ingénierie des données**, sur laquelle j'ai le plus progressé — reprises, migrations, interfaces de programmation, déduplication, modélisation d'une base analytique ; l'**analyse et la modélisation**, entendues comme le choix d'une méthode proportionnée à la donnée disponible et sa validation honnête ; la **restitution et le dialogue avec les métiers**, c'est-à-dire la traduction d'un besoin en spécification puis d'un résultat en écran. Un profil qui ne tiendrait que le premier produirait des pipelines que personne n'interroge ; un profil qui ne tiendrait que le deuxième modéliserait des données dont il ignore la provenance.

À court terme, je souhaite poursuivre au sein du groupe, sur le périmètre données et système d'information : la reprise des historiques budgétaires, la bascule définitive vers SPO et l'adaptation des outils à l'infrastructure Nexity forment un ensemble sur lequel ma connaissance du modèle de données constitue un avantage que personne d'autre n'a aujourd'hui dans l'entreprise. À moyen terme, je vise un poste d'ingénieure données orientée aide à la décision, dans une entreprise de taille intermédiaire sans équipe data constituée, où le poste couvre toute la chaîne, ou dans une direction data structurée où je travaillerais enfin à plusieurs sur un même chantier.

Ce qu'il me reste à consolider. Il serait présomptueux de conclure sans nommer ce qui me manque, d'autant que l'année l'a rendu visible. L'**industrialisation** d'abord : j'ai construit des chaînes reproductibles, mais elles se lancent à la main, et passer à une exécution planifiée, surveillée et alertée en cas d'échec est ce qui sépare un livrable d'un service. La **profondeur statistique sur les données temporelles** ensuite : c'est l'axe où le projet du second semestre a donné les meilleurs résultats, et celui où j'ai le plus senti la limite de mes acquis. La **conduite d'un projet à plusieurs** enfin : deux ans seule sur les sujets data laissent hors champ les conventions de code partagées, la revue par un pair et la répartition d'un chantier entre plusieurs personnes.

Conclusion

Cette deuxième année d'alternance a été dominée par des enjeux d'ingénierie des données et d'architecture système, avant de revenir au second semestre à la modélisation statistique.

Le premier semestre a été celui de la reconstruction du socle. La migration de Grimmo vers l'ERP SPO ne consistait pas à transférer des données, mais à rétro-concevoir un modèle dont les règles n'étaient pas documentées, à résoudre des problèmes d'intégrité référentielle avec la gestion des identifiants dynamiques et du versionnement, et à adapter la technique aux impératifs métier — ce qu'illustre l'adoption des « coquilles vides » pour sécuriser le démarrage de la facturation. En parallèle, j'ai maintenu le service sur le reporting, avec la mise en œuvre d'une règle juridique complexe malgré les contraintes de nos outils, et participé au déploiement du SSO.

Le second semestre a prolongé ce travail, puis l'a valorisé. La reprise des tiers a achevé de constituer le socle commercial du nouvel ERP, en créant 1 434 clients acquéreurs sans doublon détecté par les trois clés d'unicité retenues. Le Copilote Financier a ensuite exploité ce socle pour outiller la direction financière sur trois questions de gestion, de bout en bout, de la compréhension des exports jusqu'à une application que les contrôleurs de gestion ouvrent eux-mêmes.

Ce parcours aura démontré la thèse annoncée en introduction, et il l'aura fait deux fois. Une première fois en creux, lorsque la charge de la migration a repoussé le projet de modélisation au second semestre : modéliser des phénomènes financiers sur une base fragmentée entre l'ancien et le nouveau système aurait donné des résultats biaisés et non pérennes. Une seconde fois en plein, lorsque le projet de Data Science a donné des résultats solides sur le rythme d'écoulement, où les données avaient une profondeur temporelle, et modestes sur le risque de marge, où elles n'étaient qu'une photographie à date. La structure de la donnée commande ce que la modélisation peut en tirer : c'est le même énoncé, obtenu par deux chemins indépendants.

Il reste beaucoup à faire. La migration n'est pas achevée, l'historique budgétaire reste à reprendre, l'intégration à l'infrastructure Nexity s'annonce, et le Copilote Financier ne deviendra un véritable outil de suivi que lorsque les exports auront été historisés sur une durée suffisante. Ce que cette année aura établi n'en dépend pas. Un projet de données ne se joue pas au moment du choix de l'algorithme mais bien avant, lorsqu'on décide ce qu'est un client, ce qu'est une marge, ou ce que contient réellement un fichier dont le nom annonce autre chose. Structurer une donnée et la modéliser ne sont pas deux métiers successifs, mais deux moments du même travail, et c'est le premier qui décide de ce que le second pourra en tirer.

Bibliographie

- [1] Michael Page. (2025). *Fiche métier : gestionnaire d'applications*. [En ligne]. Disponible sur : <https://www.michaelpage.fr/advice/m%C3%A9tiers/syst%C3%A8mes-dinformation/fiche-m%C3%A9tier-gestionnaire-d%E2%80%99applications>.
- [2] Salvia Développement. (2025). *Site officiel de l'éditeur de la solution SPO et documentation technique de son API*. [En ligne]. Disponible sur : <https://www.salviadeveloppement.fr/>.
- [3] Bryan, P. et Nottingham, M. (2013). *JavaScript Object Notation (JSON) Patch*, RFC 6902, Internet Engineering Task Force. [En ligne]. Disponible sur : <https://www.rfc-editor.org/rfc/rfc6902>.
- [4] Banque centrale européenne. *Taux d'intérêt des crédits à l'habitat en France, série mensuelle*. [En ligne]. Disponible sur : <https://data.ecb.europa.eu/>.
- [5] Eurostat. *Indicateur de confiance des ménages*. [En ligne]. Disponible sur : <https://ec.europa.eu/eurostat>.
- [6] Etalab. *API Découpage administratif, référentiel des communes françaises*. [En ligne]. Disponible sur : <https://geo.api.gouv.fr/>.